Flow Along the K-Amplitude for Generative Modeling

Weitao Du[1] Jiasheng Tang[1] Shuning Chang[1] Yu Rong[1] Fan Wang[1]
Shengchao Liu[2]

ALIBABA DAMO ACADEMY[1]

UNIVERSITY OF CALIFORNIA, BERKELEY[2]

ICLR2025

Motivation

背景、轮廓（粗粒度，大尺度）

五官、纹理（细粒度，小尺度）

现有的图像生成方法（VAE GAN FM等）：

想修改背景->五官糊了
想修改五官->背景变了

现有生成方法不能分开控制粗粒度和细粒度
未结合数据的尺度规律

回顾标题 Flow Along the K-Amplitude for Generative Modeling

如何度量数据的尺度？——尺度参数k与K-幅度

我们定义信号（数据）为ϕ，空间的基向量为$\{e_j\}_{j=1}^{n}$

可以对信号进行某种分解$\phi = \sum_k \phi_k$，也就是将原始信号分解为了尺度不同的信号之和

k即尺度参数，k用来表达数据的尺度，k小（粗粒度），k大（细粒度）

ϕ_k的范数就是K-幅度 ⟷ $E \propto A_k^2$，物理中能量与幅度平方成正比

↓

K-幅度的大小反映了能量的大小，也就是该尺度信息的重要性

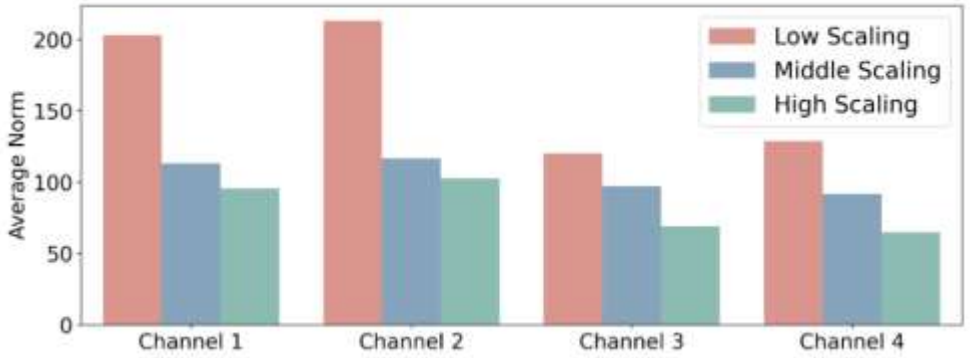

Flow Matching(FM)流匹配

核心是求解常微分方程(ODE)

$$\frac{d}{dt}\Psi_t(x) = v_t(\Psi_t(x))$$

学习的目标
演化的依据是时间t，未包含尺度信息！

$\Psi_t(x)$即流(Flow)，表示t时刻数据的状态， $v_t(x)$是速度场

令$\Psi_0(x)$（初始的简单分布）通过ODE演化到$\Psi_1(x)$（真实数据分布）

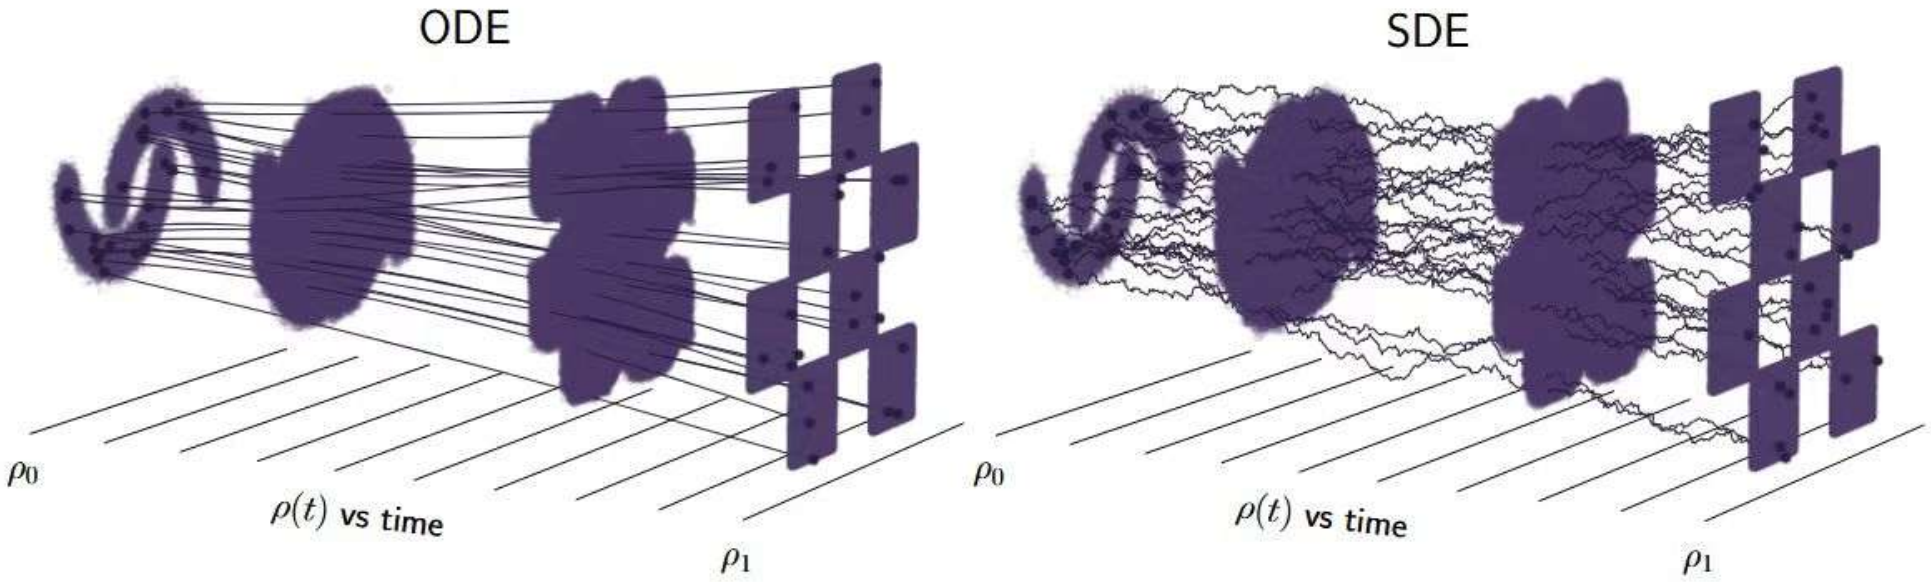

K-Flow核心创新

Flow Matching

$$\frac{d}{dt}\Psi_t(x) = v_t\big(\Psi_t(x)\big), t \in [0,1]$$

噪声->图像

技术实现:time embedding

尺度参数k替换时间t

K-Flow

$$\frac{d}{dk}\Psi_k(x) = v_k\big(\Psi_k(x)\big), k \in [0, k_{max}]$$

噪声->低尺度特征->高尺度特征->图像

技术实现:k embedding

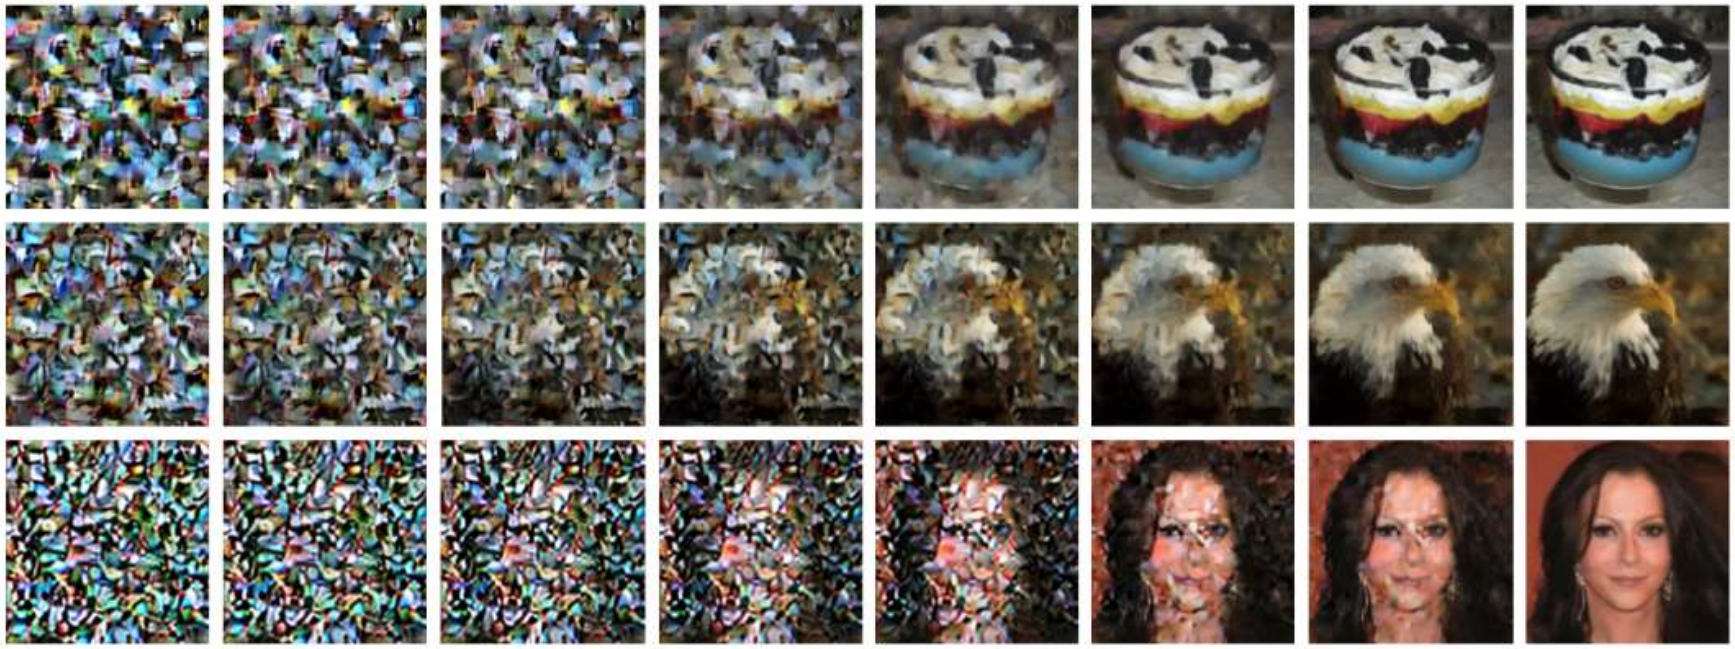

Low-scaling

High-scaling

K-Flow pipeline

随机采样尺度参数k, 采样训练数据ϕ, 采样噪声ϵ

Step1:K-幅度分解(可逆变换) $\phi = \sum_k \phi_k$具体如何分解?

傅里叶变换:$\mathcal{F}\{\phi\}(k_x, k_y, k_z) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \phi(x,y,z) e^{-2\pi i(k_x x + k_y y + k_z z)}\, dxdydz$

小波变换:$\phi(x) = \sum c_k \omega_k(x) + \sum d_k \phi_k(x)$

PCA主成分分析:$\phi_k = U_k \phi$

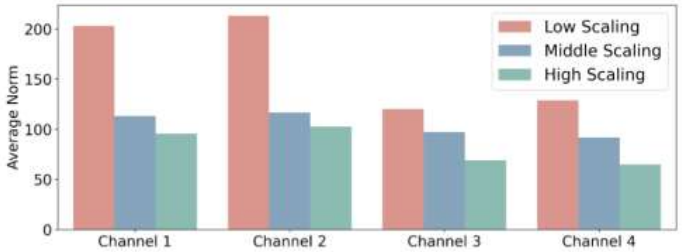

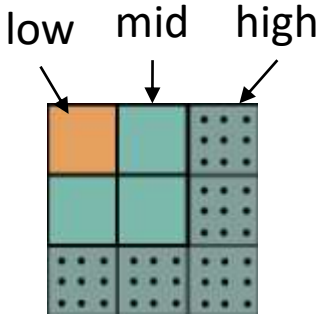

Step2:计算当前尺度k下的流位置$\Psi_k = \varphi_k$(以傅里叶变换为例)

使用指示函数和逆变换构造当前的流

$$\varphi_k = \mathcal{F}^{-1}\left(\mathbb{1}_{\sqrt{k_x^2+k_y^2+k_z^2}\le k} \cdot \mathcal{F}\{\phi\}(k_x,k_y,k_z) + \left(1 - \mathbb{1}_{\sqrt{k_x^2+k_y^2+k_z^2}\le [k]+1}\right)\cdot \epsilon\right)$$

$$\begin{aligned}\Psi_k &= \Psi_{[k]+t} \\ &= \mathcal{F}^{-1}\left(\mathbb{1}_{\sqrt{k_x^2+k_y^2+k_z^2}<[k]} \cdot \mathcal{F}\{\phi\}(k_x,k_y,k_z) + \left(1 - \mathbb{1}_{\sqrt{k_x^2+k_y^2+k_z^2}\ge [k]+1}\right)\cdot \epsilon \right. \\ &\left. + \mathbb{1}_{\sqrt{k_x^2+k_y^2+k_z^2}\in [[k],[k]+1)} \cdot \left(\mu(t)\cdot \mathcal{F}\{\phi\}(k_x,k_y,k_z) + (1-\mu(t))\cdot \epsilon\right)\right)\end{aligned}$$

低尺度分量直接保留数据信息;
高尺度分量用噪声填充;
中间尺度分量通过bump函数$\boldsymbol{\mu(t)}$实现数据与噪声的线性插值(确保流的连续性)

K-Flow pipeline

随机采样尺度参数k, 采样训练数据ϕ, 采样噪声ϵ

Step3:向量场的计算

$$\frac{d\Psi_k}{dk}(\phi,\epsilon) = \mathcal{F}^{-1}\left(\mathbb{I}_{\sqrt{k_x^2+k_y^2+k_z^2}\in[[k],[k]+1)} \cdot \mu'(t)\left(\epsilon - \mathcal{F}\{\phi\}(k_x,k_y,k_z)\right)\right)$$

只有当前k的尺度区间有非零导数，

局部向量场

仅更新当前局部的尺度

Step4:Loss function

$$\mathcal{L}_{k-flow} = E_{\phi_0}\int_0^K d\phi_0 dk \left\|\frac{d\Psi_k}{dk} - v_k(\Psi_k,\theta)\right\|^2$$

模型推理:逆变换

当前状态Ψ_k->根据$v_k(\Psi_k,\theta)$求解ODE$\frac{d}{dk}\Psi_k(x) = v_k\left(\Psi_k(x)\right)$(仅更新当前$k$范围的信息)->最后逆变换到原来空间

Low-scaling High-scaling

Properties of K-Flow

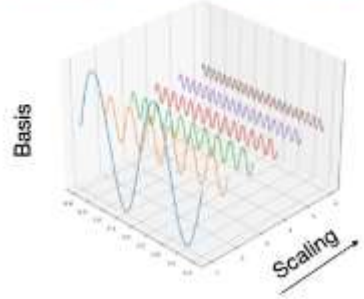

1.按数据的能量规律按尺度k拆解信号，自然处理尺度信息

2.支持多尺度建模。低/中/高的k分别建模背景/细节等多尺度信息

3.与物理规律统一。能量与幅度平方成正比，k小/大，能量高/低

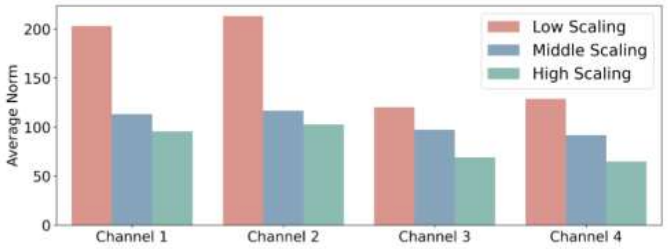

4.尺度k=演化的依据（时间t）。
早期先画背景，后期画细节，符合认知上“画画”的规律

5.不同尺度间的平滑过渡。特殊设计bump函数$\mu(t)$

6.精准控制生成内容。通过k调整不同尺度的生成过程

Experiments

1.无条件生成+条件生成

Table 4: Class-conditional generation on ImageNet.

Model	FID↓	CDR↓	Recall↑
K-Flow, Wave-DiT L/2 (Ours)	17.8	-	0.56
+ cfg=1.5	4.49	-	0.44
K-Flow, Fourier-DiT L/2 (Ours)	13.5	-	0.57
+ cfg=1.5	**2.77**	**1.49**	0.45
LFM, DiT L/2	14.0	-	0.56
+ cfg=1.5	2.78	3.25	0.42
LDM-8 [54]	15.51	-	**0.63**
LDM-8-G	7.76	-	0.35
DiT-B/2 [32]	43.47	-	-

Table 2: Unconditional generation on CelebA-HQ 256.

Model	FID↓	Recall↑
K-Flow, Fourier-DiT L/2 (Ours)	5.11	0.47
K-Flow, Wave-DiT L/2 (Ours)	**4.99**	0.46
K-Flow, PCA-DiT L/2 (Ours)	5.19	0.48
LFM, ADM [53]	5.82	0.42
LFM, DiT L/2 [53]	5.28	0.48
FM [9]	7.34	-
LDM [54]	5.11	**0.49**
LSGM [55]	7.22	-
WaveDiff [42]	5.94	0.37
DDGAN [56]	7.64	0.36
Score SDE [31]	7.23	-

Table 3: Unconditional generation on LSUN Church 256.

Model	FID ↓	Recall ↑
K-Flow, two scales (Ours)	5.37	0.47
K-Flow, three scales (Ours)	**5.19**	**0.49**
LFM (ADM)	7.7	0.39
LFM (DiT L/2)	5.54	0.48
FM	10.54	-
LDM	4.02	0.52
WaveDiff	5.06	0.40
DDPM	7.89	-
ImageBART	7.32	-

Experiments

2. 控制条件生成

在生成的最后阶段丢弃掉条件信息（猫、狗。。）

结论：
K-flow可以有效保留高频信息而普通的FM趋于模糊

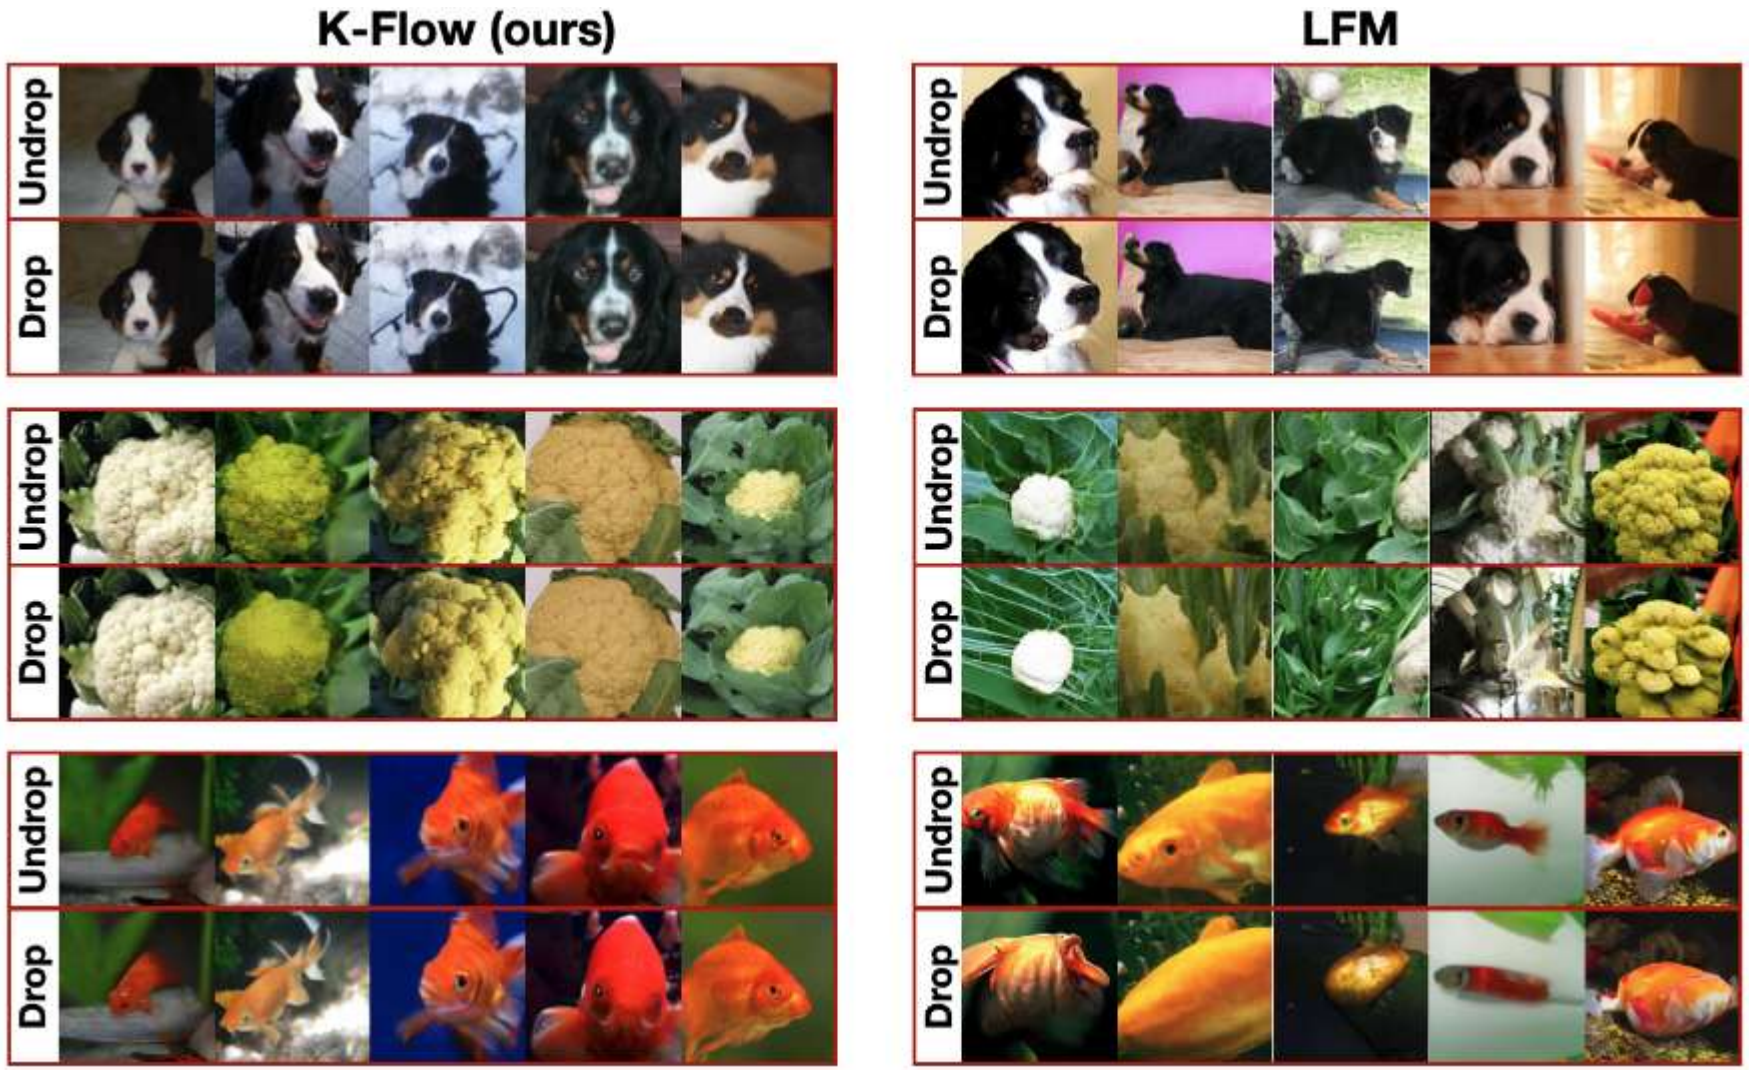

Experiments

3. 尺度控制生成

高尺度噪声不变，修改低尺度噪声

低尺度噪声不变，修改高尺度噪声

Experiments

4. 科学研究（分子组装）

	COD-Cluster17-5K		COD-Cluster17-10K		COD-Cluster17-All	
	PM (atom) ↓	PM (center) ↓	PM (atom) ↓	PM (center) ↓	PM (atom) ↓	PM (center) ↓
GNN-MD	13.67 ± 0.06	13.80 ± 0.07	13.83 ± 0.06	13.90 ± 0.05	22.30 ± 12.04	14.51 ± 0.82
CrystalSDE-VE	15.52 ± 1.48	16.46 ± 0.99	17.25 ± 2.46	17.86 ± 1.11	17.28 ± 0.73	18.92 ± 0.03
CrystalSDE-VP	18.15 ± 3.02	19.15 ± 4.46	22.20 ± 3.29	21.39 ± 1.50	18.03 ± 4.56	20.02 ± 3.70
CrystalFlow-VE	14.87 ± 7.07	13.08 ± 4.51	16.41 ± 2.64	16.71 ± 2.35	12.80 ± 1.20	15.09 ± 0.34
CrystalFlow-VP	15.71 ± 2.69	17.10 ± 1.89	19.39 ± 4.37	16.01 ± 3.13	13.50 ± 0.44	13.28 ± 0.48
CrystalFlow-LERP	13.59 ± 0.09	13.26 ± 0.09	13.54 ± 0.03	13.20 ± 0.03	13.61 ± 0.00	13.28 ± 0.01
AssembleFlow	7.27 ± 0.04	6.13 ± 0.10	7.38 ± 0.03	6.21 ± 0.05	7.37 ± 0.01	6.21 ± 0.01
K-Flow (ours)	**7.21 ± 0.12**	**6.11 ± 0.11**	**7.26 ± 0.06**	**6.12 ± 0.07**	**7.23 ± 0.01**	**6.07 ± 0.01**

Future Works

1.多模态生成：文本引导的图像生成等任务，通过将图像与自然语言输入对齐，更好地操控k来生成

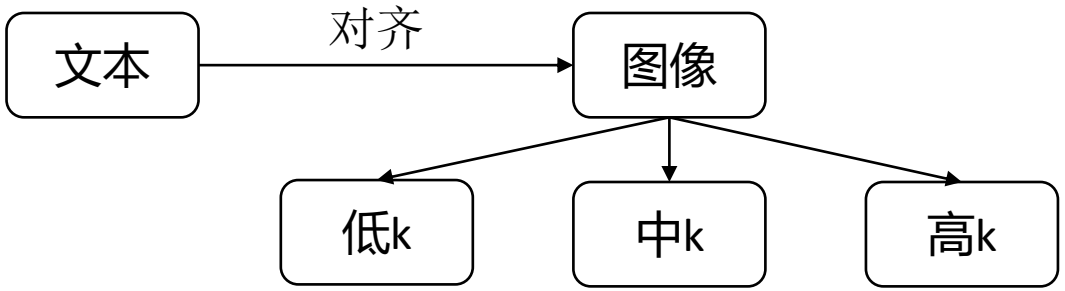

2.深化数学理论：K-幅度和能量的关系仅在实验上有简单验证。
可以进一步探索能量机制在生成模型中的作用，使生成内容更符合物理/数学规律

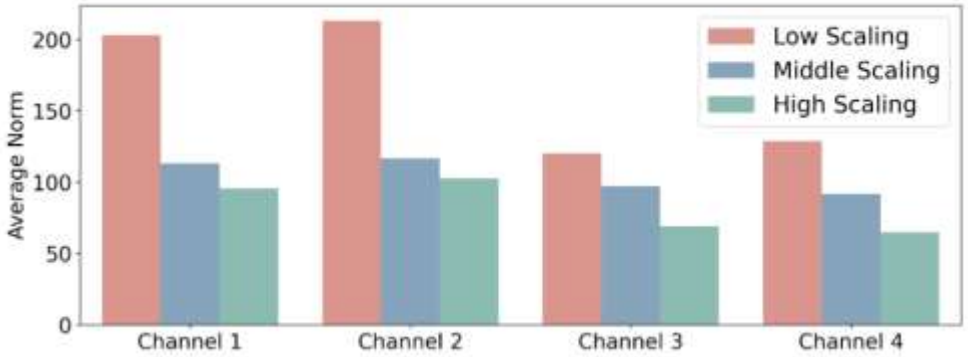

Thanks!

Appendix

$$\Psi_k = \Psi_{[k]+t}$$
$$= \mathcal{F}^{-1}\left(\mathbb{I}_{\sqrt{k_x^2+k_y^2+k_z^2}<[k]} \cdot \mathcal{F}\{\phi\}\left(k_x, k_y, k_z\right) + \left(1 - \mathbb{I}_{\sqrt{k_x^2+k_y^2+k_z^2}\geq[k]+1}\right) \cdot \epsilon\right.$$
$$\left. + \mathbb{I}_{\sqrt{k_x^2+k_y^2+k_z^2}\in\left[[k],[k]+1\right)} \cdot \left(\mu(t) \cdot \mathcal{F}\{\phi\}\left(k_x, k_y, k_z\right) + \left(1 - \mu(t)\right) \cdot \epsilon\right)\right)$$

求导（只有$\mu(t)$是关于k的函数）得到$\frac{d\Psi_k}{dk}(\phi, \epsilon) = \mathcal{F}^{-1}\left(\mathbb{I}_{\sqrt{k_x^2+k_y^2+k_z^2}\in\left[[k],[k]+1\right)} \cdot \mu'(t)\left(\epsilon - \mathcal{F}\{\phi\}\left(k_x, k_y, k_z\right)\right)\right)$

$\mu(t)$满足$\mu(0) = \mu(1) = 1$(作者笔误？), $\mu'(0) = -\mu'(1)$, 保证了可微性质，从而支持梯度优化

Appendix

$$\frac{d\Psi_k}{dk}(\phi,\epsilon) = \mathcal{F}^{-1}\left(\mathbb{I}_{\sqrt{k_x^2+k_y^2+k_z^2}\in[[k],[k]+1)} \cdot \mu'(t)\left(\epsilon - \mathcal{F}\{\phi\}(k_x,k_y,k_z)\right)\right)$$

是一个条件分布，（有ϕ）通过损失的等价性和无条件分布联系起来（参考FM和CFM）

K-幅度分解后数据的分布可以写成：$p_{data} = p(k_0)p(k_1|k_0)\dots p(k_{max}|k_{max}-1,\dots,k_0)$

可以理解为局部特化性（和之前的局部向量场对应，可控生成的数学解释）

无条件向量场的显示表达：$v_t(\Psi_k) = a_t \cdot \Psi_k + b_t \nabla \log p_t(\Psi_k)$ ，a_t ,b_t由bump函数决定

Appendix

K如何影响生成的路径维度？

量化生成轨迹$\{\Psi_k\}$在二维PCA子空间的重建误差

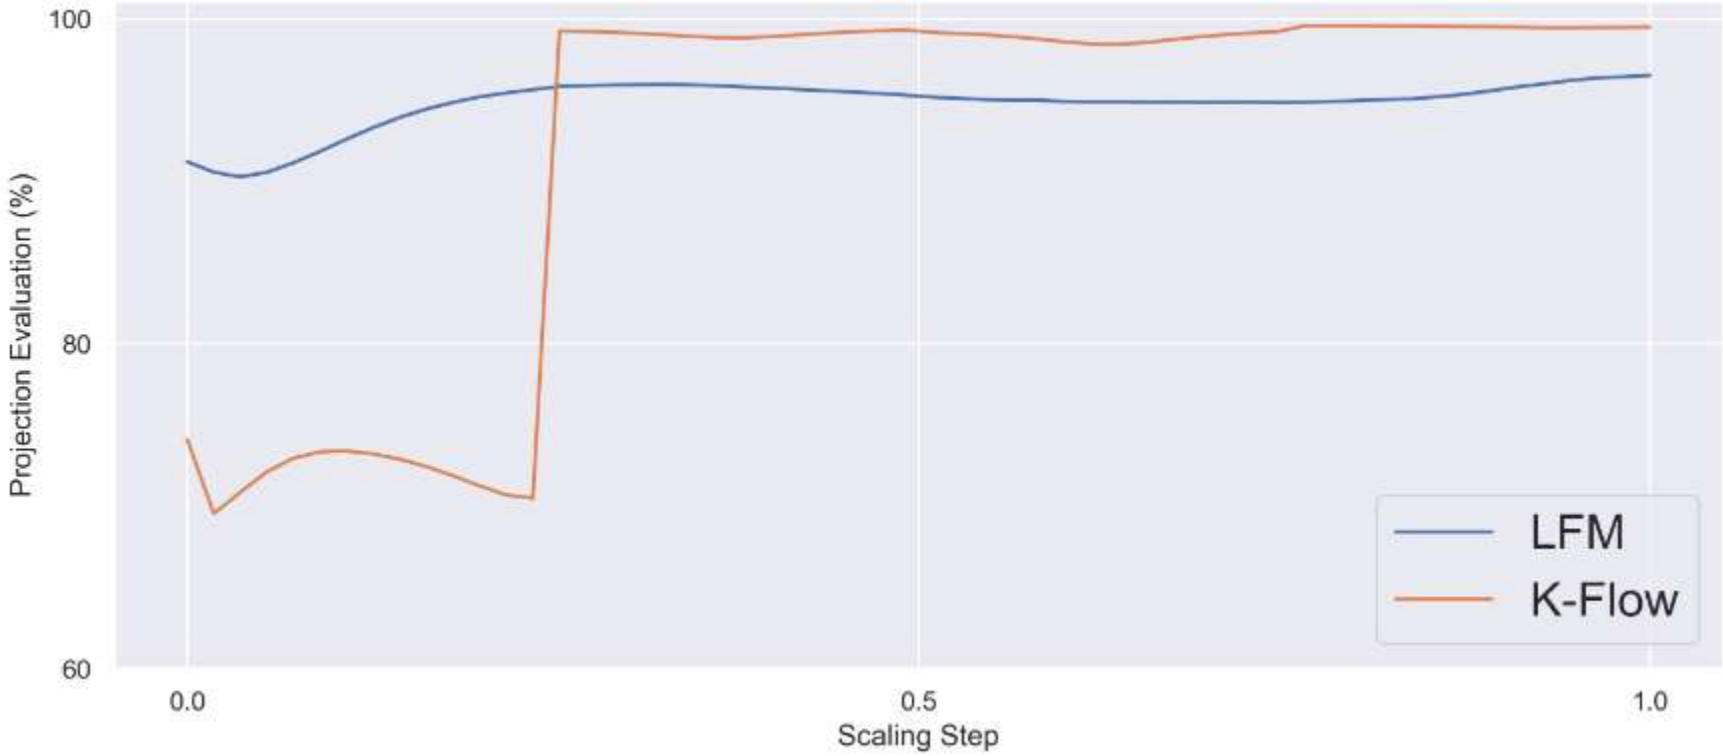

传统流匹配模型的生成路径在全流程中维度分布更均匀

K-Flow低尺度段投影误差更高，说明其低尺度段占据更高的有效维度，语义更丰富，高尺度段收敛到低维，仅补充细节