

ICLR 2025

# MODELING COMPLEX SYSTEM DYNAMICS WITH FLOW MATCHING ACROSS TIME AND CONDITIONS

**Martin Rohbeck<sup>1,2,3,4,\*</sup>, Edward De Brouwer<sup>1</sup>, Charlotte Bunne<sup>1,5</sup>, Jan-Christian Huetter<sup>1</sup>,  
Anne Biton<sup>1</sup>, Kelvin Y. Chen<sup>6</sup>, Aviv Regev<sup>1,†</sup>, Romain Lopez<sup>1,5,†</sup>**

<sup>1</sup>Genentech, USA

<sup>2</sup>Heidelberg University, Germany

<sup>3</sup>German Cancer Research Center, Germany

<sup>4</sup>European Molecular Biology Lab, Germany

<sup>5</sup>Stanford University, USA


<sup>6</sup>Osaka University, Japan

\* This work was conducted during an internship at Genentech. 美国基因泰克公司

2026.5.21 张欣宇


FM完成不同时间及条件下的系统动态变化建模

# Background : T cell to the immune response




# Background : Data capture

## Experimental Framework



数据矩阵

## Processed Data for Modeling



每一个细胞对应：一个时间，一个药物条件

t=k: 取 50 个细胞 → 裂解 → 测序 → 细胞死亡

如何获取数据?

每次测量需要杀死细胞才能做单细胞 RNA 测序

4 个时间点: 给药前 (0h)、24h、48h、72h

100多 种药物+不同浓度


**困难 1: 样本不成对 (Unpaired Samples)**

只能看到每个时间点的"细胞群体快照", 无法追踪单个细胞的演化

**困难 2: 部分 (时间, 条件) 组合缺失 (成本高)**

$\{(c,k): \text{有数据}\} \subsetneq \{1, \dots, 100\} \times \{0, 1, 2, 3\}$

# Target: inferring single-cell data at missing time/drug combinations



我们有  $C$  个条件 (conditions),  $K + 1$  个时间点  $0 = t_0 < t_1 < \dots < t_K = 1$ 。  
在每个被观测的 (时间, 条件) 组合上, 我们观测到一个**概率分布 (细胞群)** :

$$\{p_{t_k}(x \mid c) : c \in [C], k \in [K + 1]\}$$


- 1.生成: Flowmatching建模每个药物条件下的演化轨迹
- 2.插值: 预测未观测时间点/条件下的数据分布
- 3.外推: 泛化到全新的条件

|                 |  | Timepoints |   |   |   |   |   |
|-----------------|--|------------|---|---|---|---|---|
| Small-molecules |  |            |   | ? |   |   | ? |
|                 |  |            | ? | ? |   | ? |   |
|                 |  |            | ? |   |   |   | ? |
|                 |  |            |   | ? |   |   | ? |
|                 |  |            |   |   |   |   |   |
|                 |  |            | ? | ? | ? | ? | ? |

# Synthetic data

$$\begin{cases} u_t(x_t, c_m) = \left[ \left( \frac{c_m}{2} + 1 \right)^{7/4} \cos(5\pi t) \right]^3 \\ x_0(m) = \left[ 0, \frac{c_m - 2}{4} \right] \end{cases}$$

模拟细胞 unpair 演化轨迹：  
每个 (C、t) 采样50个样点后添加高斯噪声  
(确保不是相同轨迹)




目标：  
符合观测  
符合真实细胞演化

|                | 合成数据          | 真实细胞数据                |
|----------------|---------------|-----------------------|
| 数据来源           | ODE 求解 + 高斯噪声 | icCITE-seq 实验         |
| 是否 unpaired    | 是 (每次独立采样噪声)  | 是 (每个细胞只能测一次)         |
| 每个 (c, t) 的样本数 | 50            | 250                   |
| 缺失模式           | c3, c5 缺部分时间点 | 某些药物缺某些时间点            |
| 维度 D           | 2             | 20 (PCA) 或 2000 (HVG) |
| 条件 (药物) 数      | 12            | 60(从123×4中药物条件取)      |
| 时间点数           | 8             | 4                     |

X\_data.shape: (600, 8, 2) (12\*50个轨迹, K+1=8个时间点, D=2维)  
cond\_data.shape: (600, 8)  
t\_data.shape: (600, 8)

# Flow Matching

$$z = (x_0, x_1)$$



(Lipman et al., 2023)

$$\frac{d}{dt} \phi_t(x) = u_t(\phi_t(x)),$$

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t, x \sim p_t(x)} \|v_t(x; \theta) - u_t(x)\|_2^2,$$

给定 $z$ 后的损失:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, z \sim q(z), x \sim p_t(x|z)} \left[ \|v_t(x; \theta) - u_t(x|z)\|_2^2 \right].$$

给定 $z$ 后的速度向量学习对象:

$$u_t(x|z) = \frac{\sigma'_t(z)}{\sigma_t(z)}(x_t - \mu_t(z)) + \mu'_t(z).$$

Flow Matching 定义的轨迹: 插值

常数方差: 若  $\sigma_t \equiv \sigma > 0$ , 则  $\sigma'_t \equiv 0$

$$u_t(x|z) = \frac{\sigma'_t(z)}{\sigma_t(z)}(x_t - \mu_t(z)) + \mu'_t(z).$$


上式退化为  $u_t(x|z) = \mu'_t(z)$ , 向量场简化为纯平移




# Flow Matching

本任务：对缺失的(c,t)插值，把同一个轨迹的不同观测定义为z

$$z := (x_0, \dots, x_K) \in \mathcal{Z} = \mathcal{X}^{K+1}$$




问题：CFM只能处理 2 个边际(p0-p1)  
一个条件下，需要K个CFM



用一个网络实现希望完整的流型

# Multi Marginal Flow Matching

$$z := (x_0, \dots, x_K) \in \mathcal{Z} = \mathcal{X}^{K+1}$$



证明: CFM和MMFM有梯度等价性


$$\nabla_{\theta} \mathcal{L}_{FM}(\theta) = \nabla_{\theta} \mathcal{L}_{MMFM}(\theta).$$

$$\mathcal{L}_{MMFM}(\theta) = \mathbb{E}_{t, z \sim q(z), x \sim p_t(x|z)} \left[ \|v_t(x; \theta) - u_t(x | z)\|_2^2 \right],$$


MMFM 的速度 计算方式一样

$$u_t(x | z) = \frac{\sigma'_t(z)}{\sigma_t(z)} (x_t - \mu_t(z)) + \mu'_t(z).$$

## 最简单MMFM版本



L-MMFM: 分段线性插值: 突变、只看到相邻的点



X\_data.shape: (600, 8, 2)




DataLoader 输出:  
x: (B, 8, 2) 完整的样本骨架 z  
targets: (B, 8) 条件标签  
timepoints: (8,) 时间点数组

v\_t: (B, 1, 2) 神经网络预测的向量场

轨迹怎么定义?



# 关键创新1：符合物理动力学的轨迹

(1) 样条插值：建模轨迹连续性



仅符合观测

目标：



目标：

- 符合观测
- 未观测点符合真实细胞演化


FSI：只能做纯几何的样条插值

MMFM

要让**稀疏条件**也能生成符合系统动力学的轨迹，需要满足两点：

1.条件特定的信息必须能传递给网络（embedding）

Multi-Marginal Flow Matching



c 在 embedding 空间中是连续的，网络可以从密集条件插值到稀疏条件。

（三次样条插值）最小曲率先验：


物理直觉：加速度变化最小的路径（最节能的轨迹）

$$\mu_t(z) = \arg \min_{\gamma \in \mathcal{H}^2([t_0, t_K])} \int_{t_0}^{t_K} \|\gamma''(t)\|_2^2 dt \quad \text{s.t. } x_k = \gamma(t_k)$$

# 关键创新1：符合物理动力学的轨迹

## (2) 自适应方差：“强迫”网络学习

### Multi-Marginal Flow Matching



拱形自适应方差：拱形结构

$$\sigma_t(z) = \frac{4(t_{k+1} - t)(t - t_k)}{(t_{k+1} - t_k)^2},$$

高方差在没有数据的位置能够帮助学习到其它条件的信息


不同条件的高斯扰动产生空间重叠：  
在重叠区域，网络收到：

输入  $(x, c_A, t) \rightarrow$  目标  $u_t^A$


输入  $(x, c_B, t) \rightarrow$  目标  $u_t^B$

必须被迫学习其它条件信息

B. Predicted Trajectory FSI



C. Predicted Trajectory MMFM



# MMFM 退化为 CFM 的条件

如果同时满足以下三个条件：

1.  $\mu_t(z)$  是分段线性函数（在每段  $[t_k, t_{k+1}]$  上是直线）

2.  $\sigma_t(z) = \sigma$  是常数

3. 向量场在每个区间独立建模： $v_t(\cdot; \theta) = \sum_{k=1}^K v_t(\cdot; \theta_k) \mathbf{1}_{[t_k, t_{k+1})}(t)$

那么 MMFM 等价于  $K$  个独立的 CFM 问题。



即使用样条均值 + 时变方差 + 共享参数，模型就能捕捉跨区间的依赖关系。

# Classifier-Free Guidance

实践中问题：模型可能忽略条件c，直接学习所有条件的平均

$$\mathcal{L}_{\text{C-MMFM}}(\theta) = \mathbb{E}_{t, b \sim \text{Ber}(p_u), c \sim \text{Cat}(C), z^c \sim \pi_c^*, x \sim p_t} \left\| v_t \left( x, (1-b)c + bc_{\emptyset}; \theta \right) - u_t(x | z^c) \right\|_2^2,$$

80% 的样本：正常输入  $c \rightarrow$  训练  $v_t(x, c)$

20% 的样本：输入  $\emptyset=0 \rightarrow$  训练  $v_t(x, \emptyset)$



同时学  $v_t(x, c)$  和  $v_t(x, \emptyset)$   
空条件参数单独表示平均作用  
强迫模型增加条件的区分度

$$\hat{x}_T = x_0 + \int_0^T \tilde{v}_t(x, c; w, \theta) dt.$$


对抗"条件混淆"  $\tilde{v}_t(x, c; w, \theta) = (1-w)v_t(x, c_{\emptyset}; \theta) + wv_t(x, c; \theta)$

训练时多个条件的轨迹可能在一些空间区域重叠，模型可能输出不同条件的平均方向。


| w 值 | 效果                  |
|-----|---------------------|
| 0   | 完全无条件，所有条件生成相同的平均轨迹 |
| 1   | 标准条件生成（等价于纯条件模型）    |
| >1  | 放大条件信号的 <b>修正方向</b> |
| <1  | 弱化条件信号，向平均方向靠拢      |

# 关键创新2：unpaired cell - Optimal Transport( optimal couple)

第  $i$  行的样本是伪轨迹：  
这是 unpaired 数据。



Improving and generalizing flow-based generative models  
with minibatch optimal transport——Tong et al. (2024)



$x_t$  公式本身仍是直线。  
全局分布看，不同配对的直线会交叉。  
模型为了纠正这些配对：训练困难，  
生成步数多

问题定义：给定两堆样本：

$$X_0 = \{x_0^{(i)}\}_{i=1}^n, \quad X_1 = \{x_1^{(j)}\}_{j=1}^m$$

寻找最优传输计划  $\Pi^* \in \mathbb{R}_+^{n \times m}$ :  $q(x_0, x_1) = \pi^*(x_0, x_1)$

第  $i$  个源点应该和第  $j$  个目标点配对


$$\Pi^* = \arg \min_{\Pi} \sum_{i=1}^n \sum_{j=1}^m \Pi_{ij} \cdot c(x_0^{(i)}, x_1^{(j)})$$

其中  $c(x, y) = \|x - y\|^2$  为代价函数。

$$\sum_{j=1}^m \Pi_{ij} = \frac{1}{n} \quad \forall i \quad (\text{行和: 每个 } x_0^{(i)} \text{ 运出总质量 } 1/n)$$

$$\sum_{i=1}^n \Pi_{ij} = \frac{1}{m} \quad \forall j \quad (\text{列和: 每个 } x_1^{(j)} \text{ 收到总质量 } 1/m)$$

# 关键创新2：unpaired cell - Optimal Transport( optimal couple)



每一段OT: 600×600的耦合矩阵  
实际训练相当于预处理

$$\pi_k^*(x_k, x_{k+1})$$

↓  
EMD 求解置换矩阵而非分裂质量

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

|   |     |   |      |
|---|-----|---|------|
| ← | 源点0 | 配 | 目标点1 |
| ← | 源点1 | 配 | 目标点0 |
| ← | 源点2 | 配 | 目标点3 |
| ← | 源点3 | 配 | 目标点2 |

# 关键创新2：unpaired cell - Optimal Transport( optimal couple)

多边缘最优传输 (MMOT, Pass 2015):

找到  $K + 1$  个时间点样本的最优联合配对

直接求解困难  $\pi^*(x_1, \dots, x_K)$

假设：仅关注相邻时间点之间的配对——代价函数是两两可加的

$$c(x_0, x_1, \dots, x_K) = \sum_{k=0}^{K-1} c_k(x_k, x_{k+1})$$

优化目标：
$$\inf_{\pi \in \Pi(\mu_1, \dots, \mu_K)} \int_{\mathcal{X}^K} c(x_1, \dots, x_K) d\pi(x_1, \dots, x_K),$$

• 细胞状态的演化是一个连续过程（马尔科夫链, 不许考虑非相邻点）

$$\inf_{\pi \in \Pi(\mu_1, \dots, \mu_K)} \sum_{k=1}^{K-1} \iint_{\mathcal{X} \times \mathcal{X}} c^k(x_k, x_{k+1}) d\pi(x_k, x_{k+1}).$$

构造合法的联合分布：MMOT = K 个OT 过程按照顺序依次配对

$$\pi(x_0, x_1, \dots, x_K) = \mu_0(x_0) \cdot \pi(x_1 | x_0) \cdot \pi(x_2 | x_1) \cdots \pi(x_K | x_{K-1})$$

$$\pi(x_0, \dots, x_K) = \mu_0(x_0) \cdot \frac{\pi_0^*(x_0, x_1)}{\mu_0(x_0)} \cdot \frac{\pi_1^*(x_1, x_2)}{\mu_1(x_1)} \cdots \frac{\pi_{K-1}^*(x_{K-1}, x_K)}{\mu_{K-1}(x_{K-1})}$$

$$\pi^*(x_0, \dots, x_K) = \frac{\prod_{k=1}^{K-1} \pi_k^*(x_k, x_{k+1})}{\prod_{k=2}^{K-1} p_{t_k}(x_k)},$$

## 关键创新2：unpaired cell - Optimal Transport( optimal couple)

证明：MMOT = K 个独立按照顺序的OT求解就是最优解  $\pi^*(x_0, \dots, x_K) = \frac{\prod_{k=1}^{K-1} \pi_k^*(x_k, x_{k+1})}{\prod_{k=2}^{K-1} p_{t_k}(x_k)},$

(1)  $\pi^*$  是一个合法的  $(K + 1)$ -边缘联合分布，其第  $k$  个边缘恰好是  $\mu_k$ 。

数学上，对每个  $k$ ：

$$\downarrow \int_{\mathcal{X}^K} \pi^*(x_0, \dots, x_K) dx_0 \cdots dx_{k-1} dx_{k+1} \cdots dx_K = \mu_k(x_k)$$

(2)  $\pi^*$  在坐标对  $(x_k, x_{k+1})$  上积分掉其余所有变量后，得到的就是  $\pi_k^*$   
每对相邻坐标上的"局部行为"恰好就是该对的独立 OT 最优解。

$$\pi^*(x_k, x_{k+1}) = \int_{\mathcal{X}^{K-1}} \pi^*(x_0, \dots, x_K) dx_0 \cdots dx_{k-1} dx_{k+2} \cdots dx_K = \pi_k^*(x_k, x_{k+1})$$



最紧致下界

$$\sum_{k=0}^{K-1} \iint c_k d\pi_{k,k+1}^* = \sum_{k=0}^{K-1} \iint c_k d\pi_k^* = LB$$

$\pi^*$  是 MMOT 问题的最优解，且 MMOT 被分解为  $K$  个独立的两边缘 OT 问题。

DataLoader 输出:

x: (B, 8, 2) 完整的样本骨架  $z$   
targets: (B, 8) 条件标签  
timepoints: (8,) 时间点数组

FM.sample\_location\_and\_conditional\_flow(x, timepoints)

Step A: 随机采样时刻

$t = \text{torch.rand}(B)$   $\rightarrow t: (B,)$   
如  $t[0]=0.423$  表示骨架  $\theta$  在  $t=0.423$  处采样

Step B: 噪声

$\text{eps} = \text{randn\_like}(x)[:, \theta].\text{unsqueeze}(1) \rightarrow \text{eps}: (B, 1, 2)$

Step C: 三次样条插值

对每个  $b \in [0, B)$ :

$\text{spline} = \text{CubicSpline}(\text{x}=(0, 0.1, 0.15, \dots, 1.0), \leftarrow 8\text{个时间点}$   
 $\text{y}=(x[b,0,:], x[b,1,:], \dots) \leftarrow 8\text{个2D坐标}$   
 $)$

$\mu_t = \text{self.P}(t, \text{derivative}=0) \rightarrow (B, 1, 2)$  Eq.9

$\mu'_t = \text{self.P}(t, \text{derivative}=1) \rightarrow (B, 1, 2)$  Eq.9导

Step D: 时变方差

$\sigma_t = \text{compute\_sigma\_t}(t, \text{deriv}=0) \rightarrow (B,) \rightarrow (B,1,1)$

$\sigma'_t = \text{compute\_sigma\_t}(t, \text{deriv}=1) \rightarrow (B,) \rightarrow (B,1,1)$

Step E: 采样  $x_t$  - Eq.4

$x_t = \mu_t + \sigma_t * \text{eps} \rightarrow (B, 1, 2)$

Step F: 条件向量场 - Eq.6

$u_t = (\sigma'_t / \sigma_t) * (x_t - \mu_t) + \mu'_t \rightarrow (B, 1, 2)$

MMOT = K 个OT 过程按照顺序依次配对

CFG 条件掩码 + 拼接

$\text{conditions} = \text{where}(\text{rand}(B) > 0.2, \text{targets}[:,0], 0)$   
 $\text{conditions.shape}: (B, 1)$  如  $[3, 0, 5, 3, \dots]$   
 $\uparrow$  条件  $c=\emptyset$  (空)

$\text{model\_input} = \text{cat}([$   
 $\text{x\_t.squeeze}(), \quad (B, 2) \quad \leftarrow \text{状态 } x_t$   
 $\text{conditions}, \quad (B, 1) \quad \leftarrow \text{条件 } c \text{ 或 } \emptyset$   
 $\text{t[:, None]}, \quad (B, 1) \quad \leftarrow \text{时间 } t$   
 $], \text{dim}=1)$   
 $\text{model\_input.shape}: (B, 4)$

$\text{loss} = \text{mean}((v_t - u_t)^2)$

$v_t: (B, 1, 2)$  神经网络预测的向量场  
 $u_t: (B, 1, 2)$  条件向量场 (来自样条+Eq.6)

这对应:  $L_{\text{MMFM}} = E[||v_t(x_t, c) - u_t(x_t|z)||^2]$  Eq.7


# 实验结果1：合成数据集


Table 1: Sampling times and conditions for the synthetic experiments.

| $c \backslash t$ | 0 | 0.1 | 0.15 | 0.3 | 0.5 | 0.7 | 0.9 | 1.0 |
|------------------|---|-----|------|-----|-----|-----|-----|-----|
| $c_3$            | ✓ | ✓   | ✓    | -   | ✓   | -   | ✓   | ✓   |
| $c_5$            | ✓ | -   | ✓    | ✓   | ✓   | ✓   | -   | ✓   |
| Rest             | ✓ | ✓   | ✓    | ✓   | ✓   | ✓   | ✓   | ✓   |


Note: ✓ indicates that samples from that combination are available in the training set.

|               | $c_m = 3$                         |                                   | $c_m = 5$                         |                                   |
|---------------|-----------------------------------|-----------------------------------|-----------------------------------|-----------------------------------|
|               | MSE ↓                             | MMD ↓                             | MSE ↓                             | MMD ↓                             |
| FSI           | $0.72 \pm 0.60$                   | $0.42 \pm 0.37$                   | $0.72 \pm 0.93$                   | $0.33 \pm 0.45$                   |
| CFM           | $0.46 \pm 0.25$                   | $0.25 \pm 0.15$                   | $0.93 \pm 0.52$                   | $0.60 \pm 0.33$                   |
| PCFM          | $0.75 \pm 0.49$                   | $0.45 \pm 0.35$                   | $0.78 \pm 0.73$                   | $0.43 \pm 0.44$                   |
| L-MMFM (ours) | $0.39 \pm 0.25$                   | $0.20 \pm 0.17$                   | $0.36 \pm 0.27$                   | $0.17 \pm 0.19$                   |
| MMFM (ours)   | <b><math>0.13 \pm 0.08</math></b> | <b><math>0.04 \pm 0.02</math></b> | <b><math>0.22 \pm 0.15</math></b> | <b><math>0.12 \pm 0.08</math></b> |







MMFM




L-MMFM




FSI



PCFM



(1) 在没见过的起始点的内插/外推测试



(2) 当前条件未见过的时间  
C5仅观测到0.5的位置

Figure 9: Overview of extrapolation to time points. (A) Visualization of training samples, (B) predicted trajectories for FSI, and (C) predicted trajectories for MMFM. Trajectories are shown for  $c_1$ ,  $c_5$ ,  $c_{10}$ . Here  $c_5$  is only measured until  $t = 0.5$ .

# 实验结果2: single-cell 数据集

使用 CITE-seq 技术同时测量:

- 转录组 (mRNA) : 18,250 个基因的表达量


T 细胞 (T cells) 经过激活 (activation) 处理

- 用 93 种激酶抑制剂 (kinase inhibitors) 处理
- 每种抑制剂在 3 个浓度下测试: 100 nM, 1  $\mu$ M, 10  $\mu$ M
- 同时包含阴性对照: vehicle (溶剂对照) 和 non-activation (不激活)
- 在 4 个时间点测量: 0h, 24h, 48h, 72h
- 每个 (药物, 浓度, 时间点) 条件下有数百个细胞

数据处理:

- PCA降维到25个主成分
- 保留123中不同的测试条件->随机选择了60种治疗方法进行分析
- 三个时间点均留出部分数据用于测试

同类药物有相似的动态



UMAP 散点图: 低维中尽量保持高维中的邻居关系

|               | $t = 24h$            |                      | $t = 48h$            |                      | $t = 72h$            |                      |
|---------------|----------------------|----------------------|----------------------|----------------------|----------------------|----------------------|
|               | MSE ↓                | $W_2$ ↓              | MSE ↓                | $W_2$ ↓              | MSE ↓                | $W_2$ ↓              |
| FSI           | 07.77 ± 01.49        | 56.13 ± 13.44        | 04.52 ± 01.14        | 38.93 ± 08.56        | 06.62 ± 01.65        | 78.46 ± 23.48        |
| CFM           | 09.10 ± 01.59        | 60.86 ± 14.67        | 04.92 ± 01.88        | 33.28 ± 13.53        | -                    | -                    |
| PCFM          | 08.88 ± 01.58        | 56.68 ± 12.12        | 04.13 ± 01.21        | 34.85 ± 08.01        | 06.07 ± 01.32        | 61.83 ± 16.74        |
| L-MMFM (ours) | 08.05 ± 01.29        | <b>50.82</b> ± 10.79 | 03.56 ± 01.50        | 26.07 ± 08.62        | 06.30 ± 01.92        | 47.97 ± 19.69        |
| MMFM (ours)   | <b>07.54</b> ± 00.99 | 51.86 ± 07.84        | <b>03.38</b> ± 01.34 | <b>26.01</b> ± 07.72 | <b>04.92</b> ± 01.61 | <b>37.71</b> ± 12.24 |

# 实验结果3： 空气质量 数据集

北京有 12 个空气质量监测站，分别位于城区、郊区、背景站等不同位置，每小时记录一次 PM2.5、PM10、NO2 等污染物浓度。

MMFM 在这类数据上的测试：

- 给定 9 个密集观测站的全时段（26 个月）数据和 3 个稀疏观测站的部分时段数据
- 能否利用密集站的季节变化模式，推断稀疏站在缺失月份的污染物浓度？

数据处理：

数据是 1 维的。每个 (station, month) 组合只有一个月均值（PM2.5 浓度或 NO2 浓度）  
但 Flow Matching 需要学习**概率分布之间的传输**

因此：每个 (station, month) 的月均值  $\bar{x}$ ，生成  $k = 100$  个样本：

$$x_i \sim \mathcal{N}\left(\bar{x}, 0.1^2\right), i = 1, 2, \dots, 100$$

|                      | $c = 4$                           | $c = 7$                           | $c = 10$                          | Rest                              |
|----------------------|-----------------------------------|-----------------------------------|-----------------------------------|-----------------------------------|
| FSI                  | $1.70 \pm 0.40$                   | $1.89 \pm 0.16$                   | $1.92 \pm 0.10$                   | $1.47 \pm 0.54$                   |
| CFM                  | $1.86 \pm 0.19$                   | $1.78 \pm 0.35$                   | $1.85 \pm 0.21$                   | $1.83 \pm 0.30$                   |
| PCFM                 | $1.61 \pm 0.45$                   | $1.42 \pm 0.36$                   | $1.86 \pm 0.15$                   | $1.50 \pm 0.50$                   |
| <b>L-MMFM (ours)</b> | <b><math>1.33 \pm 0.61</math></b> | <b><math>1.34 \pm 0.55</math></b> | <b><math>1.24 \pm 0.68</math></b> | <b><math>1.33 \pm 0.59</math></b> |
| MMFM (ours)          | $1.52 \pm 0.45$                   | $1.50 \pm 0.49$                   | $1.32 \pm 0.50$                   | $1.52 \pm 0.51$                   |

