


JEPA

自监督学习

生成式模型 (LLM/MAE)

自回归生成
掩码生成
扩散生成


- 依赖逐像素/Token预测，计算成本极高
- 输出本质是可能性的平均值，易造成视频等生成内容模糊失真（幻觉）
- 模型缺乏对物理世界的底层理解与常识推理能力
- 误差积累



自监督学习

对比学习 (SimCLR/CLIP)

- 依赖手工数据增强
- 需要大量负样本防止表征坍塌
- 只学相似性，不学预测性
- 难以捕捉细粒度语义差异




现有AI范式的缺陷

缺乏对物理世界的真正理解
样本效率极低

没有真正的推理和规划能力
无法避免幻觉

人类是如何思考的？



自主智能六模块

JEPA (Joint-Embedding Predictive Architecture)


三大核心组件

上下文编码器：输入可见部分（如图像未掩码区域），输出上下文表征 z_{ctx}

目标编码器：输入目标部分（如掩码区域 / 未来帧），输出目标表征 z_{tgt}


预测器：接收上下文表征，预测目标部分的隐表征 $\hat{z}_{tgt}$

$$L = \left\| z_{tgt} - \hat{z}_{tgt} \right\|^2$$




损失在Embedding空间作
在抽象隐空间预测未来与缺失信息，学习可推理的世界模型

JEPA (Joint-Embedding Predictive Architecture)



I-JEPA: 证明潜空间预测在图像表征学习中优于像素级重建



空间连续的大掩码，迫使模型学习全局语义
上下文编码器和目标编码器使用ViT，预测器使用MLP

I-JEPA


线性探测准确率高，计算效率高，学习表征

Method	Arch.	Epochs	Top-1
<i>Methods without view data augmentations</i>			
data2vec [8]	ViT-L/16	1600	77.3
MAE [36]	ViT-B/16	1600	68.0
	ViT-L/16	1600	76.0
	ViT-H/14	1600	77.2
CAE [22]	ViT-B/16	1600	70.4
	ViT-L/16	1600	78.1
I-JEPA	ViT-B/16	600	72.9
	ViT-L/16	600	77.5
	ViT-H/14	300	79.3
	ViT-H/16 ₄₄₈	300	81.1

Methods using extra view data augmentations




SimCLR v2 [21]	RN152 (2×)	800	79.1
DINO [18]	ViT-B/8	300	80.1
iBOT [79]	ViT-L/16	250	81.0

Targets	Arch.	Epochs	Top-1
Target-Encoder Output	ViT-L/16	500	66.9
Pixels	ViT-L/16	800	40.7



V-JEPA: 视频自监督学习，时空连续

$16 \times 224 \times 224 \times 3$



上下文编码器
视频token删掉掩码 $\longrightarrow$ 拼接mask token $\longrightarrow$ 预测器 $\longrightarrow$ 输出掩码位置表征
 $\downarrow$
目标编码器L1

V-JEPA-视频任务


人体动作分类
依赖外观特征

运动推理

目标检测+动作分类

Method	Pretrain Data	Arch.	Image	Video	Text	K400	SSv2	AVA
<i>Methods pretrained on Images</i>								
I-JEPA	IN1K	ViT-H/16 ₄₄₈	✓			74.5	42.1	16.3
OpenCLIP	LAION	ViT-G/14	✓		✓	83.3	39.0	23.2
DINOv2	LVD-142M	ViT-g/14	✓			84.4	50.0	24.3
<i>Methods pretrained on Videos</i>								
InternVideo	UnlabeledHybrid	-		✓	✓	73.7	60.3	19.6
VATT	HowTo100M	-		✓	✓	75.1	58.7	22.9
OmniMAE	IN1K + SSv2	ViT-L/16	✓	✓		65.4	56.1	14.4
Hiera	K400	Hiera-H		✓		73.3	60.7	17.5
VideoMAE	K400	ViT-L/16		✓		77.9	61.2	21.6
VideoMAEv2	UnlabeledHybrid	ViT-g/14		✓		70.6	58.0	12.9
	K400	ViT-L/16		✓		78.7	61.7	25.0
V-JEPA	VideoMix2M	ViT-L/16		✓		79.1	67.0	25.6
		ViT-H/16		✓		81.7	69.1	25.8
		ViT-H/16 ₃₈₄		✓		82.1	71.2	25.0



V-JEPA2: JEPA应用到实际



LeJEPA: 理论最优表征

表征坍塌：对不同的输入输出相同的表征

预训练模型的输出应该满足什么分布？——各向同性高斯分布




各向同性高斯分布确保信息在不同维度上公平编码，从而在下游任务上提供偏差和方差最低的预测



引入负样本“防止坍塌” ——> 令输出的表服从各向同性高斯分布

LeJEPA: SiGReg正则化（强制输出服从高斯分布）

$$L = \lambda \left\| z_{tgt} - \widehat{z}_{tgt} \right\|^2 \longrightarrow L = \lambda JEPA \text{ loss} + (1 - \lambda) SiGReg \text{ loss}$$



f_{θ}
 $\rightarrow$



把嵌入投影到一维
强制拟合高斯分布

LeJEPA

LeJEPA在领域内的小数据集上训练的小模型性能显著优于通用模型

Freeze Backbone	Model Name	Samples per Class						
		All	1	2	5	10	100	1000
No	<i>LeJEPA (Ours)</i>							
	ConvNeXt-V2 Nano	82.72	29.42	36.65	50.94	59.85	75.34	81.97
	LeViT-128	79.41	18.45	24.08	33.11	41.76	64.59	77.59
	ResNet-18	82.15	23.34	31.56	43.82	54.64	73.53	81.41
	ResNet-34	83.28	24.27	31.51	44.23	53.95	74.93	82.32
	<i>Baselines</i>							
	DINOv2 Small	78.34	21.05	21.71	30.33	36.23	60.81	75.55
	DINOv3 ViT-S/16	81.60	24.71	29.43	37.71	44.71	69.87	80.54
Yes	<i>LeJEPA (Ours)</i>							
	ConvNeXt-V2 Nano	76.52	28.74	36.65	50.60	59.50	72.62	77.24
	LeViT-128	69.00	25.85	33.30	45.52	52.43	64.37	69.39
	ResNet-18	75.95	30.48	38.22	50.85	58.86	72.70	76.39
	ResNet-34	78.17	31.08	38.33	52.26	60.63	74.77	78.62
	<i>Baselines</i>							
	DINOv2 Small	67.62	27.68	32.22	40.72	47.72	62.49	67.89
	DINOv3 ViT-S/16	71.38	30.17	36.65	45.74	51.51	65.90	71.35

无启发式规则：EMA、位置嵌入等等

极简高效：单超参

理论完备：各向同性高斯分布

JEPA的问题

- 隐空间表征的不可解释性：不可控制地过滤细节

- 长时预测误差累积

- 生成能力残缺：缺少decoder

- 工业应用暂无：scaling不明显

——更适合具身智能，决策不需要像素级细节，只需要语义

pixel space

- 可解释性较强

- 长时预测模糊

- 生成能力强

- 工业较成熟

——适合内容创作

JEPA

- 直觉上更接近人类思考方式
- 计算效率优势明显，理论能处理更大场景
- 适合具身智能，语义理解强

pixel space的问题

- 预测像素，长程模糊
- 计算效率较低
- 语义理解能力弱

最终的世界模型：两种模式的结合（预训练的JEPA和JiT decoder）