2026-10-15 组会

完整链接：转写: 转写_方榭楷Shikai Fang预定的会议
日期: 2026-10-15 18:51:11
转写文件：https://meeting.tencent.com/ctm/ldBM55kP06



课程名称：Transformer在PDE求解与物理建模中的应用

发言人：方榭楷Shikai Fang、张凯译、陈烨、张欣宇

课程简介：本课程深入探讨了利用Transformer架构进行偏微分方程求解及物理属性建模的系列工作，重点分析了其在处理不规则网格、降低计算复杂度及实现跨几何泛化方面的创新。

一、核心知识精讲

本次会议详细讲解了如何利用Transformer架构解决偏微分方程（PDE）求解及物理属性建模中的挑战，主要涵盖以下核心内容：

1. Transformer在PDE求解中的基础应用

- 传统求解的局限与神经网络优势：传统数值求解器（如有限元法）进行多步迭代计算复杂且昂贵，而神经网络可以端到端地给定输入

（如离散坐标、几何属性、流速方向等）直接回归真实物理场的稳定状态。

- Transformer的适用性：Transformer不需要规则网格，可直接将网格点拉成节点序列输入，通过自注意力机制建模全局耦合的物理场（如车头压力影响车尾旋流），且能近似为空间中的蒙特卡罗积分。
- 计算复杂度挑战：原始Transformer的复杂度为O(N^2)，当网格点N达到百万级时，计算量巨大，且难以捕捉高维空间中的token相关性，导致注意力矩阵过于平均。

2. 物理感知注意力机制

- 动态切片与反切片：为了解决高复杂度问题，提出了物理感知注意力（Physical Attention）。该方法将大量网格点降维到物理切片（Slice）中，在低模态空间进行注意力计算后再映射回原始空间。
- 切片过程详解：每个空间点xi通过网络计算其对M个切片的贡献度权重（1xM），经过softmax归一化后得到NxM的权重矩阵W。该矩阵与原始空间点相乘，将物理状态相近的点归类到同一切片中。
- 效果与优势：该方法将计算复杂度从O(N^2)降低到O(M^2)，且在可视化中能清晰看到车身不同部位（如车盖、车尾）被正确分类到不同切片，证明了其物理状态切片的有效性。

3. Transformer的演进与优化

- 自适应温度建模：针对大网格下切片权重分布过于平滑的问题，引入了自适应温度系数。该系数通过线性层学习，用于调整softmax计算的陡峭程度，使注意力权重分布更加尖锐，增加不同切片间的区分度。
- 多GPU并行计算：为了降低显存占用，将可加性的分子和分母计算拆分到不同GPU上并行进行，中间只传输加权后的结果，大幅减少了GPU间的通信量。
- 结合律优化与单GPU推理：通过矩阵结合律将部分线性层计算顺序调整，减少了涉及N的矩阵运算步骤，从而降低了显存峰值。同时支持通过逐步累加中间结果的方式在单GPU上处理上亿规模的网格点。

4. GPT：几何物理Transformer

- 预训练动机：工业级仿真数据获取成本极高（单个样本需数万CPU小时），且缺乏动态物理场数据。GPT旨在利用廉价的几何数据，通过预训练学习通用的物理动力学表示，从而在下游任务中用少量数据实现微调。
- 粒子群轨迹合成：核心创新在于人为引入动态信息。在几何表面周围随机采样粒子，并赋予不同方向和速度的运动轨迹，直到触碰表面停止。通过计算有符号距离场或矢量距离场，合成大量的粒子轨迹数据用于预训练。
- 微调与泛化效果：预训练后的模型在仅有100个样本的下游任务（如车辆空气动力学）上进行微调，仅需60%的样本即可达到全量数据训练的效果，且在不同速度方向和幅度下均表现出良好的泛化能力。

5. 自回归与频谱算子结合

- 长程稳定性问题：直接在几何上进行自回归预测（Teacher Forcing）在短期内准确，但长期预测会发散。而带有频谱归一化（如FNO算子）的方法在长程预测中更稳定，但可能丢失短期细节。
- 混合架构思路：最新工作尝试将两者结合，通过并行计算并结合两者的输出，利用矩阵融合后再进行基础注意力计算，旨在同时保持短期准确性和长期稳定性。

二、重难点突破

本节课的重难点在于理解如何通过神经网络架构的改进来解决物理仿真中的计算瓶颈和数据稀缺问题：

1. 从显式网格到隐式切片的转换逻辑

- 物理直觉的数学表达：理解“切片”并非简单的空间划分，而是基于物理状态相似性的隐空间聚类。关键在于理解权重矩阵W如何将高维空间点映射到低维物理模态，并保留关键的全局耦合信息。
- 反切片的信息重构：理解注意力计算完成后，如何利用之前的权重矩阵将低维切片信息无损或近似无损地映射回原始高维网格空间，确保输出的物理场精度。

2. 数据合成的创造性与有效性

- 从静态到动态的数据生成：理解GPT如何通过简单的粒子运动规则（直线运动至碰撞），在没有任何真实流体仿真数据的情况下，合成出具有物理意义的动态轨迹数据。
- 预训练目标的设定：明确预训练任务并非直接预测物理量，而是学习粒子在几何约束下的运动轨迹，这使得模型能够捕捉到几何与动力学之间的通用关联，从而在下游任务中快速适应。

三、AI延伸思考

以下内容为AI基于课程内容延伸生成，非课堂原话，仅供拓展思考：

1. Scaling Law在科学计算领域的应用

- 数据与模型规模的权衡：在科学计算中，真实数据往往极其昂贵，如何设计更高效的数据合成方法（如GPT的粒子轨迹）来逼近Scaling Law中的数据规模效应？
- 架构的通用性与领域特异性：Transformer架构因其通用性在NLP和CV领域大放异彩，在物理仿真中，如何平衡其通用表示能力与特定物理定律（如守恒律、对称性）的硬约束？

2. 基础模型的科研范式转变

- 从“小作坊”到“大工厂”：传统的科研往往专注于某个特定小问题的精巧解法，而现代AI科研更强调构建可扩展（Scalable）的基础模型。这对于资源有限的学术小组提出了怎样的挑战和机遇？
- 自监督与自进化：除了数据合成，能否通过智能体（Agent）在仿真环境中的自进化（Self-evolution）来不断生成新的训练数据，实现模型能力的自我迭代和扩展？