2026-10-22 组会

录制: 方榭楷Shikai Fang预定的会议
日期: 2026-10-22 19:02:33
录制文件 & 逐字稿：https://meeting.tencent.com/crm/Kzgy3onp48



一、智能体自进化基础概念

1. 智能体演进轨迹与架构

- 从一问一答到自主完成任务：大语言模型最初仅支持对话，随后通过集成工具与环境交互，形成了具备自主任务执行能力的智能体基础架构。

- 智能体系统核心构成：一个智能体系统由底层大语言模型（基座模型）以及除模型外的所有部分（统称为 Harness，包含上下文、工具与拓扑架构）共同组成。



"It is not the most intellectual of the species that survives; it is not the strongest that survives; but the species that survives is the one that is able best to adapt and adjust to the changing environment in which it finds itself." — Charles Darwin[1]

智能体近年发展轨迹演进图（来自会议截图）

2. 形式化定义的必要性

- 借鉴强化学习定义：综述中使用了复杂的数学符号来定义智能体与环境，这主要源于大模型出现前强化学习领域的标准定义习惯。
- 将工程问题转化为科学问题：虽然实际应用时无需复杂的数学推导，但形式化的数学工具能帮助研究者将自然语言描述的工程问题，转化为定义清晰的科学问题。

一，定义与基础

环境（Environment）

将智能体系统的环境定义为部分可观测马尔可夫决策过程(POMDP)，记为元组

$$E = (G, S, A, T, R, \Omega, O, \gamma)$$

其中：

G 是潜在目标的集合。

S 是状态集合。

A 是动作集合。

T 是状态转移概率函数。输入状态与动作对 (s, a)，输出下一状态的概率分布 T(s′ | s, a)。

R: S × A × G →ℝ 是以具体目标 g ∈ G 为条件的反馈 / 奖励函数。反馈 r = R(s, a, g) 通常表现为标量分数或文本反馈。

Ω 是智能体可获得的观测集合。

O 是观测概率函数。输入状态与动作对 (s, a)，输出智能体下一观测的概率分布 O(o′ | s, a)。

γ 是折扣因子。

智能体环境POMDP形式化定义（来自会议截图）

智能体系统：

将一个（多）智能体系统定义为$\Pi = (\Gamma, \{\psi i\}, \{Ci\}, \{Wi\})$。架构Γ决定系统的控制流或多个智能体之间的协作结构，通常表示为由图或代码结构组织的一系列节点$(N_1, N_2, \ldots)$。每个节点：

ψ_i：底层 LLM

C_i上下文信息

W_i可用工具 / API 集合。

给定任务 (E, g)，即环境 E 及相应目标 g ∈ G，系统生成轨迹$\tau = (o_0, a_0, o_1, a_1, \ldots)$，并接收外部环境或内部信号提供的反馈 r

自演化策略：

$$f(\Pi, \tau, r) = \Pi' = (\Gamma', \{\psi i'\}, \{Ci'\}, \{Wi'\})$$

自演化智能体的目标

$$\max_f \sum_{j=0}^{n} U(\Pi_j, \mathcal{T}_j)$$

多智能体系统自演化公式（来自会议截图）

二、智能体自进化核心机制

1. 进化对象

- 模型参数与经验对齐：针对开源模型，可通过任务轨迹进行后训练对齐；或通过与环境交互记录失败经验，将其存入记忆或提示词中以推动迭代。
- 上下文信息优化：包括通过长期记忆机制积累经验，以及采用自动提示词工程优化大模型输入。
- 工具与架构进化：工具进化涵盖自主发现创建、迭代改进及多工具管理；架构进化则分为单智能体节点优化与多智能体间的协作与数据互供。

context(C_i上下文信息)

1 记忆演化

基于 LLM 的智能体越来越多地采用长期记忆机制，随持续解决任务和环境交互而增长、调整。

记忆演化的关键在于从经验中学习启发式规则或技能。

2 提示优化

记忆演化关注保留哪些知识，提示优化（PO）则通过改进输入骨干模型的指令，让智能体在不修改权重的情况下直接改变模型行为。

智能体能自主改进提示策略，使提示文本成为随经验共同演化的可学习组件。

tool(W_i可用工具)

智能体的能力在根本上取决于其能够使用的工具。

1 自主发现与创建。

自主创建工具的首要动力是突破固定工具集的固有限制，获得按需创新的灵活性。

2 通过迭代改进掌握工具。

自创建工具越来越多，需要稳健的掌握机制：新生成的工具往往只是脆弱脚本，尚不是可靠函数。

3 可扩展的管理与选择。

当技能库达到数百或数千项，智能体面临“丰裕诅咒”：挑战从创建工具转向高效管理与选择。

上下文与工具进化分类说明（来自会议截图）

Architecture

1 单智能体系统优化

1.1 LLM 调用节点优化

主要有两种策略。第一种固定工作流结构，只优化节点。第二种同时优化节点和工作流架构。

1.2 自主智能体优化

优化 Agent 的整体架构

修改 Agent 自身代码

2 多智能体系统优化

2.1 智能体工作流优化

优化多个 Agent 之间的连接结构、任务分工和执行顺序

2.2 多自主智能体优化

不仅优化 Agent 之间的连接关系，还让多个 Agent 通过交互学习，共同优化各自的行为策略

单多智能体架构优化路径（来自会议截图）

2. 进化时机

- 单次测试内与测试间进化：单次测试内进化发生在任务执行期间，通过实时调整策略达成目标；测试间进化则发生在任务结束后，将成功轨迹总结为技能或记忆，以指导未来任务。
- 经验积累具有连续性：单次测试内积累的经验或日志，可以在任务完成后沉淀为技能或记忆，进而指导后续的测试间进化。

三、核心论文分享与解析

1. ReAct：反思驱动的短期记忆进化

- 从失败中学习：该早期工作让智能体在任务执行中调用工具，将失败轨迹存入短期记忆，通过语言模型总结后形成长期记忆，从而指导后续动作。
- 启发式经验总结效果更优：在2023年大模型能力尚弱的背景下，使用内部写好的启发式程序来总结长期记忆，其效果甚至优于直接调用大模型进行总结。

2. TextGrad：提示词自动优化与文本梯度

- 文本梯度指导提示词优化：针对提示词被越狱等失效场景，利用大模型生成文本形式的梯度，指导提示词向安全或正确的方向更新。
- Beam Search 保留次优解：在提示词更新过程中，采用启发式的 Beam Search 算法，不仅保留当前最优解，也保留具有潜力的次优解，以避免陷入局部最优。

3. TextGrad（Nature）：通用计算图与反向传播

- 构建通用计算图：该工作将提示词优化推广至任意变量节点（如记忆、技能、脚本），通过调用两次大模型构建计算图，并利用链式法则计算文本梯度。
- 顺应时代风口发表：该工作之所以能发 Nature，一方面得益于其通用框架，另一方面是因为在2024年底推理模型尚未普及前，通过复杂拆解来引导大模型深度思考是前沿需求。

4. 推理策略记忆与测试时扩展

- 提炼泛化推理策略：针对长期任务中过度依赖成功经验的局限，该最新工作从成功与失败轨迹中提炼出更抽象、可迁移的推理策略，而非简单的节点式工作流记忆。
- 测试时扩展生成高质量记忆：通过拉长测试时间（Test-Time Scaling），让智能体在并行或串行探索中产生更多轨迹，从而压缩出更高质量、更泛化的记忆库。

四、自进化策略与范式探讨

1. 自进化策略分类

- 基于奖励与示范学习：奖励分为文本、内部、外部及隐式奖励；示范学习则分为自生成、跨智能体及混合式，但面临数据质量与多样性不足的挑战。
- 基于种群的演化方法：借鉴达尔文进化论，通过选择、交叉、变异（如让智能体自我博弈）来寻找最优进化方向。

2. 当前研究同质化问题

- 套路化严重：当前大量自进化 Agent 研究均遵循“设计框架-加入记忆/强化学习-验证分数提升”的固定套路，缺乏实质性的范式更新。
- 易被基础模型能力覆盖：随着 DeepSeek R1 等推理模型的出现，模型本身具备了内部迭代和推理能力，过去在提示词层面进行的复杂雕花（如 TextGrad）正逐渐被基模能力内化并取代。

五、未来创新方向与讨论

1. 寻找真实复杂场景作为切入点

- 突破简单 Benchmark 局限：当前研究多集中在短推理链的简单任务上，导致同质化严重，真正的创新应来源于金融、物理、硬件控制等真实且复杂的工程问题。
- 应对多目标与多模态反馈：真实任务往往包含成本、安全性等多目标约束，且反馈可能是光谱或图片等多模态形式，而非简单的成功或失败。

2. 结合具体场景细化创新思路

- 失败经验的精细化归因：在引入经验筛选器时，不能简单判断成败，需结合具体场景对失败原因进行分组（如区分是 Prompt 错误还是环境故障），以提取有价值的经验。
- 引入代理模型评估技能价值：针对技能验证成本高的问题，可借鉴贝叶斯优化中的 UCB 算法，建立快速打分系统，在付出高昂验证成本前预估技能价值。

六、待办事项

- 下周进行线上分享，主题为利用 Agent 调用小模型执行特定任务的方法论。 @张凯译