Agent+小模型

2026.10.29

张凯译

Structured Agentic Workflows for Financial Time-Series Modeling with LLMs and Reflective Feedback

Yihao Ang*
National University of Singapore
yihao_ang@comp.nus.edu.sg

Yifan Bao*
National University of Singapore
yifan_bao@comp.nus.edu.sg

Lei Jiang*
University College London
lei.j@ucl.ac.uk

Jiajie Tao
University College London
jiajie.tao.21@ucl.ac.uk

Anthony K. H. Tung†
National University of Singapore
atung@comp.nus.edu.sg

Lukasz Szpruch†
University of Edinburgh
l.szpruch@ed.ac.uk

Hao Ni†
University College London
h.ni@ucl.ac.uk

TS-Agent
https://arxiv.org/html/2508.13915v1

时间序列预测

当前时刻t：发起预测的时间点
回看窗口L：回看多少个历史时间步的数据
预测跨度H：预测接下来的多少个时间步

如气候干旱指数预测
输入：
t之前的L个时间步的干旱指数
[38.2, 42.1, 44.5, 46.0, 47.2, 48.5, 49.8, 52.0]
输出：t之后的H个时间步的预测值
[52.5, 53.1, 54.0, 54.8, 55.5, 56.2, 57.0, 57.8, 58.5, 59.3]

时间序列生成

输入：从先验分布（如标准正态分布）中采样的一段随机噪声向量
输出： 一段合成时序数据

TS-Agent

金融任务Agent
时间序列的预测和生成任务
调用模型写代码并进行机器学习训练
小模型在代码库中，LLM对代码进行检索、完善、运行

一个简单的例子，快速了解agent+小模型

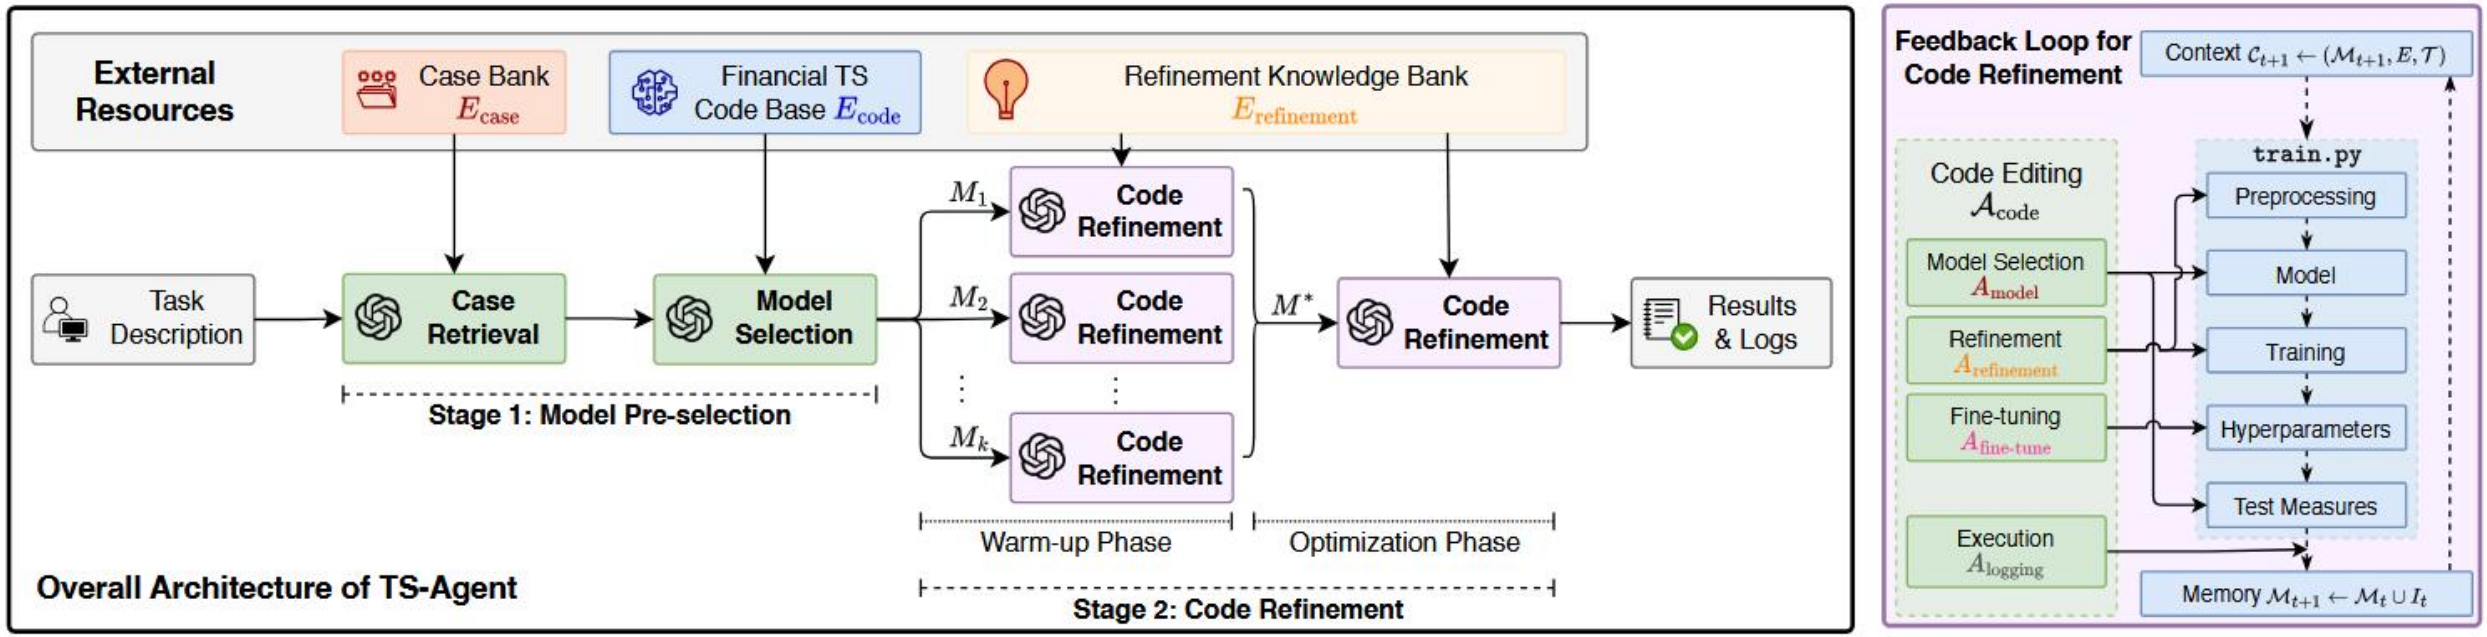
外部资源

case bank包括历史金融建模任务和成功方法论

E_code包括模型代码库和评估指标库

E_refinement包括预处理、训练优化、超参数调优的专家启发式规则

上下文包括外部资源、任务描述和动态记忆（过去的实验训练日志、结果、代码、配置等）



(a) Overall architecture of TS-Agent.

(b) Feedback loop for code refinement.

model pre-selection

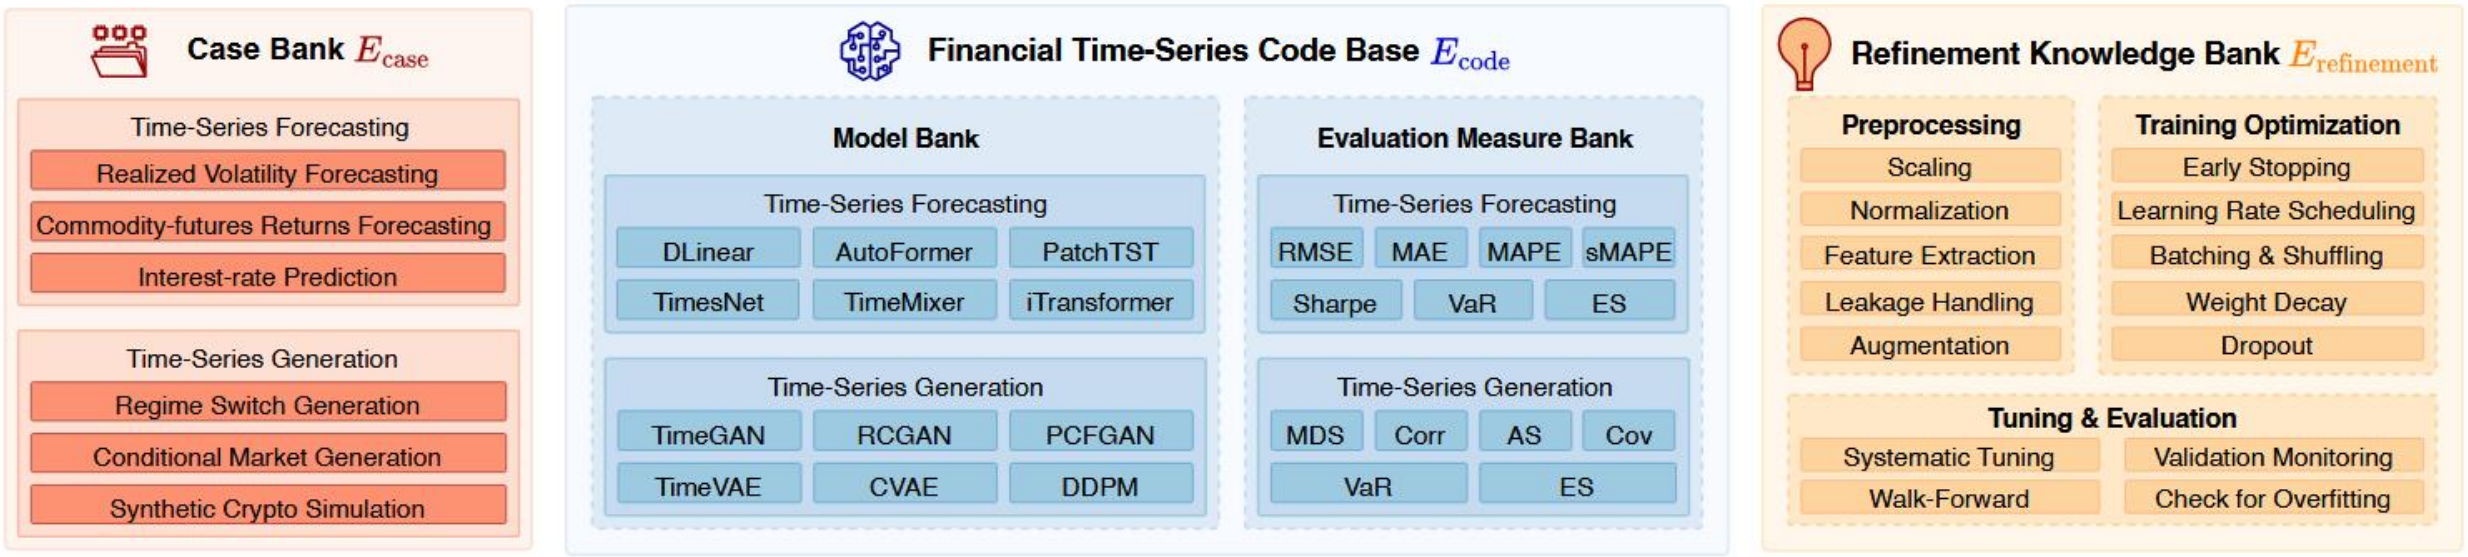
根据任务描述，检索相似的历史案例，并从E_code中检索top-k匹配的模型和度量标准

code refinement

对k个模型并行进行少量迭代的代码完善，根据测试结果，选出最好的模型->进行大量迭代的代码完善（利用启发式规则等）

每次迭代：根据E_refinement和过往日志修改训练相关代码->根据历史评估指标修改超参数配置文件->执行并得到结果和日志，加入记忆

外部资源的具体内容


Case Bank E_{case}
Time-Series Forecasting
Realized Volatility Forecasting
Commodity-futures Returns Forecasting
Interest-rate Prediction
Time-Series Generation
Regime Switch Generation
Conditional Market Generation
Synthetic Crypto Simulation
Financial Time-Series Code Base E_{code}
Model Bank
Time-Series Forecasting
DLinear
AutoFormer
PatchTST
TimesNet
TimeMixer
iTransformer
Time-Series Generation
TimeGAN
RCGAN
PCFGAN
TimeVAE
CVAE
DDPM
Evaluation Measure Bank
Time-Series Forecasting
RMSE
MAE
MAPE
sMAPE
Sharpe
VaR
ES
Time-Series Generation
MDS
Corr
AS
Cov
VaR
ES
Refinement Knowledge Bank $E_{refinement}$
Preprocessing
Scaling
Normalization
Feature Extraction
Leakage Handling
Augmentation
Training Optimization
Early Stopping
Learning Rate Scheduling
Batching & Shuffling
Weight Decay
Dropout
Tuning & Evaluation
Systematic Tuning
Validation Monitoring
Walk-Forward
Check for Overfitting

时序预测与生成任务上的性能

Dataset	Model	RMSE ↓				MAE ↓				MAPE (%) ↓				sMAPE (%) ↓				Success Rate (%) ↑			
		GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova
Crypto	TS-Agent	**0.277**	**0.206**	**0.254**	**0.249**	**0.0076**	**0.0051**	**0.0066**	**0.0063**	**1.692**	**1.531**	**1.643**	**1.655**	**1.693**	**1.529**	**1.644**	**1.658**	**100**	**100**	**100**	**100**
	DS-Agent	0.369	0.297	0.320	0.307	0.0082	0.0070	0.0074	0.0073	2.065	1.883	1.905	1.912	2.063	1.881	1.907	1.914	60	60	60	60
	ResearchAgent	0.392	0.341	0.355	3.477	0.0094	0.0083	0.0088	0.0085	2.344	2.040	2.210	2.198	2.347	2.040	2.230	2.200	40	60	60	60
	AutoGluon	0.223				0.0055				1.664				1.662				100			
Exchange	TS-Agent	**0.0073**	**0.0068**	**0.0069**	**0.0077**	**0.0041**	**0.0036**	**0.0040**	**0.0041**	**0.564**	**0.474**	**0.499**	**0.562**	**0.563**	**0.474**	**0.498**	**0.560**	**100**	**100**	**100**	**80**
	DS-Agent	0.0095	0.0088	0.0090	0.0096	0.0066	0.0057	0.0062	0.0068	0.801	0.782	0.792	0.811	0.800	0.781	0.792	0.810	80	**100**	60	60
	ResearchAgent	0.0099	0.0096	0.0095	0.0098	0.0066	0.0056	0.0054	0.0059	0.812	0.793	0.804	0.817	0.811	0.79	0.804	0.817	60	40	80	60
	AutoGluon	0.0089				0.0052				0.701				0.699				100			
Stock	TS-Agent	**8.727**	**8.017**	**7.982**	**8.590**	**5.117**	**4.912**	**4.905**	**5.047**	2.336	**2.046**	**2.076**	**2.123**	**2.001**	**1.770**	**1.765**	**1.850**	**80**	**100**	**100**	**100**
	DS-Agent	8.644	8.557	8.559	8.732	5.248	5.193	5.150	5.207	**2.308**	2.137	2.177	2.244	2.142	1.969	2.055	2.099	60	80	**100**	60
	ResearchAgent	9.890	9.410	9.570	9.791	6.041	5.677	5.738	5.910	2.878	2.498	2.420	2.590	2.414	2.053	2.238	2.331	60	80	80	80
	AutoGluon	8.430				5.258				2.174				1.890				100			

Dataset	Model	Marginal ↓				Correlation ↓				Autocorrelation ↓				Covariance ↓				Success Rate (%) ↑			
		GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova	GPT-3.5	GPT-4o	Claude	Nova
Exchange	TS-Agent	**0.360**	**0.356**	0.374	**0.366**	**4.249**	**2.796**	**2.803**	**1.874**	**0.00426**	0.00216	0.00226	**0.00120**	**0.00301**	**0.00179**	**0.00151**	**0.00120**	**100**	**100**	**100**	**100**
	DS-Agent	—	0.692	**0.329**	0.401	—	14.755	3.373	14.290	—	0.0605	0.00475	0.0347	—	0.00706	0.00287	0.00600	0	40	**100**	20
	ResearchAgent	—	0.737	0.530	—	—	9.591	6.369	—	—	**0.000884**	**0.00105**	—	—	0.00595	0.00403	—	0	80	**100**	0
	Optuna	0.377				2.114				0.00198				0.00172				100			
Stock	TS-Agent	**0.309**	**0.269**	**0.266**	**0.259**	**3.468**	**1.228**	**1.194**	**1.413**	**0.227**	**0.152**	**0.153**	0.161	$\mathbf{6.99 \times 10^{-5}}$	$\mathbf{4.43 \times 10^{-5}}$	$\mathbf{4.35 \times 10^{-5}}$	$\mathbf{4.50 \times 10^{-5}}$	**100**	**100**	**100**	**100**
	DS-Agent	—	0.299	0.331	0.277	—	6.930	5.282	11.991	—	0.231	0.286	**0.147**	—	5.58×10^{-5}	5.81×10^{-4}	5.63×10^{-5}	0	80	**100**	40
	ResearchAgent	—	0.575	0.397	0.904	—	7.175	7.343	12.879	—	0.490	0.329	1.244	—	5.75×10^{-5}	4.74×10^{-5}	5.84×10^{-5}	0	80	**100**	40
	Optuna	0.270				1.530				0.162				4.83×10^{-5}				100			

总结

概述：根据领域知识选择模型、完善代码、执行代码

针对领域，
1.提供领域知识、需求、代码库与规则等，复用金融团队内部的代码、知识库等
2.使用金融相关指标进行优化
3.满足可审计性和可解释型要求，代码修改全部留痕

待解决的问题
1.只能解决预测与生成问题，要想拓展，需要拓展模型、指标、规则等多个部分
2.只处理了纯数值的数据，并不能处理文本等其他多模态数据
3.比较依赖规则库和代码库，若错误或缺失，则可能有较大影响，没办法自由探索
4.模型选择之后，就不能再回退，存在性能完全达不到预期的风险

TIMEEVO: FAILURE-DRIVEN SELF-EVOLUTION OF A TIME SERIES AGENT

Jie Yang[1,2], Yan Zheng[2], Jiarui Sun[2], Xiran Fan[2], Junpeng Wang[2], Liang Wang[2], Zelin Xu[2,3], Qinghua Liu[2,4], Zhengyu Fang[2,5], Yiwei Cai[2], Philip S. Yu[1,†]

[1]University of Illinois at Chicago [2]Visa Research [3]University of Florida
[4]The Ohio State University [5]Case Western Reserve University

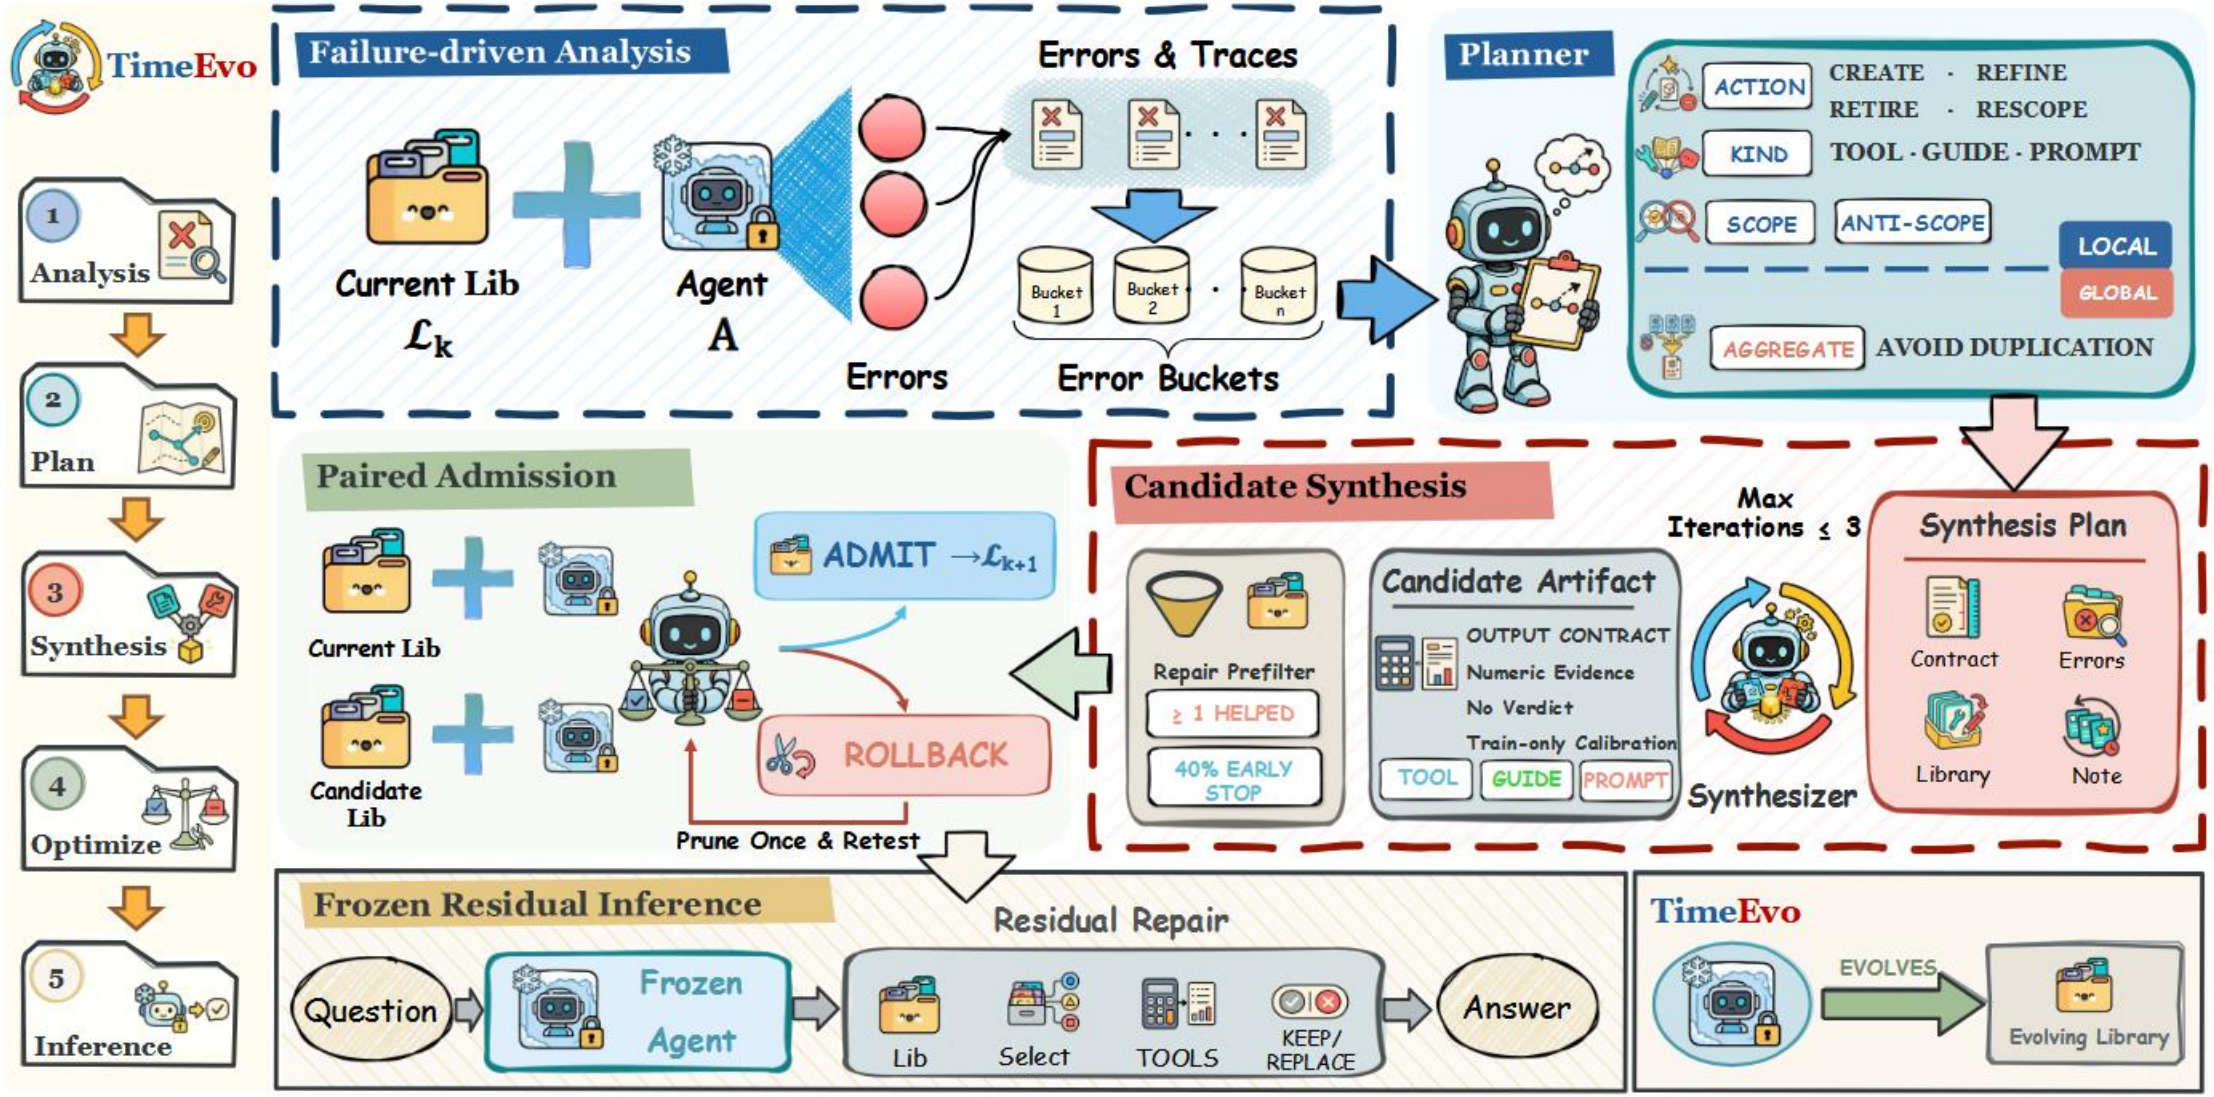
jyang265@uic.edu

TimeEvo
https://arxiv.org/abs/2609.27277

TimeEvo

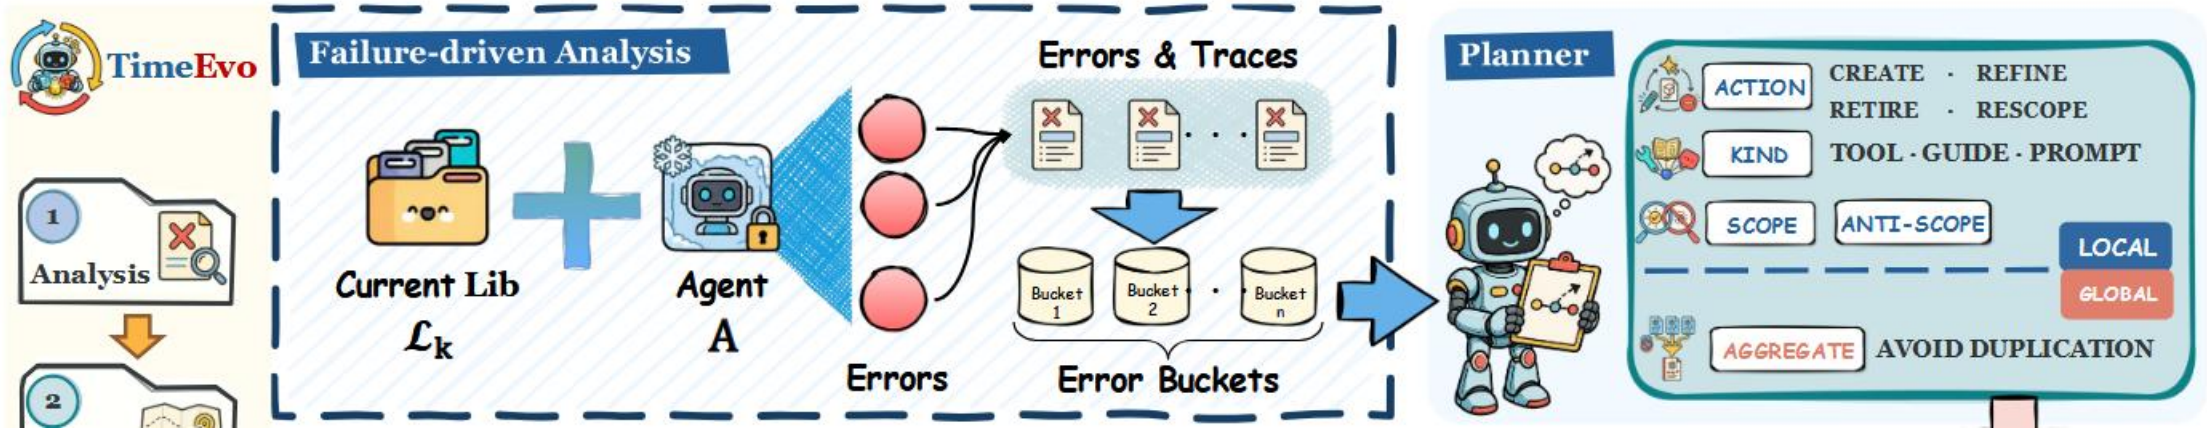
输入题目
自然语言问题+几个候选选项如ABCD+几个时间序列数组

管理工具
工具是python代码，文本指导（告诉模型怎么读已有工具的输出），提示词补丁，可以类比于管理小模型


TimeEvo
1 Analysis
2 Plan
3 Synthesis
4 Optimize
5 Inference
Failure-driven Analysis
Current Lib
$\mathcal{L}_k$
Agent
A
Errors
Errors & Traces
Bucket 1
Bucket 2
Bucket n
Error Buckets
Planner
ACTION
CREATE · REFINE
RETIRE · RESCOPE
KIND
TOOL · GUIDE · PROMPT
SCOPE
ANTI-SCOPE
LOCAL
GLOBAL
AGGREGATE
AVOID DUPLICATION
Paired Admission
Current Lib
Candidate Lib
ADMIT → $\mathcal{L}_{k+1}$
ROLLBACK
Prune Once & Retest
Candidate Synthesis
Repair Prefilter
≥ 1 HELPED
40% EARLY STOP
Candidate Artifact
OUTPUT CONTRACT
Numeric Evidence
No Verdict
Train-only Calibration
TOOL
GUIDE
PROMPT
Max Iterations ≤ 3
Synthesizer
Synthesis Plan
Contract
Errors
Library
Note
Frozen Residual Inference
Question
Frozen Agent
Residual Repair
Lib
Select
TOOLS
KEEP/ REPLACE
Answer
TimeEvo
EVOLVES
Evolving Library

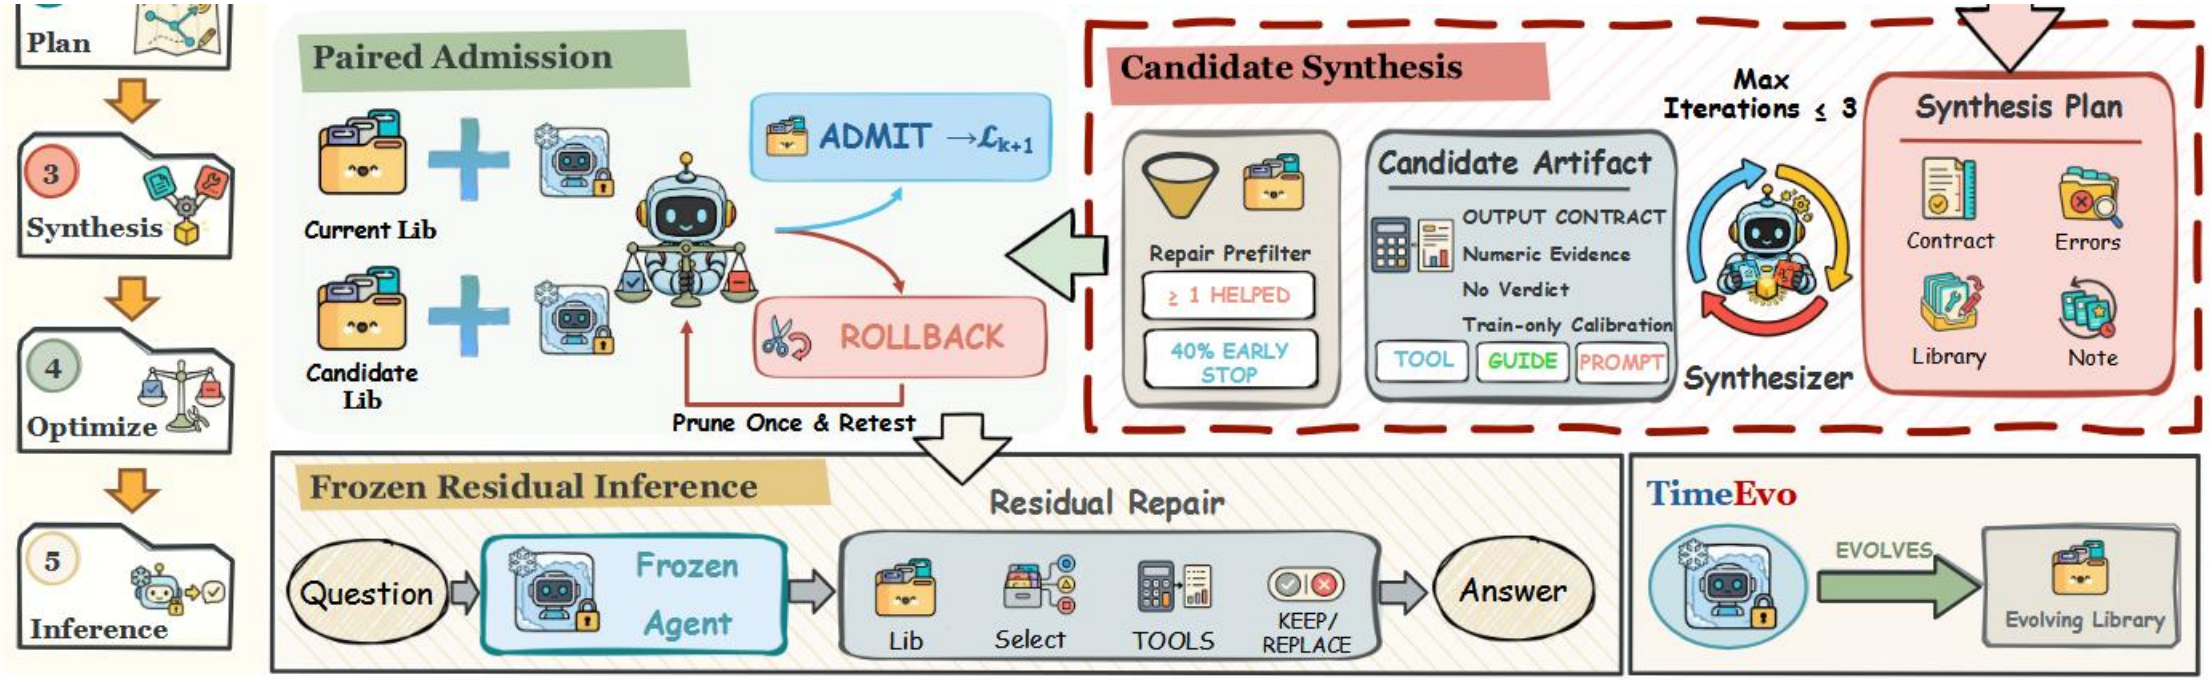
Failure-driven Analysis
每一轮，agent用现有工具库（第一轮是空的）做训练集题目，做对的去掉，收集错题和答题过程（运行日志，包括LLM推理、工具调用等）
错题先按是否调用工具分两类，每类再总结出8个错误类型，装入不同的桶

Planner
对于每一个错题桶，LLM给出契约，规定了执行的动作（CREATE 新建工具、REFINE 写使用说明、RESCOPE 修改工具适用范围、或 RETIRE 删掉废工具），输出类型（TOOL 代码工具、GUIDE 指南、PROMPT 提示词），使用范围和禁用范围（可用于什么类型的题目）
全局会将计算相同指标的契约合并



Paired Admission
现有工具库和candidate工具库，在验证集上测试，统计有多少1)原来错现在对和2)原来对现在错的
ADMIT1)明显多于2)，则新工具可以进入工具库
ROLLBACK去掉那些错太多的工具，然后再测一次，还不行则放弃本轮工具

Candidate Synthesis
根据契约和错题样本写python代码，每个契约最多3次迭代
规则：
1.python代码只返回数字，不会输出选项
2.如果需要决策边界，如确定返回的数字异常还是正常，则会再训练集上拟合一个二叉决策树
3.代码写好后在错题抽32道测试，做对1道可以保留，继续迭代；做对40%则可以提前通过迭代



Frozen Residual Inference
对于测试集的题目，先不看新工具给出初步答案，然后查找符合适用范围的工具并运行，根据工具给出的数字判断是否修改初始答案

总结

概述：LLM回答问题，过程中根据错题更新工具（代码），LLM参考工具输出的数字修正回答；工具的管理
可学习的点：
1.可参考，作为管理小模型的一个方法例子

问题：
1.工具都是针对错题生成的，可能缺乏泛化能力
2.错误的工具会误导模型的输出
3.有点像提示词优化，工具的输出只是作为额外提示词出现，主要还是看LLM的性能

WHEN TOMORROW BECOMES TODAY: SELF-EVOLVING POLICIES FOR AGENTIC TIME-SERIES FORECASTING

Yifan Hu[1,2,*], **Xilin Dai**[1,3,*], **Zhiyuan Qu**[2], **Yiding Liu**[1], **Zewei Dong**[1,†], **Jiang-ming Yang**[1], **Qiang Xu**[3,†]
[1]Ant International [2]Tsinghua University [3]The Chinese University of Hong Kong
{hyf476357}@ant-intl.com

TIMEVOLVE
https://arxiv.org/abs/2609.24862

时间序列预测Agent

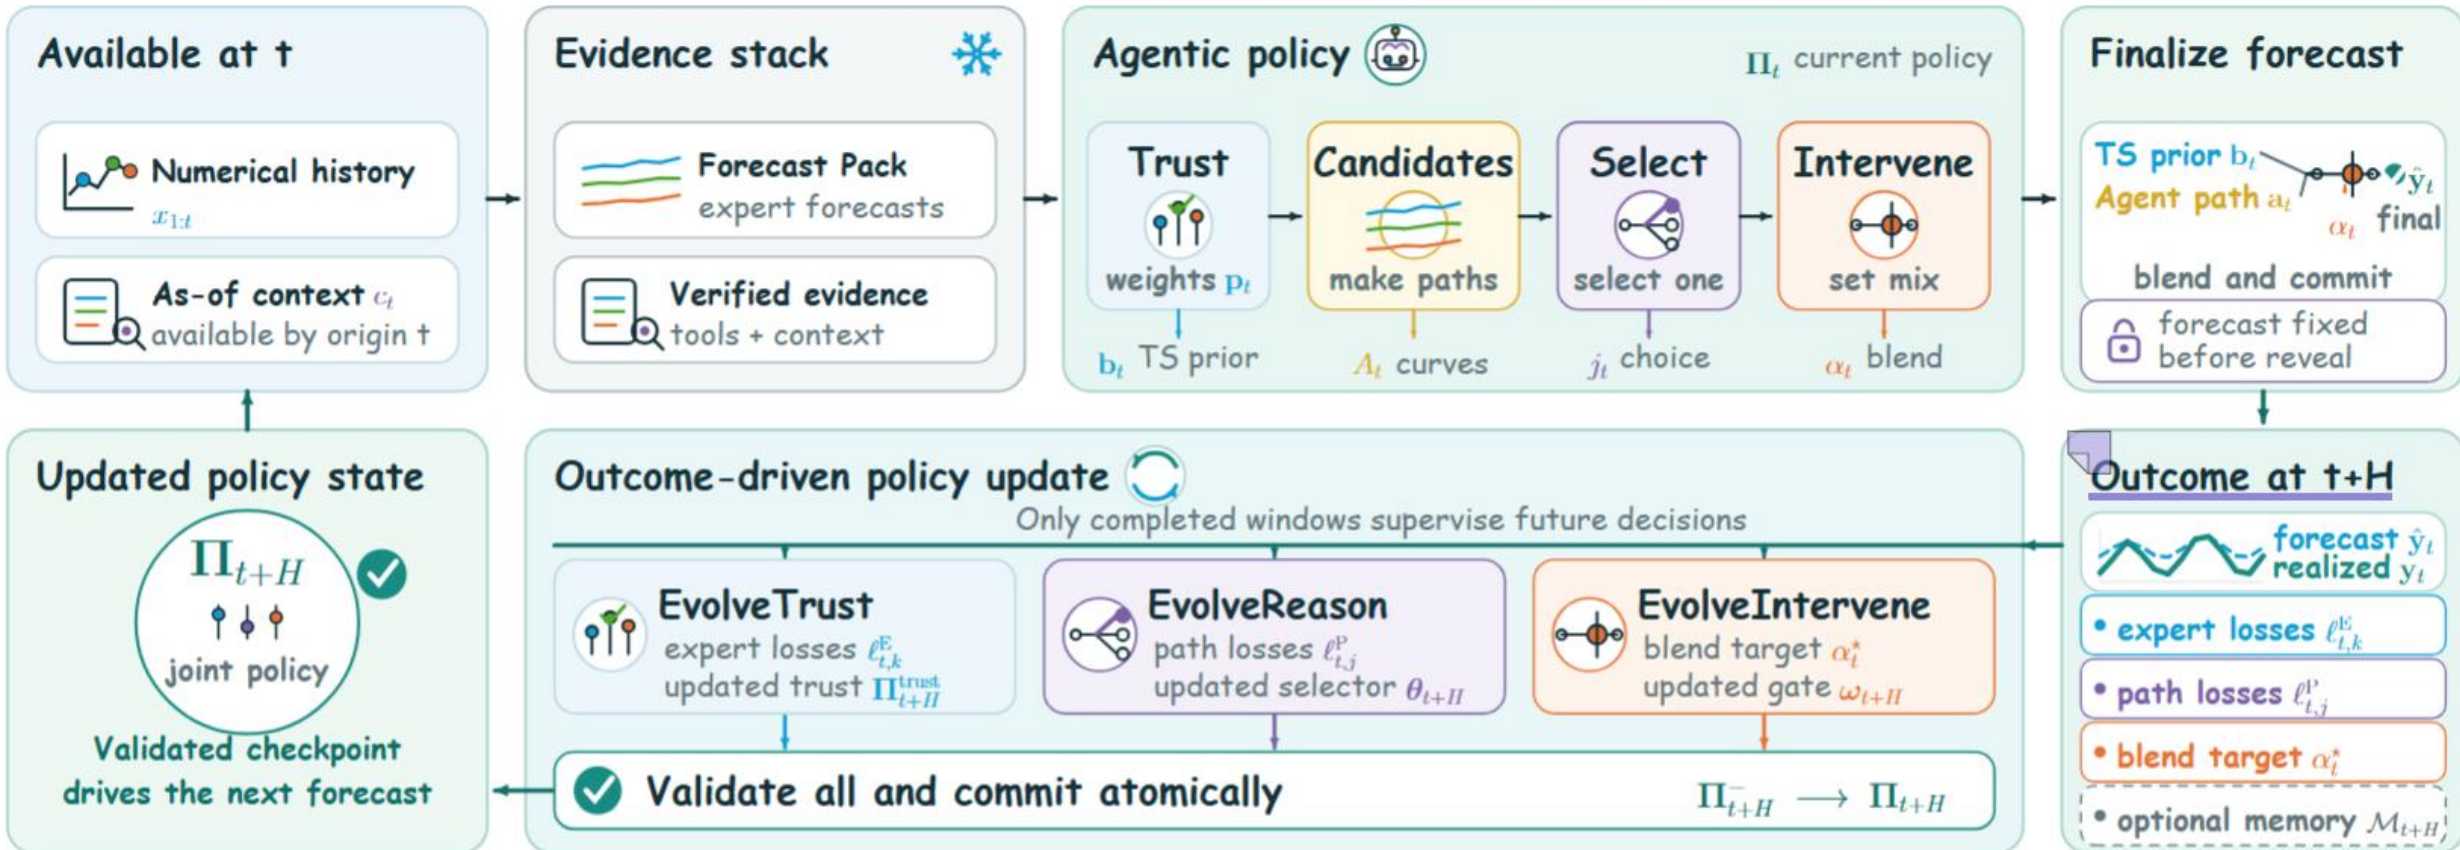
当前时刻t：发起预测的时间点
回看窗口L：回看多少个历史时间步的数据
预测跨度H：预测接下来的多少个时间步

如气候干旱指数预测
输入：
1) t之前的L个时间步的干旱指数
[38.2, 42.1, 44.5, 46.0, 47.2, 48.5, 49.8, 52.0]
2) 多模态上下文，如t之前的报告事实、报告预测、网页搜索事实、网页搜索预测

输出：t之后的H个时间步的预测值
[52.5, 53.1, 54.0, 54.8, 55.5, 56.2, 57.0, 57.8, 58.5, 59.3]

此论文的数据->进化

1.观测的真实结果Ground truth->系统性地改变策略
2.预测过程中的数据->训练小模型
3.被舍弃的备选方案->提供价值

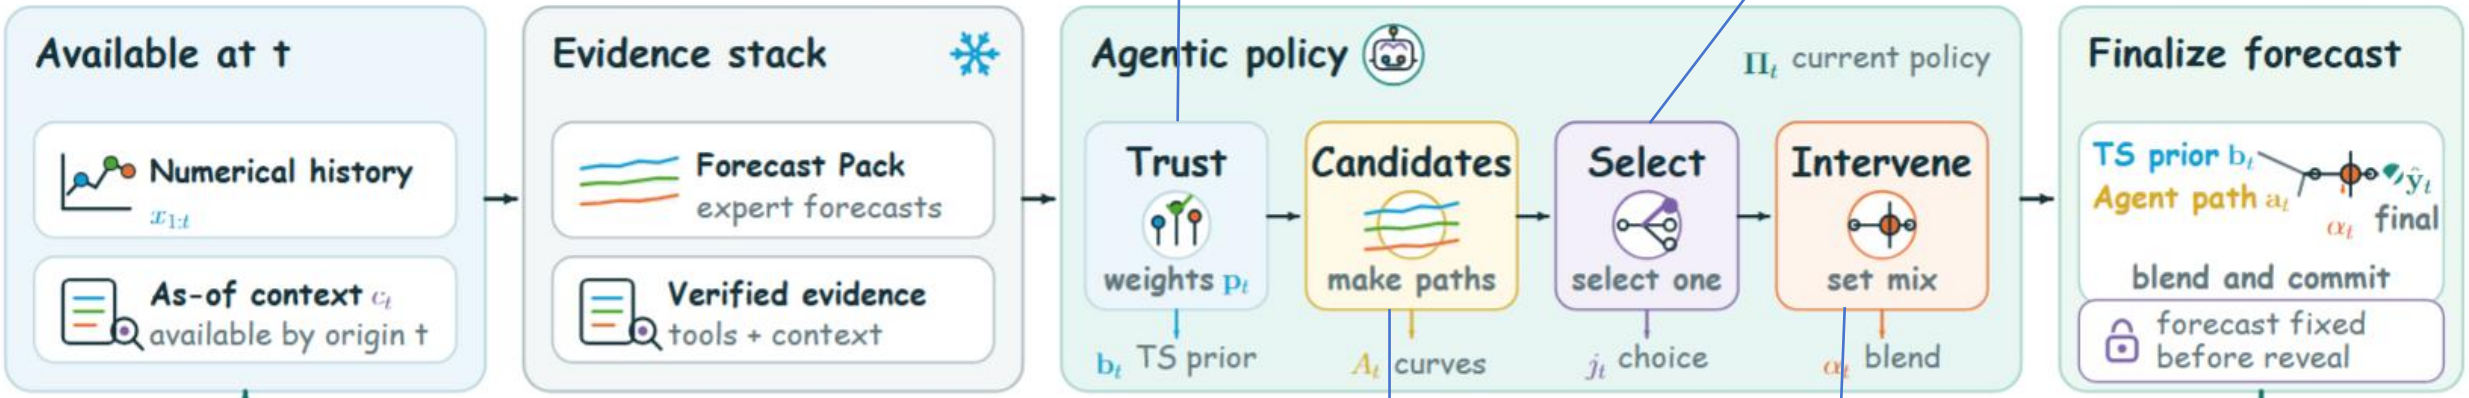

Available at t
Numerical history
$x_{1:t}$
As-of context c_t
available by origin t
Evidence stack
Forecast Pack
expert forecasts
Verified evidence
tools + context
Agentic policy
Π_t current policy
Trust
weights p_t
b_t TS prior
Candidates
make paths
A_t curves
Select
select one
j_t choice
Intervene
set mix
α_t blend
Finalize forecast
TS prior b_t
Agent path a_t
α_t
$\hat{y}_t$ final
blend and commit
forecast fixed
before reveal
Outcome at t+H
forecast $\hat{y}_t$
realized y_t
• expert losses $\ell^E_{t,k}$
• path losses $\ell^P_{t,j}$
• blend target $\alpha^\star_t$
• optional memory $\mathcal{M}_{t+H}$
Outcome-driven policy update
Only completed windows supervise future decisions
EvolveTrust
expert losses $\ell^E_{t,k}$
updated trust Π^{trust}_{t+H}
EvolveReason
path losses $\ell^P_{t,j}$
updated selector θ_{t+H}
EvolveIntervene
blend target $\alpha^\star_t$
updated gate ω_{t+H}
Validate all and commit atomically
$\Pi^-_{t+H} \longrightarrow \Pi_{t+H}$
Updated policy state
Π_{t+H}
joint policy
Validated checkpoint
drives the next forecast

输入历史序列和多模态上下文

包含多个时序基础大模型和传统模型，分别输出预测结果

每个专家计算出一个信任权重向量pt，所有专家预测结果进行加权平均得到bt

对At中每条曲线打分，选择误差最小的路径jt，曲线at



评估专家预测的**证据**：
1.结合历史序列和其他专家预测结果，计算预测结果的统计特征；
2.上下文中的内容

LLM阅读**证据**，输出许多候选路径j；
每条路径包括对证据的解读、挑选的专家子集；
所有路径根据pt加权计算预测结果At

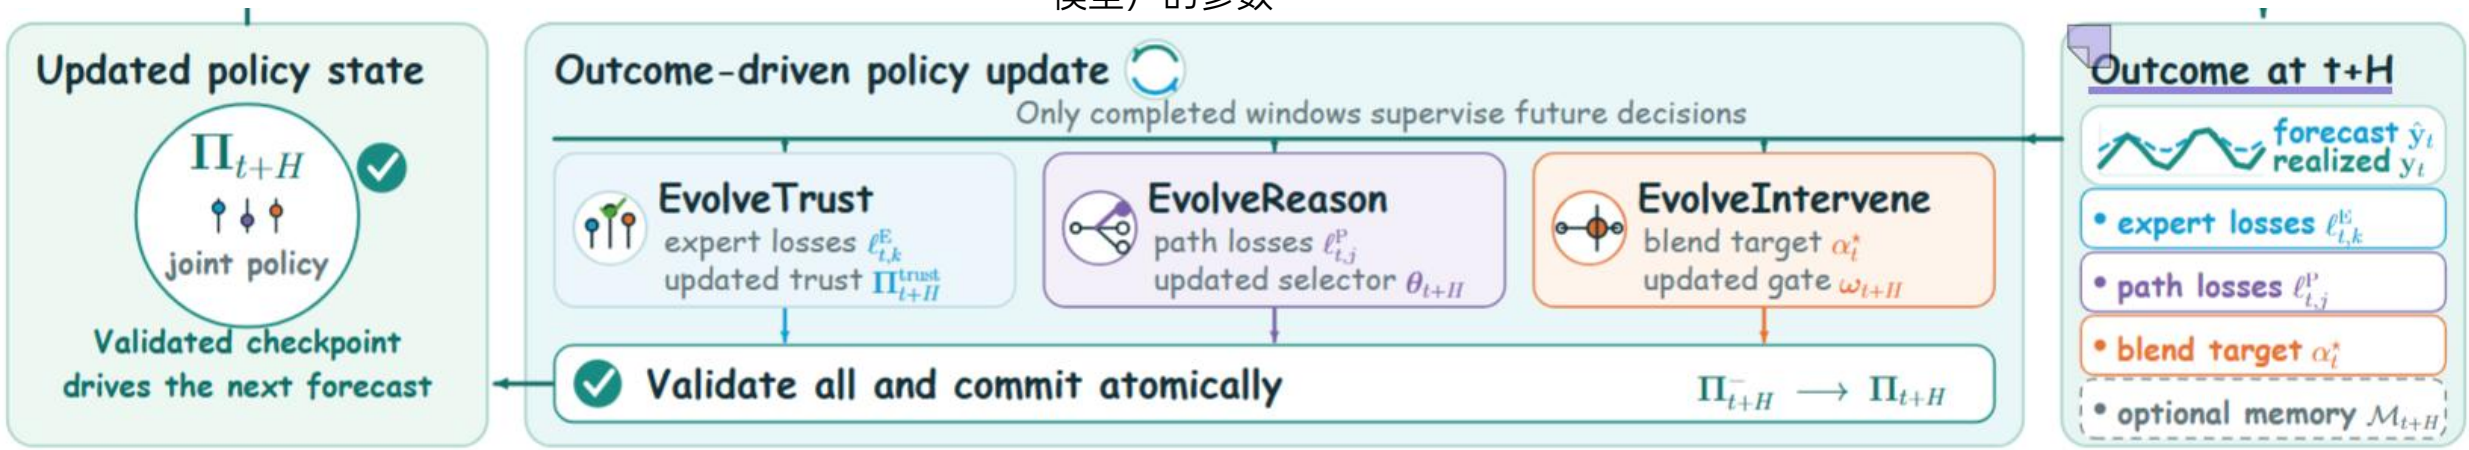
由于at与bt有偏差，所以设计了一个模块计算出混合比例alpha_t

结合at和bt得到预测结果yt^，并将(pt,bt,jt,at,alpha_t,yt^)存入记录Rt

1.根据专家损失更新专家的信任权重pt

2.根据路径损失更新路径选择时打分器（回归模型）的参数

3.更新混合比例计算模块的参数



1.观测的真实结果Ground truth->系统性地改变策略
2.预测过程中的数据->训练小模型
3.被舍弃的备选方案->提供价值

When tomorrow becomes today
1.每个专家的预测结果与yt的均方误差
2.每个路径的预测结果at与yt的均方误差
3.根据bt和at，最小化混合结果与yt的均方误差，求出最优的alpha_t*
4.前面的上下文，做出的决策，预测成功与否等可以总结到记忆中

性能对比

Model	Agriculture	Climate	Economy	Energy	Environment	Security	Social Good	Traffic	Avg. rank
Agentic systems									
TIMEVOLVE	**0.129/0.227**	**0.314/0.402**	**0.181/0.329**	**0.181/0.303**	**0.274/0.372**	**58.937/3.285**	0.808/0.381	**0.087/0.176**	**1.250/1.375**
KairosAgent	0.194/0.282	0.863/0.739	0.186/0.335	0.217/0.330	0.378/0.435	76.658/4.340	**0.769/0.376**	0.151/0.231	5.188/5.125
MemCast	0.218/0.313	0.897/0.752	0.196/0.339	0.207/0.318	0.289/0.390	69.481/3.876	0.797/0.378	0.132/0.200	4.375/5.250
CastFlow	0.220/0.303	0.890/0.748	0.193/0.338	0.204/0.316	0.286/0.388	68.900/3.860	0.810/0.383	0.130/0.198	4.000/4.125
Zero-shot foundation models									
Aurora	0.282/0.356	0.863/0.747	0.275/0.412	0.251/0.370	0.276/0.379	72.763/4.085	0.828/0.506	0.162/0.289	7.688/8.938
TimesFM-3	0.195/0.270	0.555/0.516	0.428/0.482	0.334/0.384	0.326/0.391	63.468/3.822	0.834/0.457	0.414/0.469	8.125/8.375
Chronos-2	0.133/0.233	0.321/0.417	0.264/0.408	0.209/0.316	0.340/0.397	64.695/3.818	1.124/0.497	0.315/0.431	7.375/6.688
Toto-2.0 (313M)	0.330/0.346	0.393/0.450	0.565/0.556	0.196/0.314	0.329/0.394	244.928/5.691	0.818/0.469	0.649/0.640	9.375/9.750
Sundial	0.327/0.366	0.920/0.765	0.216/0.348	0.234/0.337	0.379/0.443	83.403/4.836	0.819/0.377	0.228/0.292	9.375/8.375
Moirai-Large	0.239/0.306	0.982/0.792	0.198/0.345	0.261/0.347	0.412/0.446	74.249/4.129	0.868/0.391	0.186/0.263	8.750/7.750
Full-shot multimodal models									
T3Time	0.229/0.303	1.206/0.894	0.239/0.384	0.266/0.378	0.489/0.507	72.113/4.070	0.998/0.432	0.289/0.368	10.750/9.813
TimeCMA	0.318/0.360	1.282/0.926	0.262/0.412	0.351/0.447	0.536/0.533	72.011/4.113	1.092/0.578	0.297/0.412	12.250/13.188
CALF	0.241/0.311	1.199/0.895	0.223/0.370	0.258/0.373	0.537/0.509	73.267/4.040	0.890/0.416	0.227/0.305	10.438/9.438
Full-shot unimodal models									
PatchTST	0.248/0.308	1.176/0.891	0.223/0.380	0.243/0.353	0.496/0.513	76.105/4.445	0.959/0.475	0.209/0.316	10.188/10.750
DLinear	0.377/0.396	1.036/0.807	0.218/0.370	0.233/0.346	0.591/0.627	82.521/4.891	0.891/0.448	0.219/0.315	10.875/11.063

消融实验

Model	Agriculture	Climate	Economy	Energy	Environment	Security	Social Good	Traffic
w/o EvolveTrust	0.142/0.236	0.334/0.424	0.205/0.349	0.183/0.307	0.281/0.385	59.712/3.391	0.812/0.448	0.088/0.178
w/o EvolveReason	0.138/0.234	0.328/0.418	0.196/0.342	0.182/0.305	0.278/0.380	59.402/3.351	0.810/0.421	0.088/0.177
w/o EvolveIntervene	0.135/0.232	0.324/0.414	0.190/0.337	0.182/0.304	0.276/0.378	59.248/3.329	0.809/0.408	0.088/0.177
TIMEVOLVE-STACK	0.148/0.240	0.342/0.432	0.220/0.360	0.185/0.309	0.285/0.396	60.429/3.479	0.814/0.508	0.089/0.178
TIMEVOLVE	**0.129/0.227**	**0.314/0.402**	**0.181/0.329**	**0.181/0.303**	**0.274/0.372**	**58.937/3.285**	**0.808/0.381**	**0.087/0.176**

证明evolve机制的有效性

Feedback regime	Agriculture	Climate	Economy	Energy	Environment	Security	Social Good	Traffic
Selected-path feedback	0.134/0.231	0.321/0.409	0.187/0.334	0.182/0.305	0.277/0.379	59.374/3.348	0.810/0.414	0.088/0.177
Selected-expert feedback	0.140/0.236	0.331/0.419	0.198/0.344	0.184/0.308	0.282/0.386	59.756/3.401	0.812/0.451	0.088/0.178
Selected-only feedback	0.145/0.239	0.336/0.424	0.208/0.352	0.184/0.308	0.283/0.392	60.158/3.448	0.813/0.485	0.089/0.178
Frozen policy	0.148/0.240	0.342/0.432	0.220/0.360	0.185/0.309	0.285/0.396	60.429/3.479	0.814/0.508	0.089/0.178
All-alternative feedback	**0.129/0.227**	**0.314/0.402**	**0.181/0.329**	**0.181/0.303**	**0.274/0.372**	**58.937/3.285**	**0.808/0.381**	**0.087/0.176**

证明备选方案的价值，如Selected-path feedback 意思是路径
损失只考虑当时选择的路径，而不考虑其他未选择的路径

总结

整体流程：综合使用各个模型都跑一遍预测结果->通过可参数更新的模块将这些结果融合起来->模块的参数会在预测过程中根据真实值更新

可参考的思路：融合多个模型结果的想法；利用预测过程中的数据进行训练；融合了多模态上下文；很小的模型在过程中更新，优化性能且减少开销

存在的问题
1.没有考虑预测对环境的影响，这方法假设无论预测结果是什么，未来的真实结果都是确定的，但实际问题中，可能会出现预测结果对未来产生影响的情况 例如根据销量预测调整商品定价
2.依赖冻结的模型的能力，若各个模型都无法到达预期效果，则最终效果也不会很好，可能需要对模型进行微调
3.没有测试长期预测的效果与稳定性，没有测试对于具有周期性的曲线的适应能力
4.进化过程中更新参数的模型都是非常小且简单的模型，适应能力有限，对于更复杂的真实场景的有效性有待验证

4KAgent:
Agentic Any Image to 4K Super-Resolution

Yushen Zuo[1], Qi Zheng[1†], Mingyang Wu[1†], Xinrui Jiang[2†], Renjie Li[1], Jian Wang[3], Yide Zhang[4], Gengchen Mai[5], Lihong V. Wang[6], James Zou[2], Xiaoyu Wang[7], Ming-Hsuan Yang[8], Zhengzhong Tu[1⋆]

[1]Texas A&M University [2]Stanford University [3]Snap Inc. [4]CU Boulder
[5]UT Austin [6]California Institute of Technology [7]Topaz Labs [8]UC Merced

⋆Corresponding Author: tzz@tamu.edu. †Equal contributions.

Project Website: 4kagent.github.io

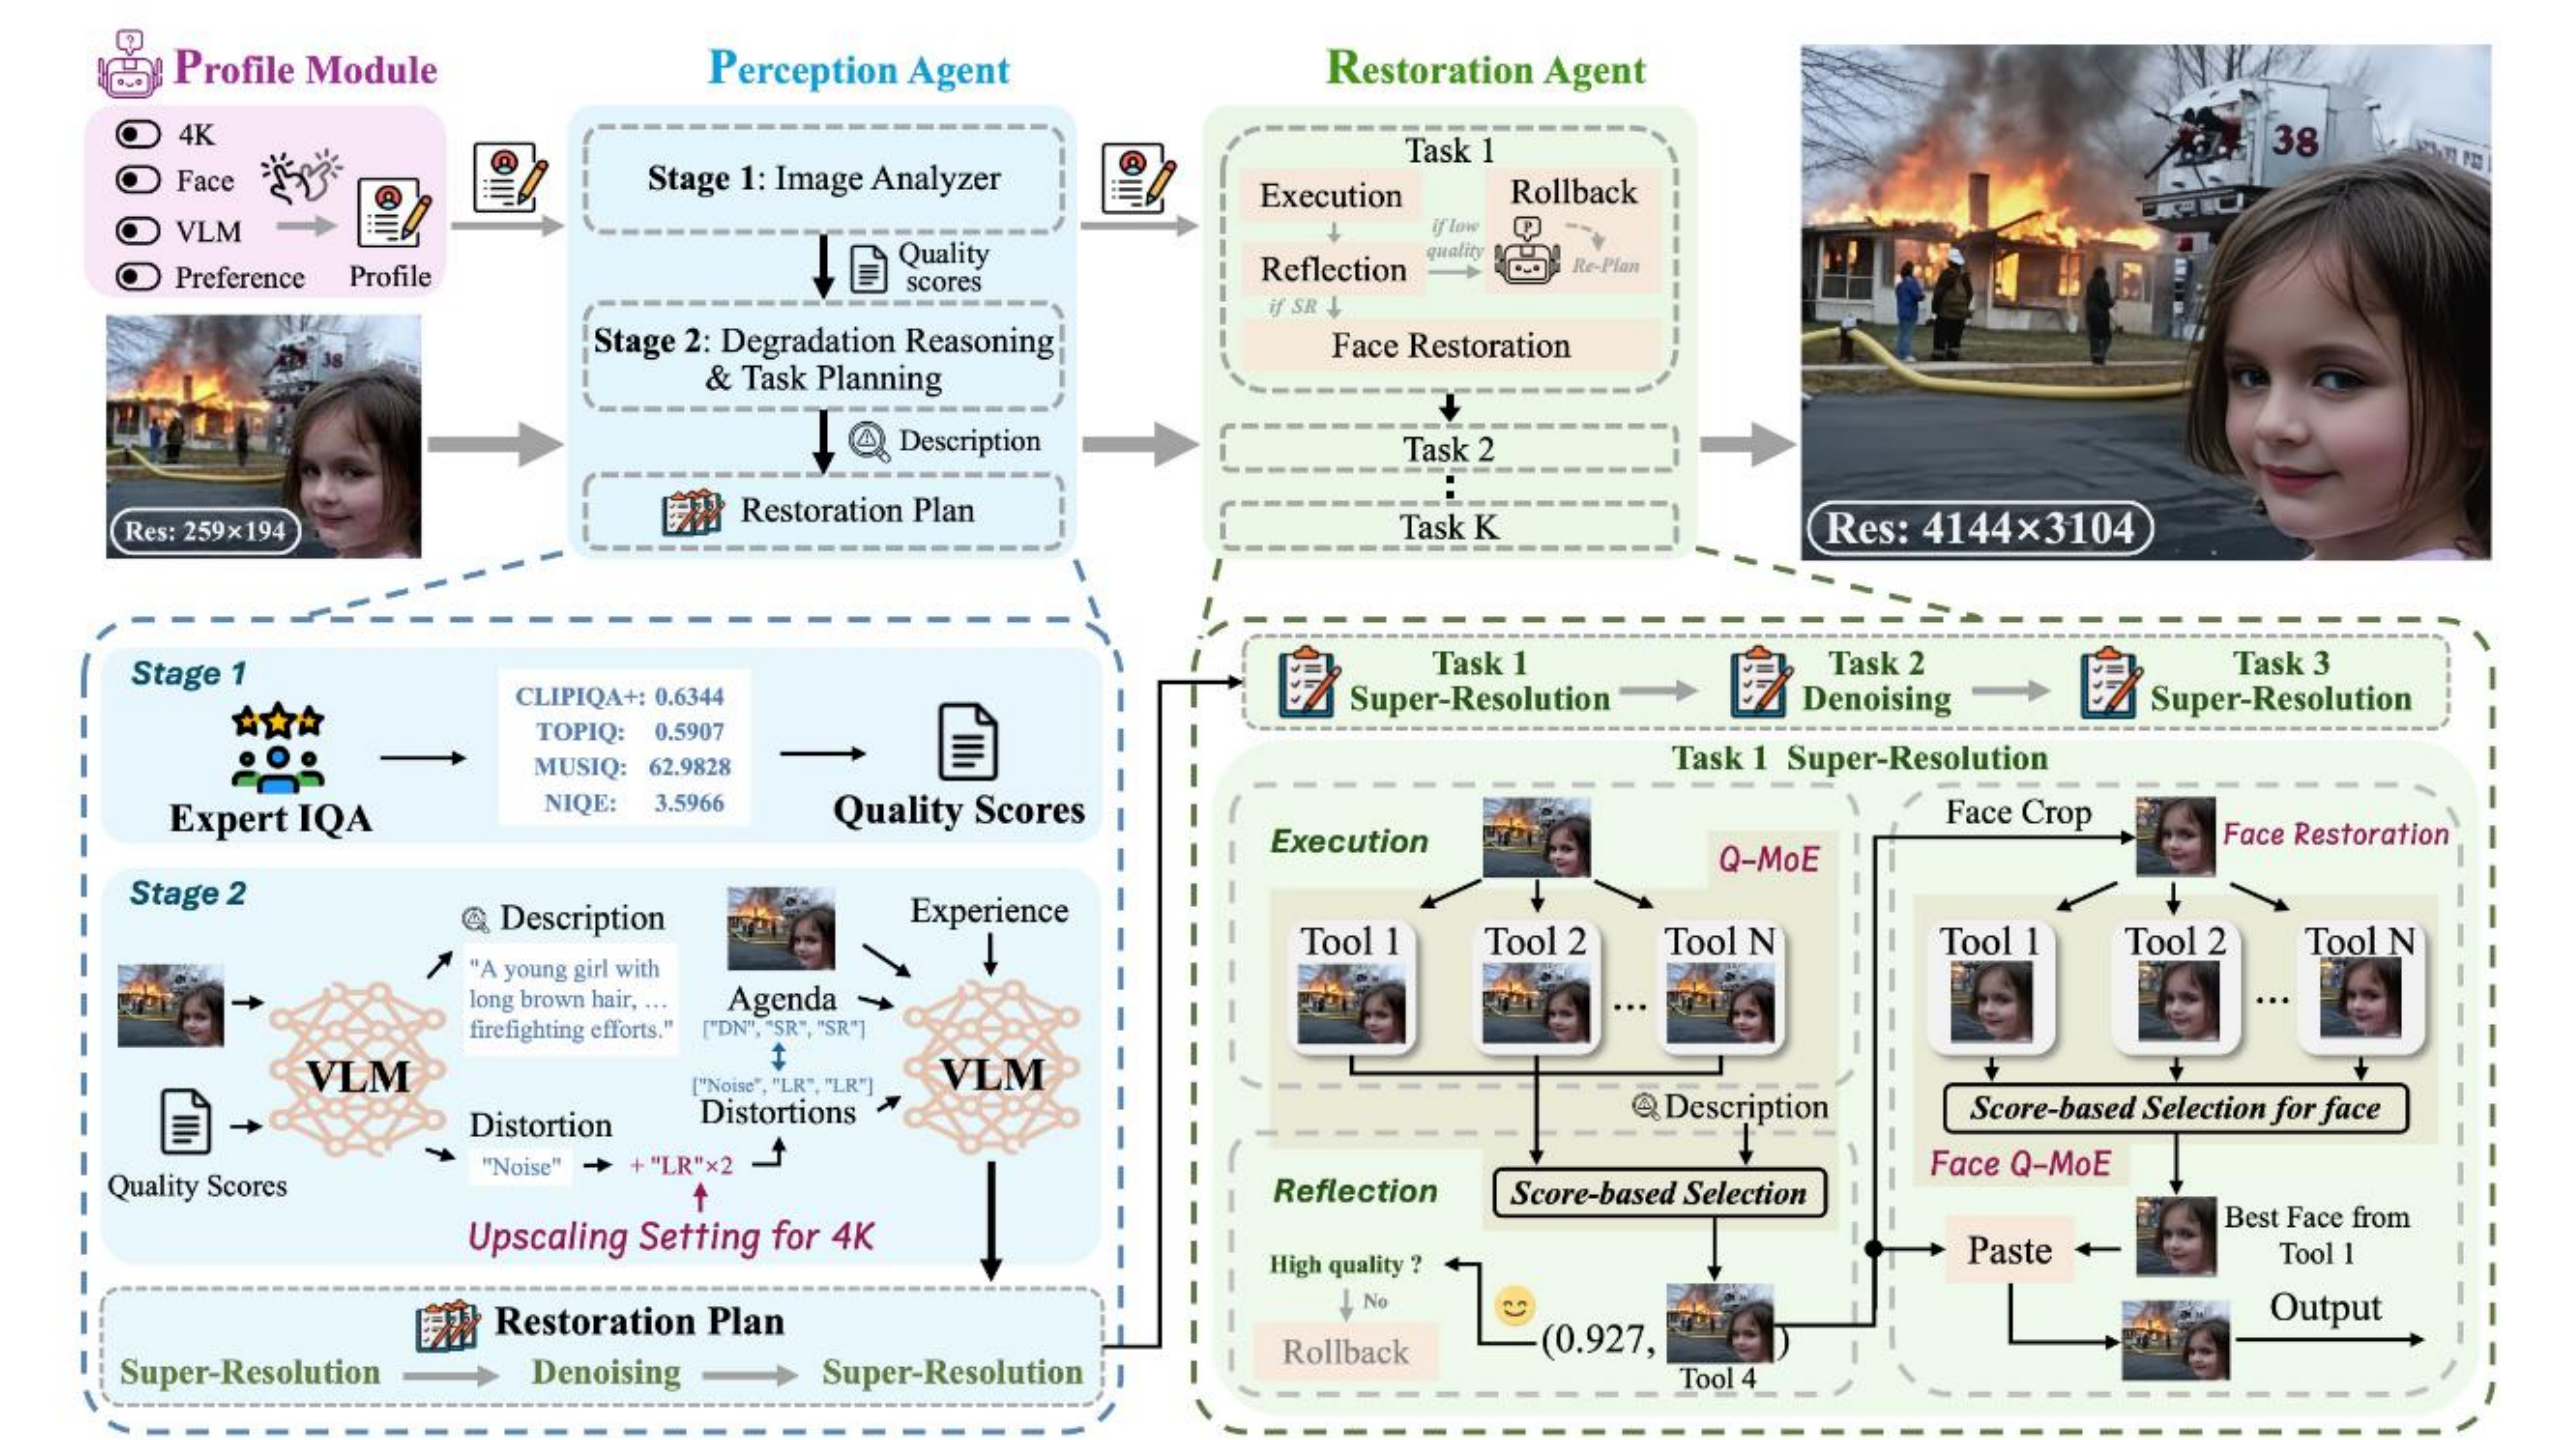
4KAgent
https://arxiv.org/abs/2507.07105

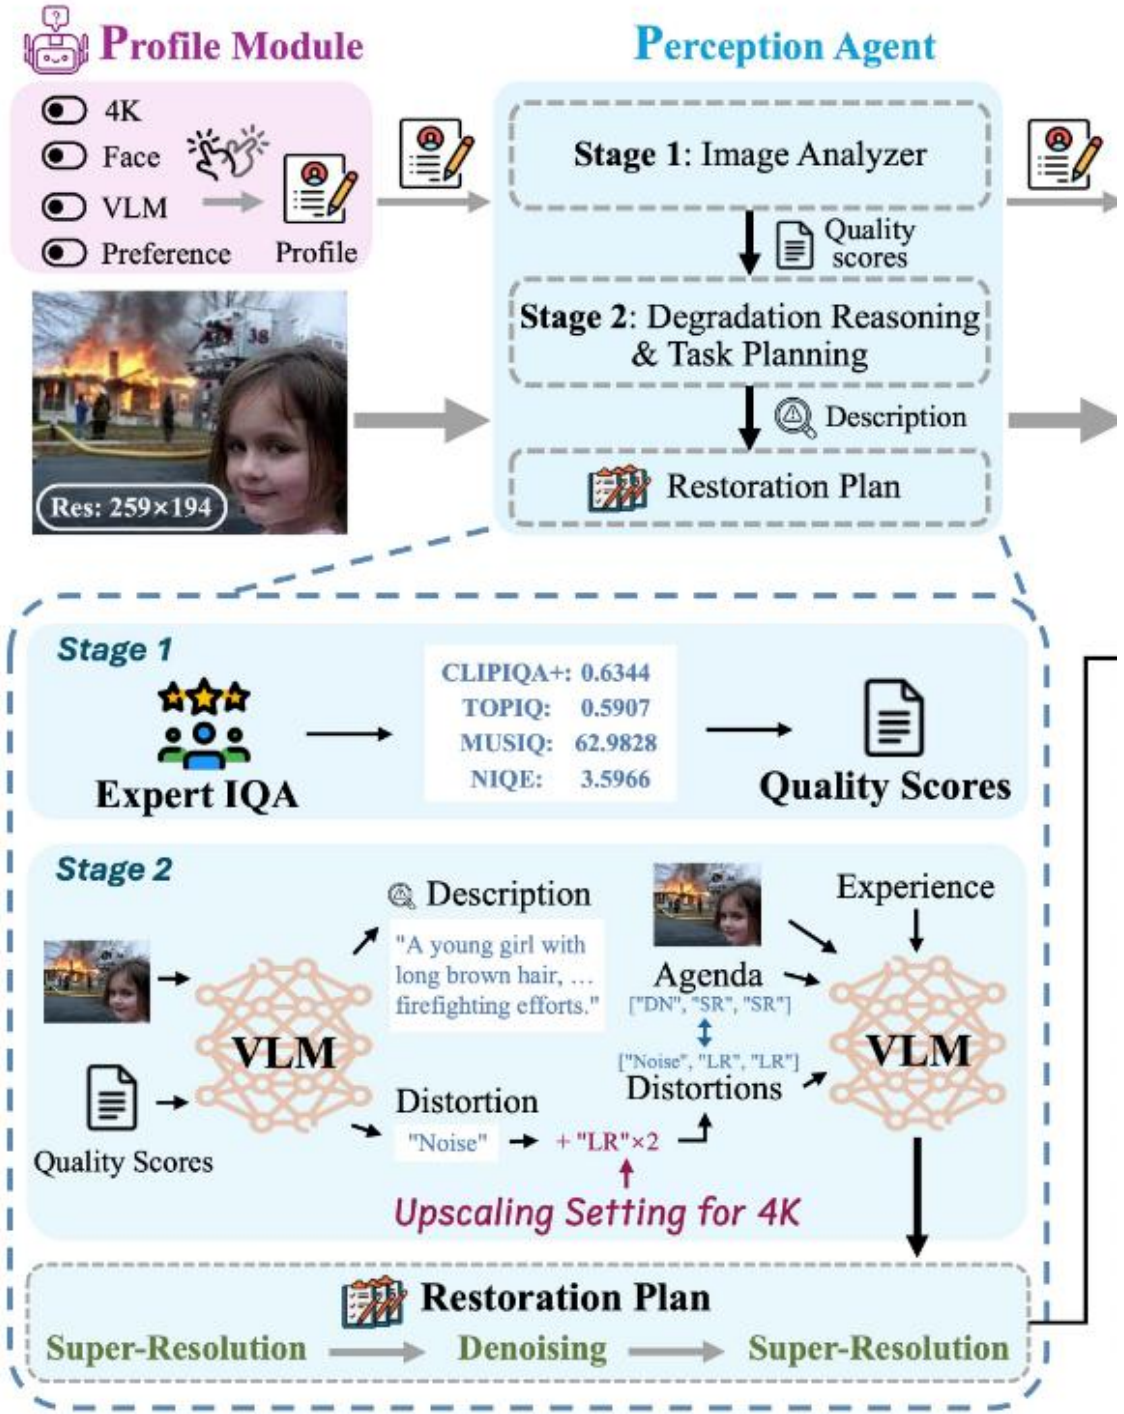
超分任务

低分辨率图像->高分辨率图像
H x W x C -> sH x sW x C

4KAgent的优势与功能

1.自由的超分放大比例和处理各类退化问题
2.仅用自然图像模型，无需训练，就可以处理任何图像，并击败专业模型，以证明这个agent框架的能力
3.可以调节超分的方向，是以观感为主还是以内容准确为主
4.对于复杂退化，单一的工具很难达到最好的表现
5.4K生成，运用1k模型的成熟生成能力与4k超分


Profile Module
4K
Face
VLM
Preference
Profile
Perception Agent
Stage 1: Image Analyzer
Quality scores
Stage 2: Degradation Reasoning & Task Planning
Description
Restoration Plan
Res: 259×194
Restoration Agent
Task 1
Execution
Rollback
if low quality
Reflection
Re-Plan
if SR
Face Restoration
Task 2
Task K
Res: 4144×3104
Stage 1
Expert IQA
CLIPIQA+: 0.6344
TOPIQ: 0.5907
MUSIQ: 62.9828
NIQE: 3.5966
Quality Scores
Stage 2
Description
"A young girl with long brown hair, … firefighting efforts."
Agenda
["DN", "SR", "SR"]
["Noise", "LR", "LR"]
Distortions
Experience
VLM
VLM
Quality Scores
Distortion
"Noise"
+"LR"×2
Upscaling Setting for 4K
Restoration Plan
Super-Resolution
Denoising
Super-Resolution
Task 1 Super-Resolution
Task 2 Denoising
Task 3 Super-Resolution
Task 1 Super-Resolution
Execution
Q-MoE
Tool 1
Tool 2
Tool N
Description
Reflection
Score-based Selection
High quality ?
No
Rollback
(0.927,
Tool 4
Face Crop
Face Restoration
Tool 1
Tool 2
Tool N
Score-based Selection for face
Face Q-MoE
Best Face from Tool 1
Paste
Output

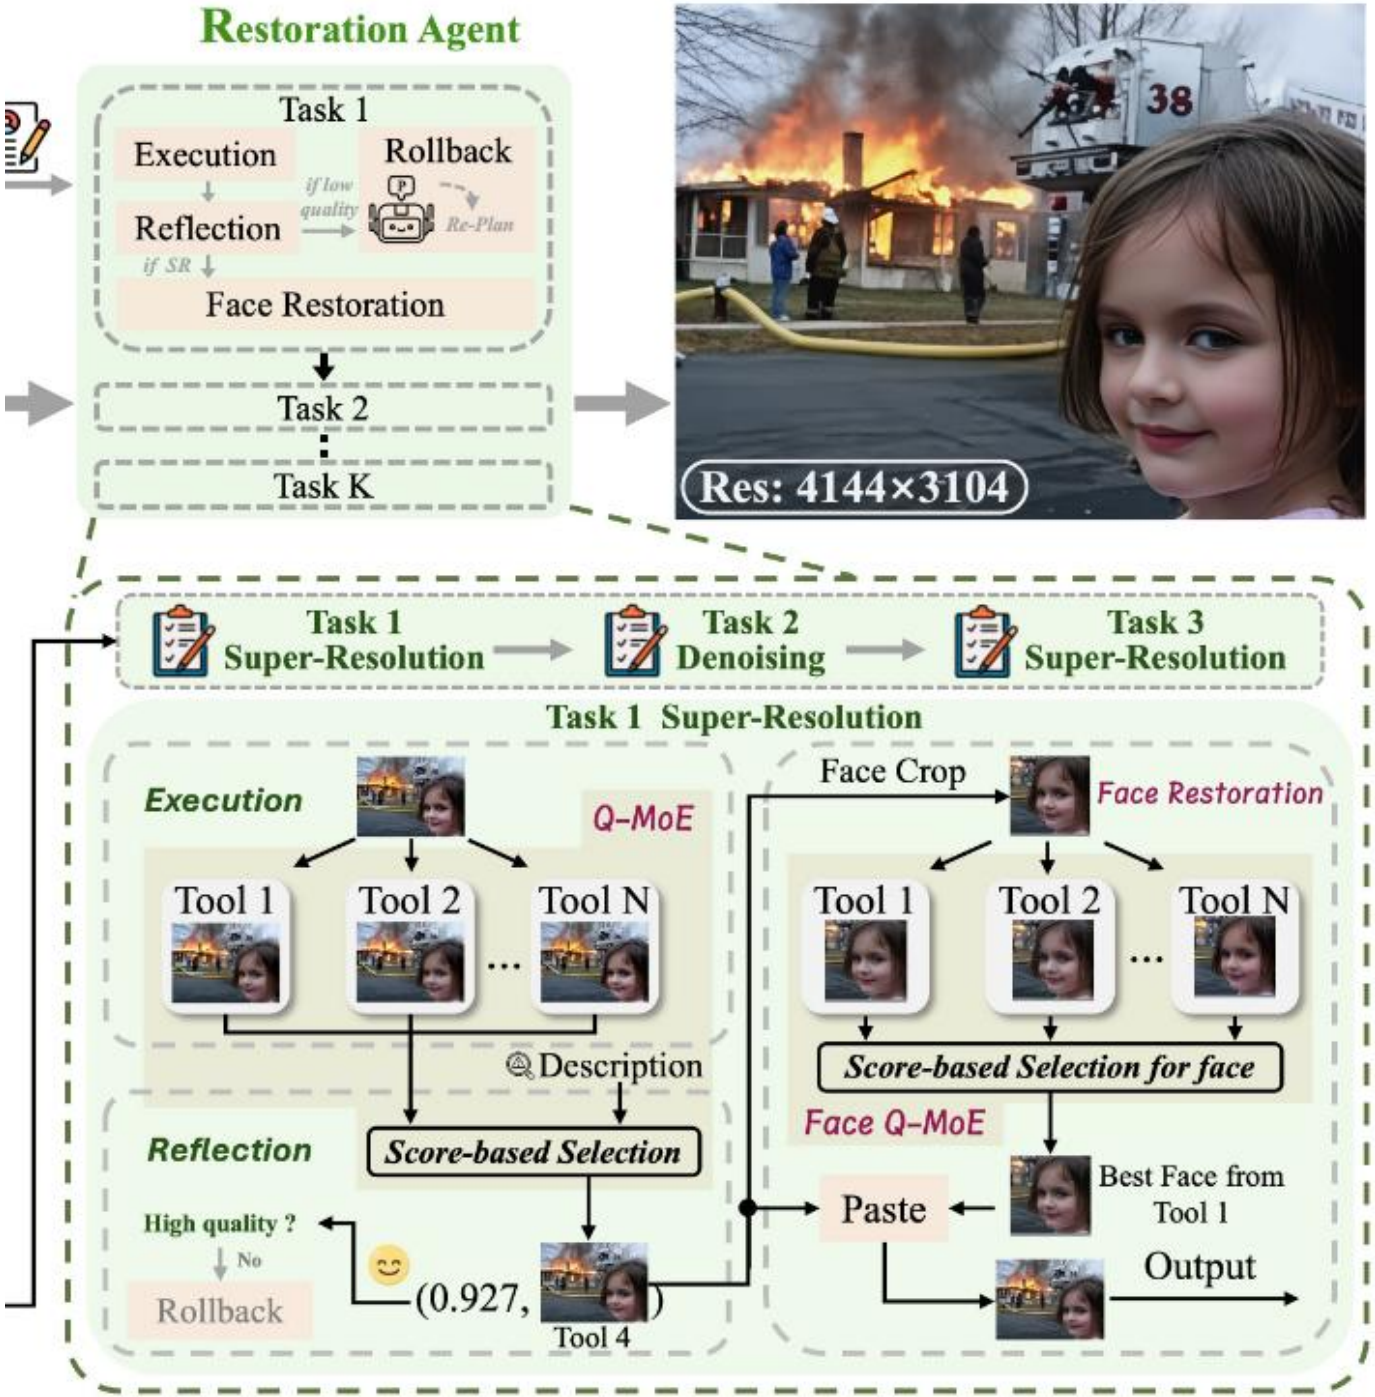


Profile Module：
配置模块，类似system prompt。可设定参数，例如是否上4K、模型选择等等

Perception Agent：
1.图像质量评估，用多种工具评估当前图像质量得到多维度分数
2.图像和分数输入VLM，得到图像描述、退化类型、初步恢复任务列表
3.根据图像高宽计算放大倍数，将超分任务追加到任务列表
4.根据描述、退化类型、任务列表、恢复经验（先验知识，通常采用哪些恢复手段更好）、图像，输入到VLM，得到恢复计划

Restoration Agent:
根据计划，执行-反思-回滚
1.执行时按照计划逐步执行，每步会尝试所有相关工具
2.反思时计算分数，选择最优图像
3.若某一步质量分数低于阈值，则回滚，调用Perception Agent调整后续计划
4.存在一个人脸恢复管道，因为人脸恢复比较特殊，所以有专门的流程

对于工具箱：9类任务的多个sota模型，都是在自然图像的工具
提亮、散焦去模糊、运动去模糊、去雾、去噪、去雨、去JPEG 压缩伪影、超分、人脸恢复



工具箱中的模型

Brightening

CLAHE [271]
Constant Shift (C=40)
DiffPlugin [129]
FourierDiff [134]
Gamma Correction ($\gamma = 2/3$)
MAXIM [183]

Denoising

MAXIM [183]
MPRNet [243]
NAFNet [25]
Restormer [241]
X-Restormer [28]
SwinIR [117]

Defocus Deblurring

ConvIR [39]
DiffPlugin [129]
DRBNet [165]
IFAN [98]
LaKDNet [164]
Restormer [241]

Motion Deblurring

EVSSM [88]
LaKDNet [164]
MAXIM [183]
MPRNet [243]
NAFNet [25]
Restormer [241]
X-Restormer [28]

Dehazing

DehazeFormer [172]
DiffPlugin [129]
MAXIM [183]
RIDCP [213]
X-Restormer [28]

Deraining

DiffPlugin [129]
MAXIM [183]
MPRNet [243]
Restormer [241]
X-Restormer [28]

Face Restoration

GFPGAN [196]
CodeFormer [266]
DifFace [239]

Super Resolution

DiffBIR [121]
DRCT [68]
HAT-L [29]
HAT-GAN [29]
HMA [34]
OSEDiff [211]
PiSA-SR [176]
SwinIR [117]
SwinIR (Real-ISR) [117]
SwinFIR [248]
X-Restormer [28]

JPEG CAR

FBCNN [77] (QF=5)
FBCNN [77] (QF=90)
FBCNN [77] (BQF)
SwinIR [117] (QF=40)

提示词1 -- 根据IQA指标，对退化类型进行推理

Prompt for Llama-Vision in Degradation Reasoning

You are an expert tasked with image quality assessment (IQA) and well-versed in popular IQA metrics, including CLIPIQA+, TOPIQ_NR, MUSIQ, and NIQE. Note that for NIQE, a lower score indicates better image quality, whereas for the other metrics, higher scores generally reflect better quality. Here's an image to restore, along with its corresponding quality scores evaluated using the aforementioned IQA metrics. First, please describe the content and style of the input image, the description must not contain its image quality. Second, please assess the image based on both the metric scores and your prior visual knowledge, with respect to the following two degradations: noise, motion blur, defocus blur, haze, rain, jpeg compression artifact. Images may suffer from one or more of these degradations. **Do not output any explanations or comments.** **Strictly return only a JSON object** containing degradation types and image content/style description. The keys in the JSON object should be: 'degradations' and 'image_description'. Information about the input image: IQA metrics: **{iqa_result}**. (**{iqa_result}** corresponds to Q_I in Sec. 2.2.)

你是一位负责图像质量评估（IQA）的专家，并且精通流行的 IQA 指标，包括 CLIPIQA+、TOPIQ_NR、MUSIQ 和 NIQE。请注意，对于 NIQE，分数越低表示图像质量越好，而对于其他指标，分数越高通常代表质量越好。这是一张待恢复的图像，以及使用上述 IQA 指标评估出的相应质量分数。首先，请描述输入图像的内容和风格，描述中不得包含其图像质量（评价）。其次，请基于指标分数和你的先验视觉知识来评估该图像，涉及以下六种退化类型：噪声、运动模糊、失焦模糊、雾霾、雨滴、JPEG 压缩伪影。图像可能遭受这些退化中的一种或多种。**不要输出任何解释或评论。** **严格只返回一个 JSON 对象**，包含退化类型以及图像内容/风格描述。JSON 对象中的键应为：degradations 和 image_description。关于输入图像的信息：IQA 指标：{iqa_result}。

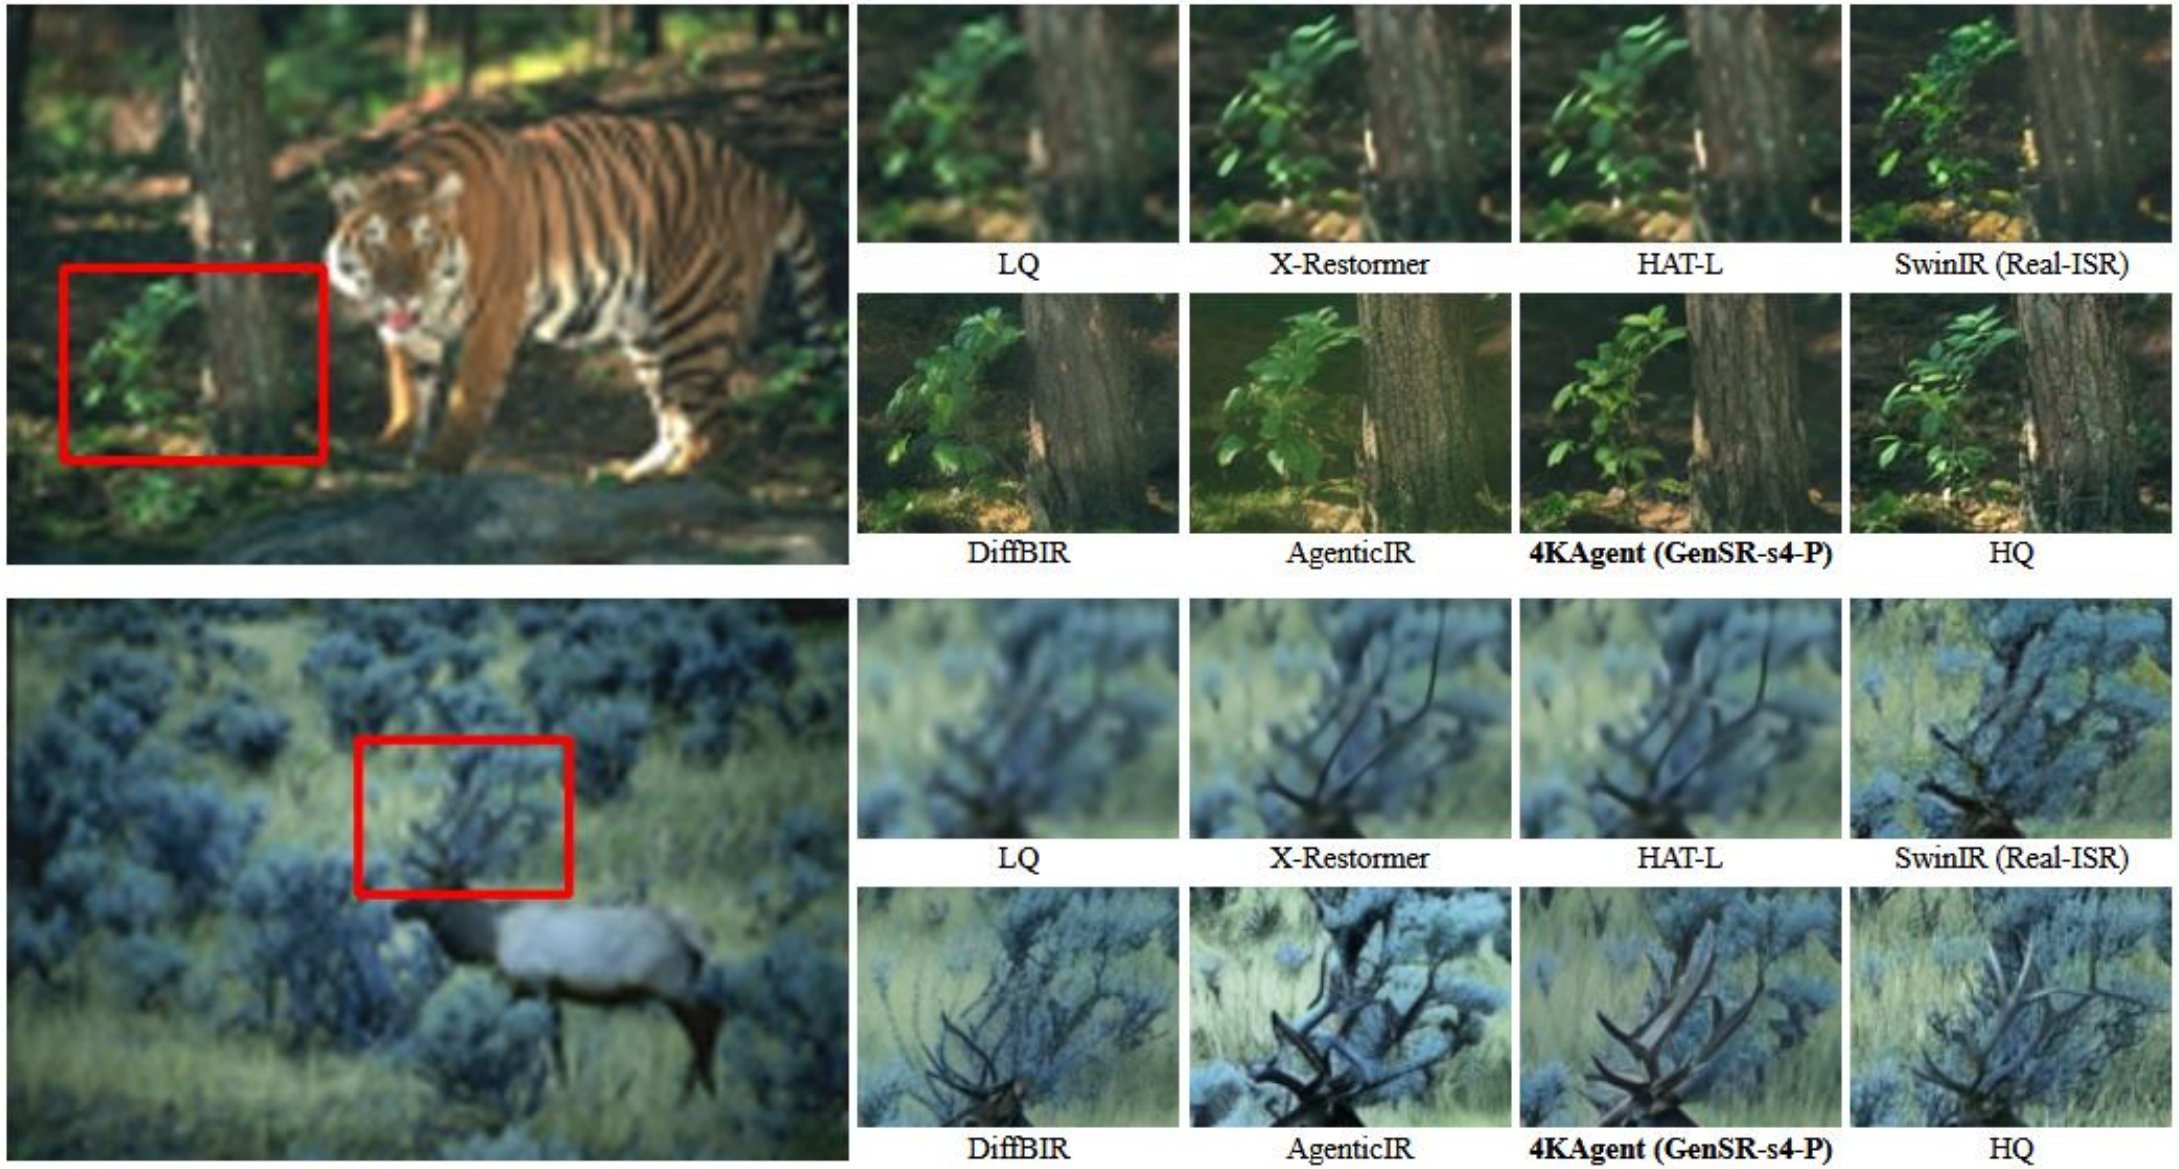
提示词2 -- 任务规划与回滚

Prompt for Llama-Vision in Planning (Rollback)

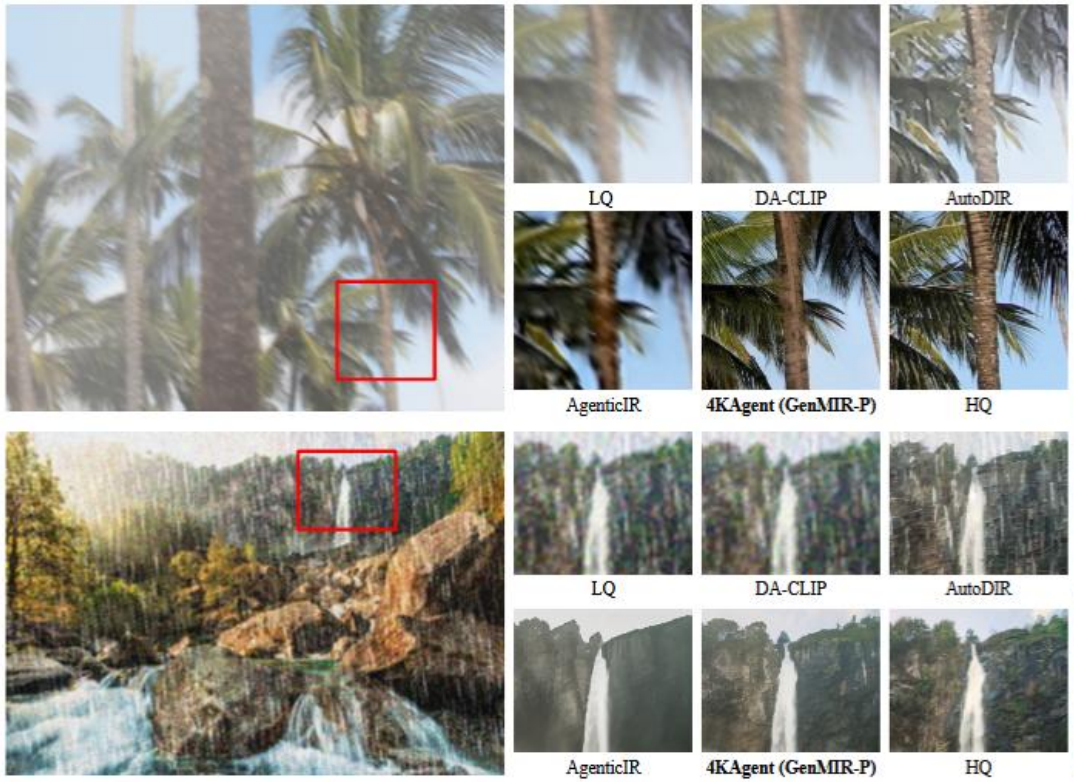
You are an expert in image restoration. Given an image of low quality, your task is to guide the user to utilize various tools to enhance its quality. The input image requires a list of restoration tasks. Your goal is to make a plan (the order of the tasks) based on the task list. The final output should be formatted as a JSON object containing the restoration plan (the correct order of the tasks). The key in the JSON object should be: 'plan'. Information about the input image:
Its description is: **{image_description}** (C_I),
It suffer from degradations **{degradations}** (D_I),
The list of restoration tasks: **{tasks}** (A_I / A_I^R),
For your information, based on past trials, we have the following experience in making a restoration plan: **{experience}** (E). Based on this experience, please give the correct order of the tasks in the restoration plan. The restoration plan must be a permutation of **{tasks}** in the order you determine. (Besides, in attempts just now, we found the result is unsatisfactory if **{failed_tries}** (S_I) is conducted first. Remember not to arrange **{failed_tries}** in the first place.) **Do not output any explanations or comments.**
Strictly return only a JSON object containing plan. The keys in the JSON object should be: 'plan'.

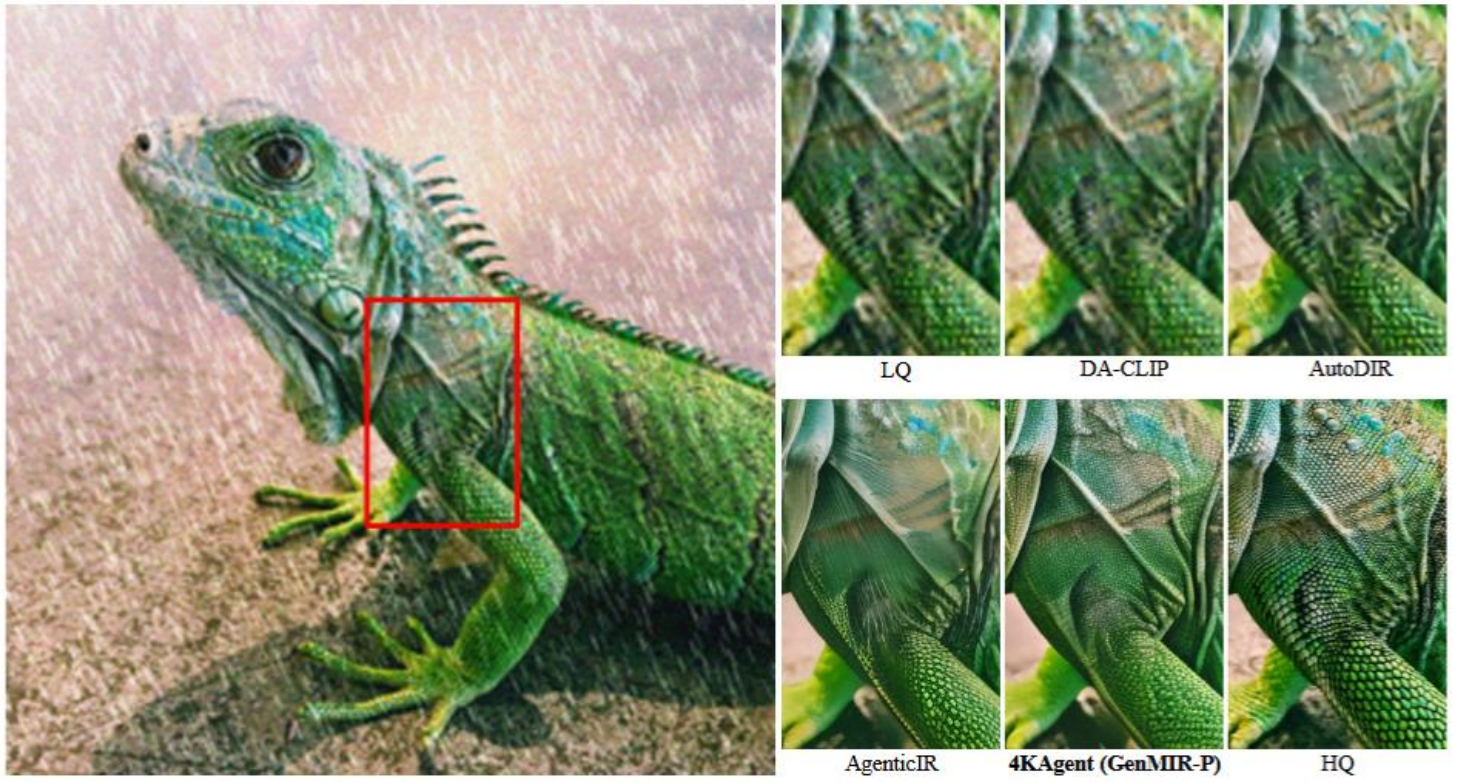
你是一位图像恢复专家。给定一张低质量的图像，你的任务是指导用户利用各种工具来提升其质量。输入图像需要一系列恢复任务。你的目标是根据任务列表制定一个计划（即任务的执行顺序）。最终输出应格式化为包含恢复计划（任务的正确顺序）的 JSON 对象。JSON 对象中的键应为：plan。
关于输入图像的信息：
其描述为：{image_description}，
它遭受了以下退化 {degradations}，
恢复任务列表：{tasks}，
供你参考，基于过去的尝试，我们在制定恢复计划方面有以下经验：{experience}。基于此经验，请给出恢复计划中任务的正确顺序。恢复计划必须是按你确定的顺序对 {tasks} 进行的排列。（此外，在刚才的尝试中，我们发现如果首先执行 {failed_tries} 结果并不理想。请记住不要把 {failed_tries} 安排在首位。）严格只返回一个包含计划的 JSON 对象。JSON 对象中的键应为：plan。

实验--自然图像


LQ
X-Restormer
HAT-L
SwinIR (Real-ISR)
DiffBIR
AgenticIR
4KAgent (GenSR-s4-P)
HQ
LQ
X-Restormer
HAT-L
SwinIR (Real-ISR)
DiffBIR
AgenticIR
4KAgent (GenSR-s4-P)
HQ

实验--复杂退化





通过agent做到基模无法做到的事情

实验--人脸


LQ
GFPGAN
CodeFormer
DifFace
AgenticIR
4KAgent (GenSRFR-s4-P)

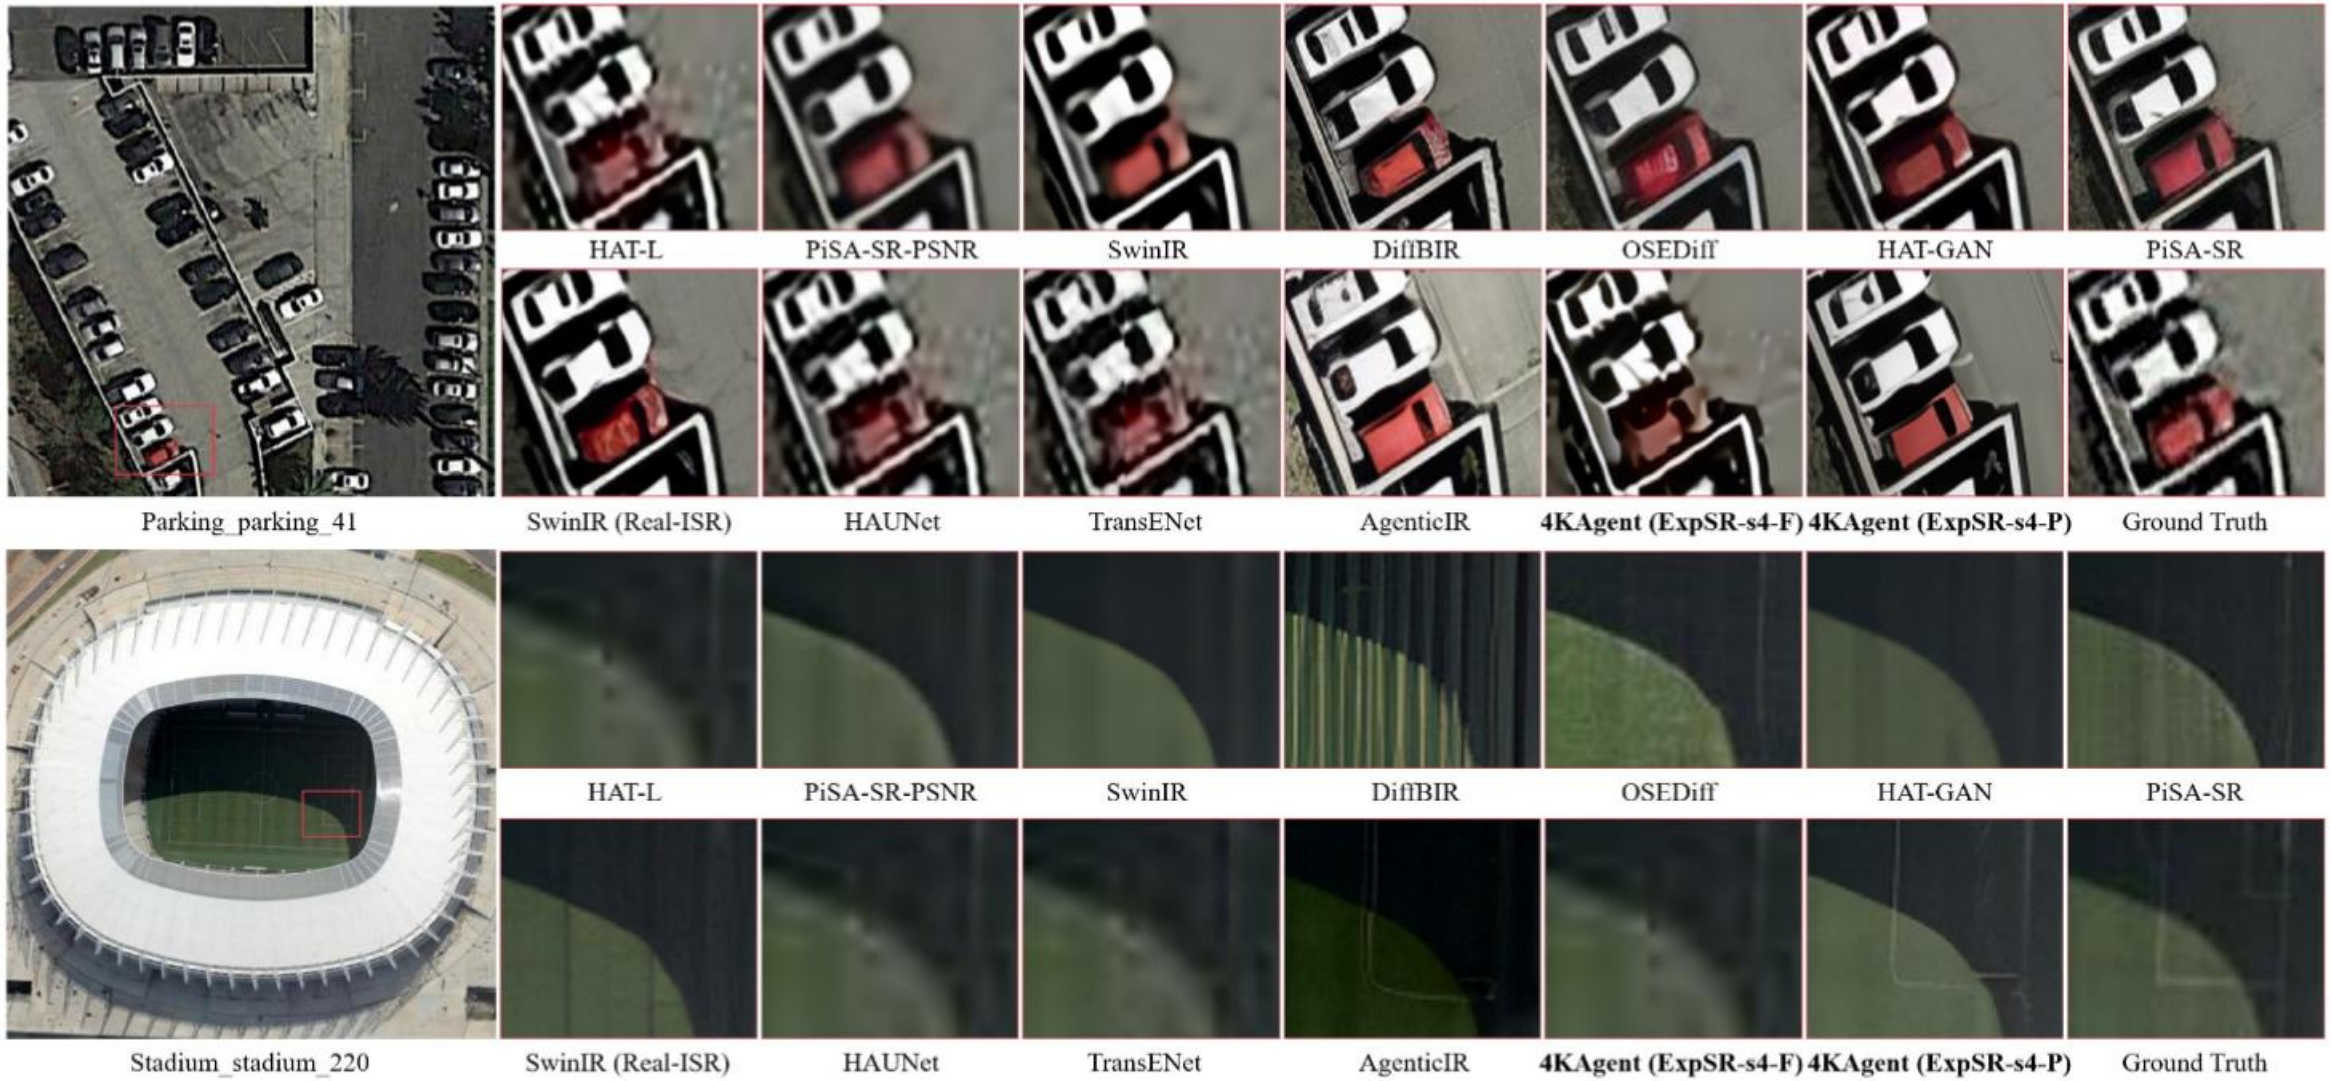
实验--4K生成



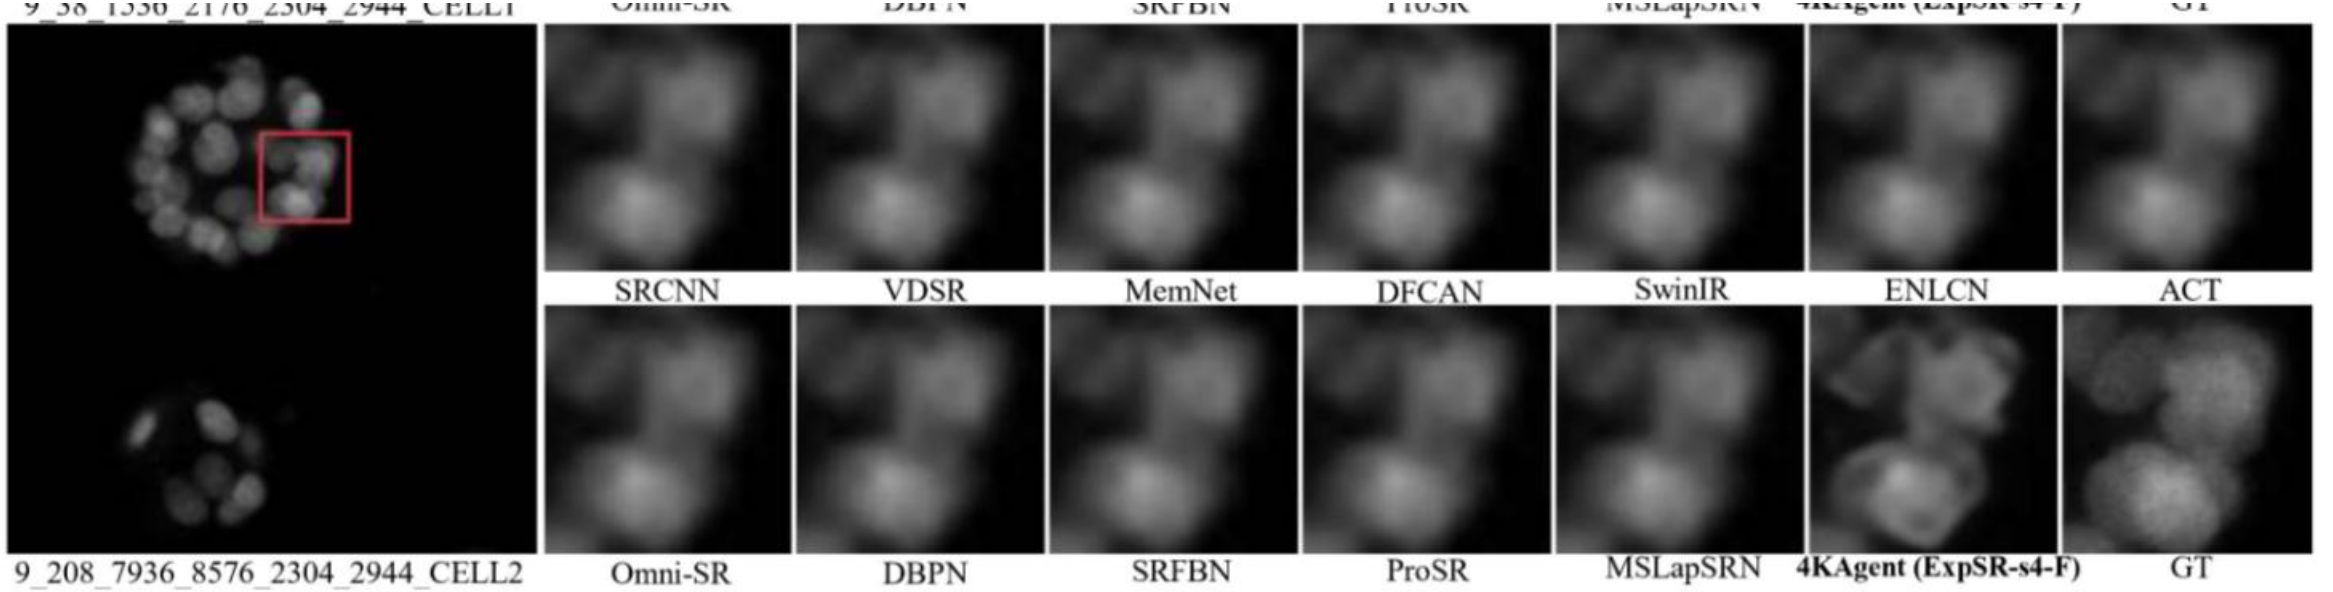
对比原生4K和1K生成+超分

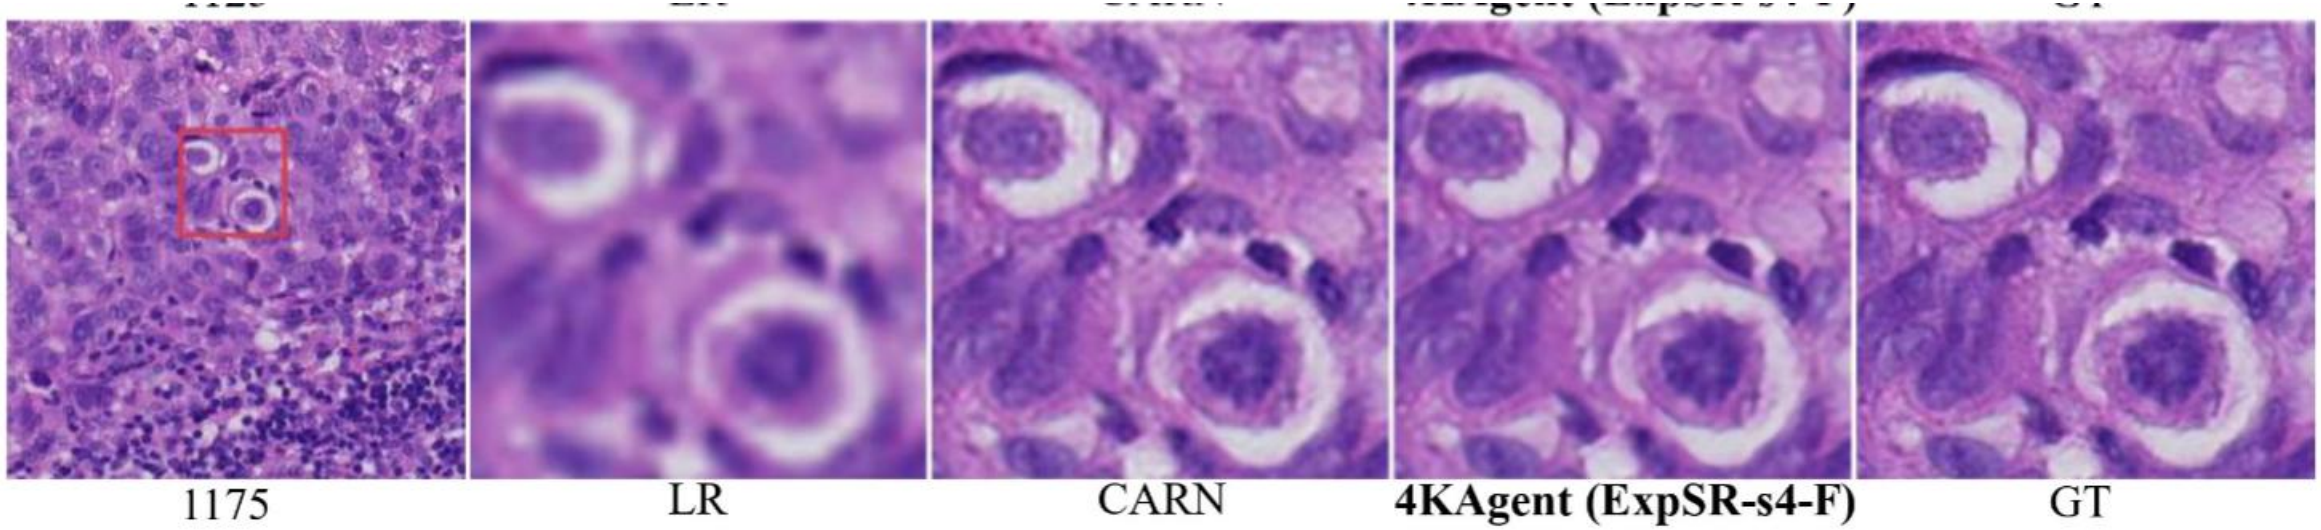
通过agent超越基模的性能

实验--遥感


HAT-L
PiSA-SR-PSNR
SwinIR
DiffBIR
OSEDiff
HAT-GAN
PiSA-SR
Parking_parking_41
SwinIR (Real-ISR)
HAUNet
TransENet
AgenticIR
4KAgent (ExpSR-s4-F)
4KAgent (ExpSR-s4-P)
Ground Truth
HAT-L
PiSA-SR-PSNR
SwinIR
DiffBIR
OSEDiff
HAT-GAN
PiSA-SR
Stadium_stadium_220
SwinIR (Real-ISR)
HAUNet
TransENet
AgenticIR
4KAgent (ExpSR-s4-F)
4KAgent (ExpSR-s4-P)
Ground Truth

实验--医学


SRCNN
VDSR
MemNet
DFCAN
SwinIR
ENLCN
ACT
9_208_7936_8576_2304_2944_CELL2
Omni-SR
DBPN
SRFBN
ProSR
MSLapSRN
4KAgent (ExpSR-s4-F)
GT


1175
LR
CARN
4KAgent (ExpSR-s4-F)
GT

总结

概述：评估图像确定退化类型->生成计划->调用多个小模型迭代和筛选出最优图像

优点：　通用性+可扩展性+达到单一模型无法达到的效果
1.确实解决了一些实际问题，而不是只是为了刷榜，这是单一模型确实无法解决的问题
2.可以通过工具的整合让功能更多样更便利，如自由的放大比例和各类问题
3.工具可以替代和扩展
4.可以通过工具的组合运用达到单一模型无法达到的效果，如复杂退化，4K生成

待解决的问题
1.计算慢，受限于资源，大部分工具为顺序执行
2.在某些场景，随时间变化，数据分布可能改变，相应的模型可能也需要适应新数据而进行进化 比如显微镜下的图像可能成像更清晰，比如物理场的采集方法进步后可能数据噪声更少
3.配置的选择问题可能待解决，在不同图像下，到底使用哪些配置比较合适

An Agentic AI Scientific Community for Automated Neural Operator Discovery

Luis Loo and Ulisses Braga-Neto

Department of Electrical & Computer Engineering
Texas A&M University, College Station, TX
loo,ulisses@tamu.edu

AI-SC
https://arxiv.org/abs/2607.12122

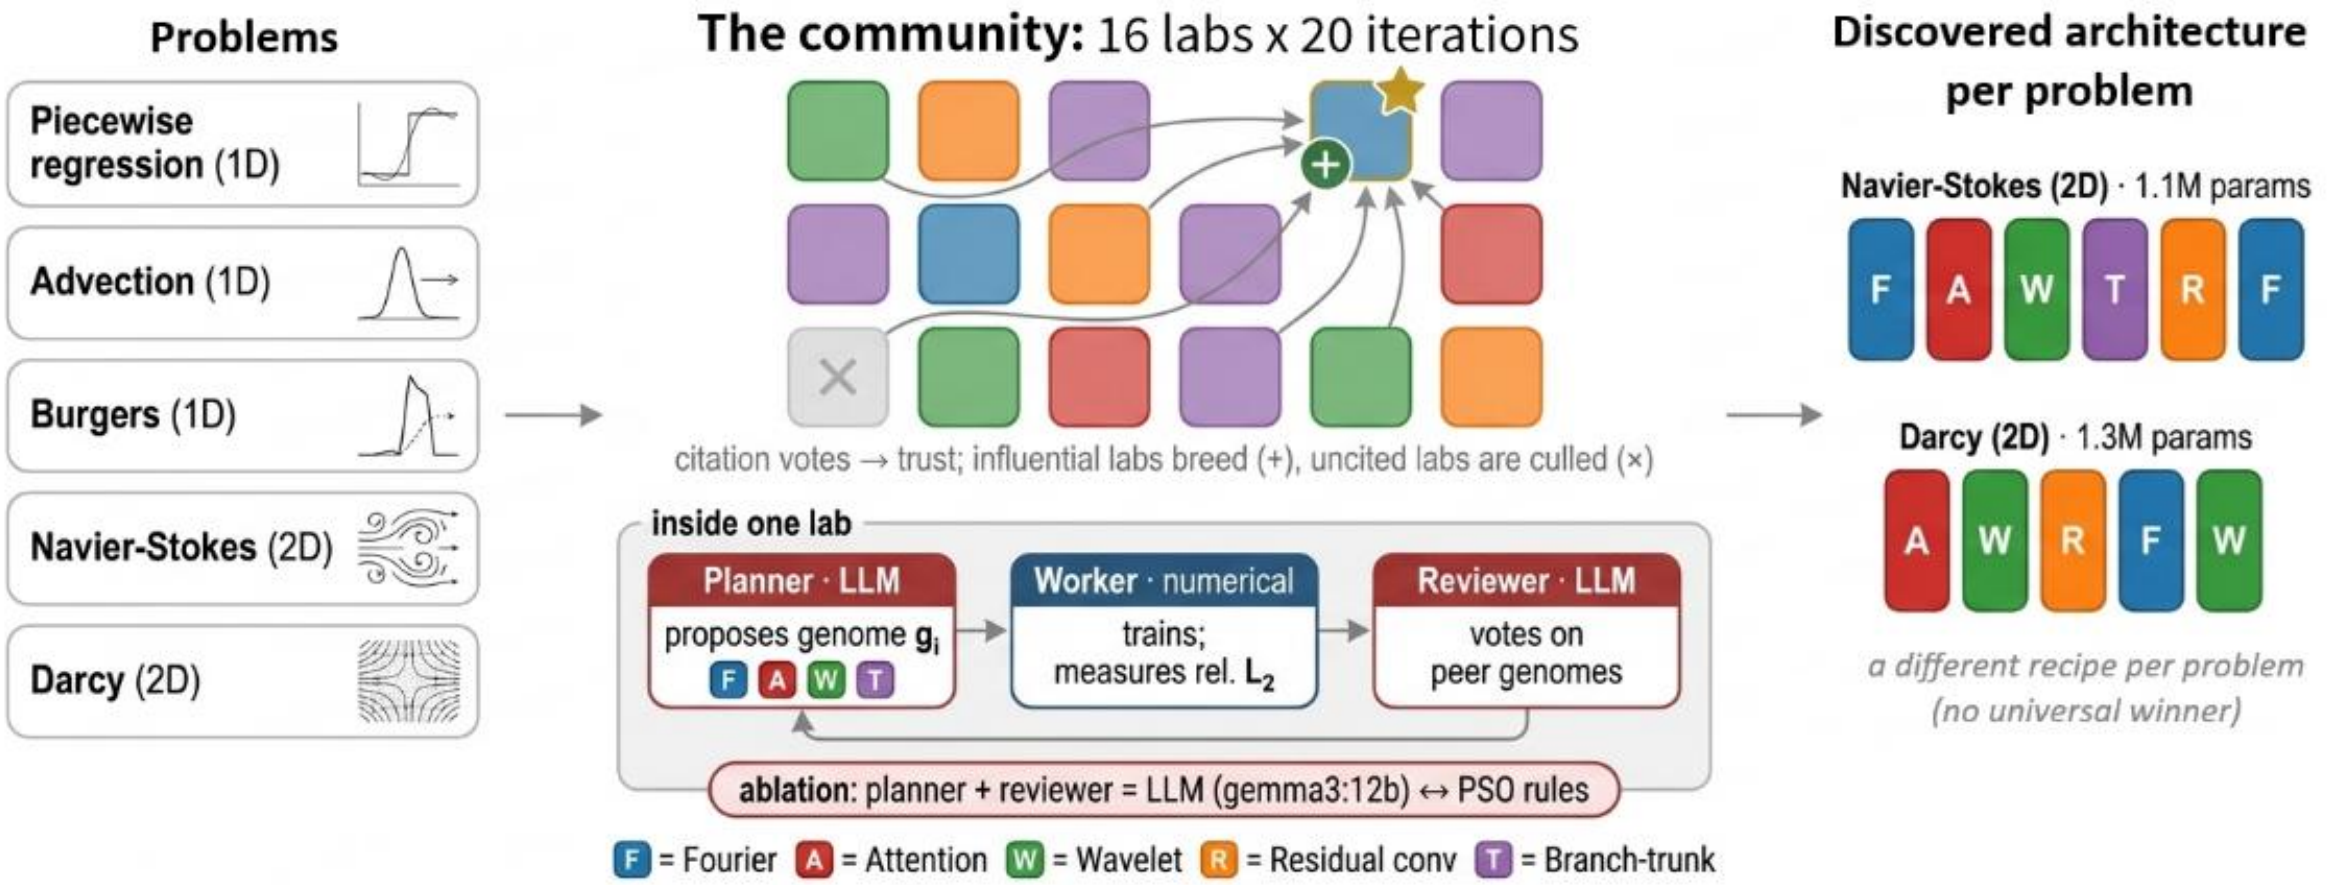
AI-SC

解决的任务是PDE求解，模型作为解算子，学习初值到解函数的映射
对于1d，输入和输出为B,c,l->B,c′,l
对于2d，输入和输出为B,c,h,w->B,c′,h,w

整体框架参考了粒子群算法，但核心部分用LLM代替，搜索出对于每个问题最佳的模块组合和超参数组合

原因与动机：
单一模型很难适用于所有PDE，且超参数也需要人工调节。比如物理基座模型，看似使用了各种PDE的数据进行训练，但实际上网络依然不能适配所有PDE

通过agent提供通用性，而不是从基座模型层面做



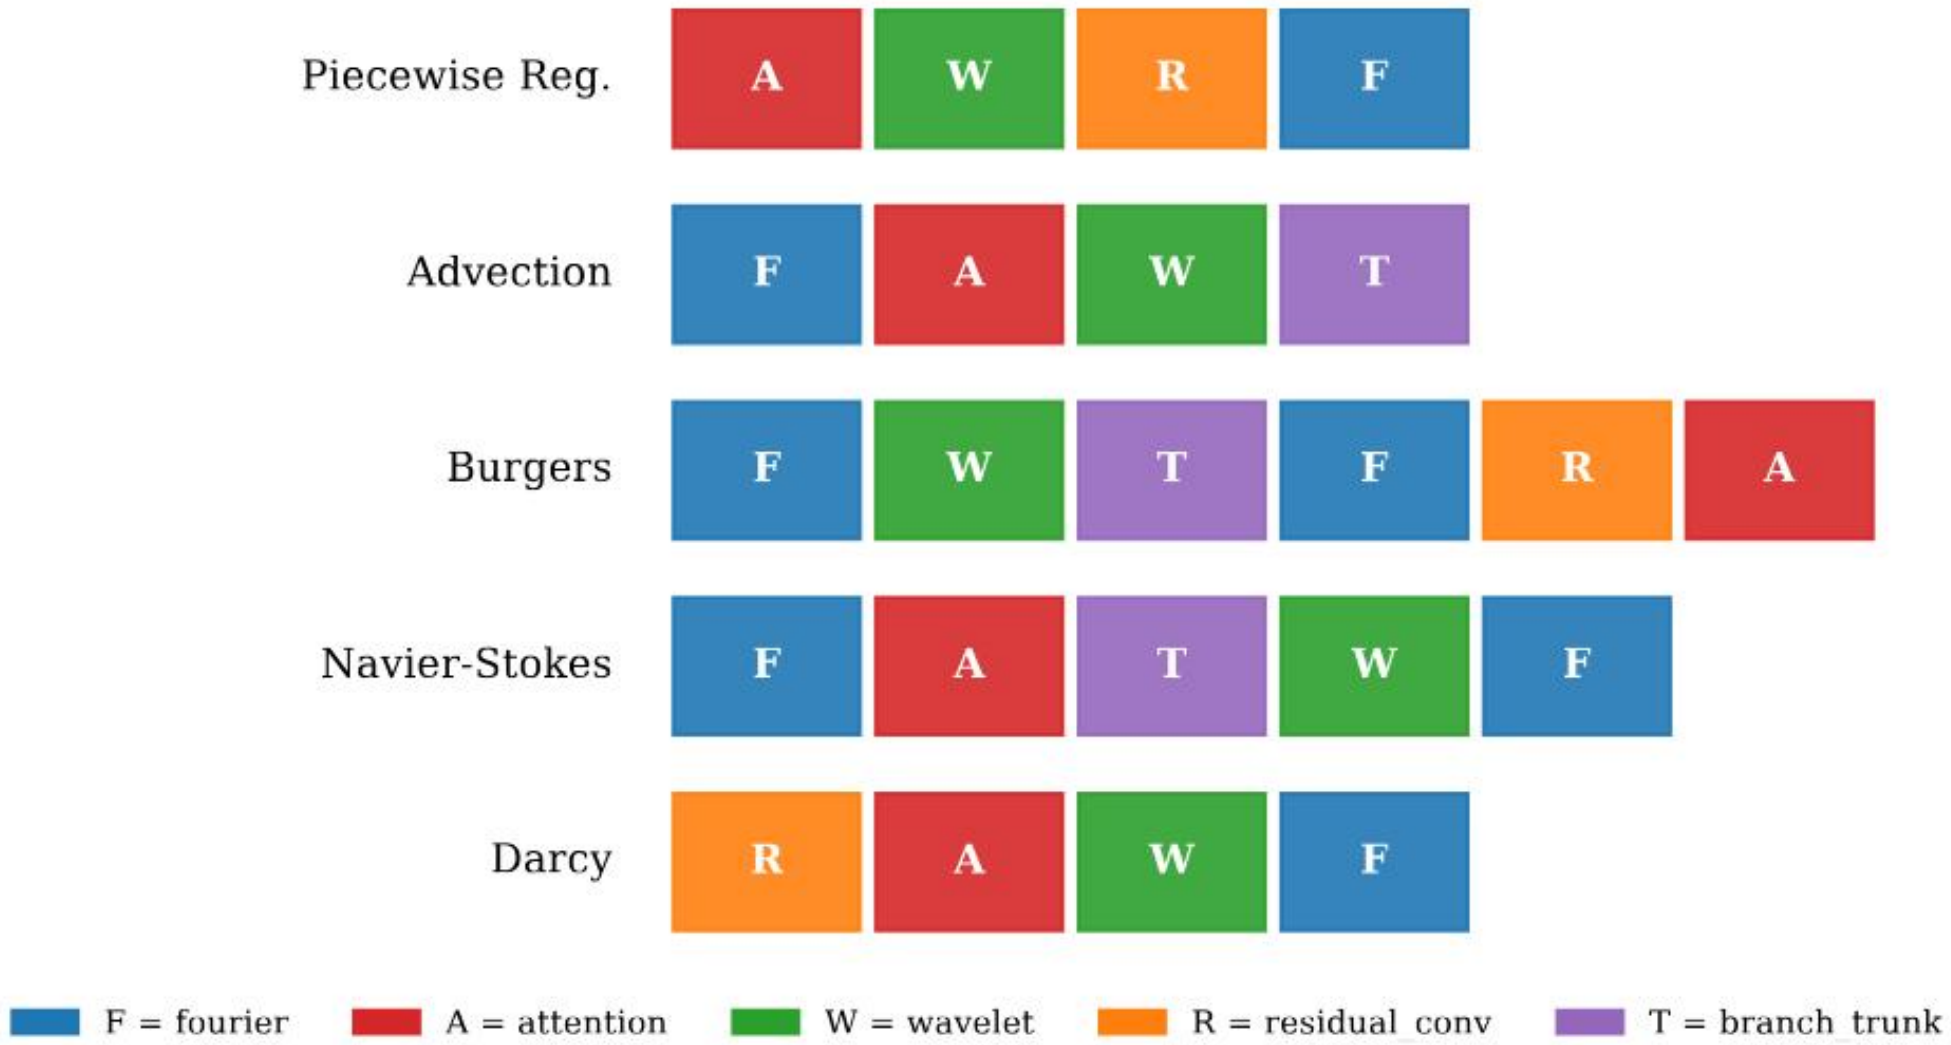
单个lab
1.有5种基础算子模块
F 傅里叶算子
A 注意力机制
W 小波算子
R 残差卷积
T 分支-主干块 DeepONet

2.每次迭代：
Planner：LLM根据自身历史、全局最优架构、同行实验室表现摘要，生成新的算子架构基因组（如F-A-W-T序列，并设定超参数等）
Worker：使用确定的算法训练基因组，并在干净数据和加噪数据上测量误差
Reviewer：抽取一部分同行lab的候选架构和指标，利用LLM进行同行评审并投票
3.消融实验中本地部署的LLM可被换成粒子群规则，以证明LLM的作用

宏观演化
1.同行的投票累加为信任分（五角星）
2.系统结合各个指标计算分数（+）
3.两个分数高的lab可以繁衍后代
4.淘汰分数低的实验室

新lab会替代旧lab以保证总数量不变

五个问题的最终架构


Piecewise Reg.
A
W
R
F
Advection
F
A
W
T
Burgers
F
W
T
F
R
A
Navier-Stokes
F
A
T
W
F
Darcy
R
A
W
F
F = fourier
A = attention
W = wavelet
R = residual_conv
T = branch_trunk

实验

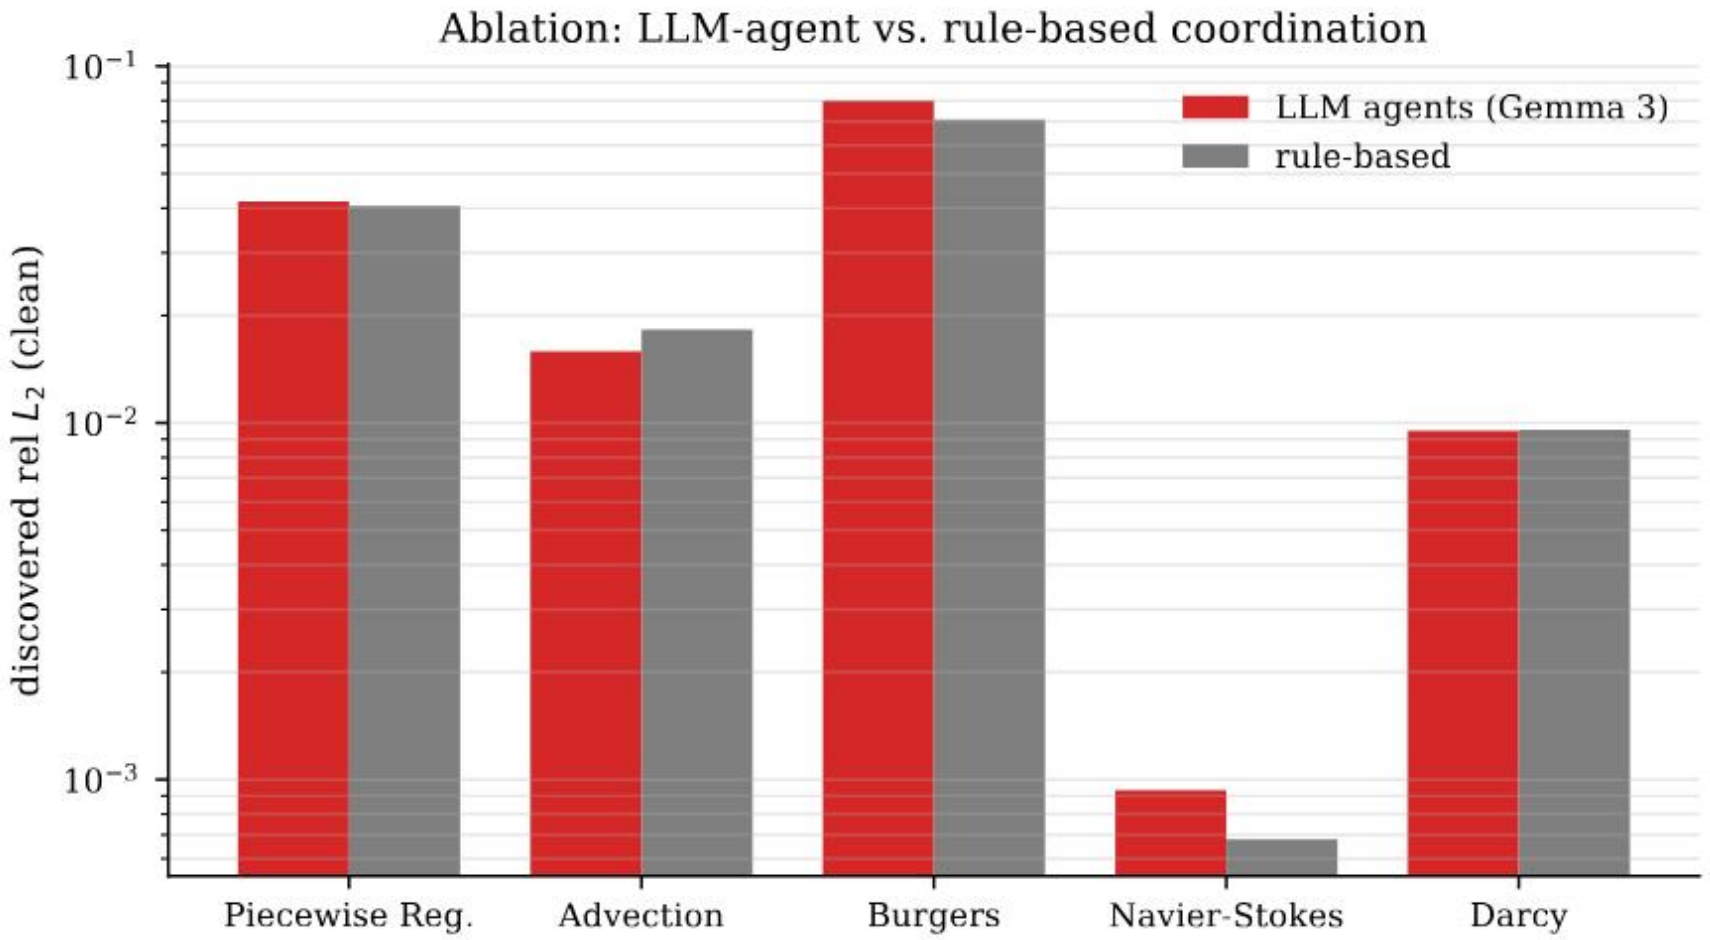
Model	Params	NS-2D rel. L_2	Darcy-2D rel. L_2
Discovered hybrid (Darcy)	1.3M	0.0018±0.0002	0.0631±0.0083
Discovered hybrid (NS)	1.1M	0.0005±0.0000	0.7127±0.0736
DeepONet	603K	0.1613±0.0122	0.0649±0.0037
POD-DeepONet	142K	0.0033±0.0001	0.0819±0.0028
FNO	1.2M	0.0002±0.0000	0.3070±0.0404
Transformer	105K	0.2624±0.0038	0.5207±0.0102

性能对比
冠军均在自己的PDE上达到最优，但在对方的PDE上则表现很差

Problem	Relative L_2 error		Parameter count	
	LLM	rule-based	LLM	rule-based
Piecewise Reg. (1D)	0.0417±0.0011	0.0405±0.0007	487K±258K	198K±95K
Advection (1D)	0.0159±0.0038	0.0183±0.0007	273K±157K	456K±159K
Burgers (1D)	0.0799±0.0067	0.0709±0.0047	472K±415K	197K±103K
Navier-Stokes (2D)	0.0009±0.0005	0.0007±0.0000	2.2M±613K	5.6M±4.1M
Darcy (2D)	0.0095±0.0003	0.0096±0.0015	1.4M±403K	966K±593K

对比LLM和PSO，发现LLM在复杂问题上参数量明显更少
数据不是很强，标准差过大，因为只做了3次重复实验

实验



消融实验，使用LLM和PSO的最终架构的L2误差
LLM在准确率上没有展现明显差异，但是提供了架构的多样性与小参数量

多样性使得架构可解释性更强，更符合人的直观想法，潜在地更适合扩展到其他PDE

总结

概述：搜索最合适的架构，用于解决PDE求解问题
优点：
1.整体参数量小，计算和时间开销友好，单卡需要串行，多卡则可以并行。对比网格搜索等方式，总搜索数要少的多（五种算子、序列长度2-8、超参数）
2.在有限的资源上做出的效果还算不错
3.通用性与可扩展性

待解决的问题和存在的问题：
1.LLM只接受提示词，没有额外的物理知识；LLM使用小模型，对于更长程的架构搜索，不确定是否上下文够用
2.可以扩展到其他各个领域
3.实验次数少，数据比较弱，性能和参数量等方面都不能保证最优
4.只是搜索架构和超参数，优化的范围比较窄，并不能突破单一模型的上限，没有做到agent超越单一模型的效果

PINNMorph: Evolving Online Adaptation Policies for Physics-Informed Neural Networks

Xu Yang[1], Mingyang Yu[2], Jun Zhang[3], Keqian Li[1], Jing Xu[2]

[1]East China Normal University
[2]Nankai University
[3]Hanyang University

PINNMorph
https://arxiv.org/abs/2609.32685

PINNMorph

解决求解PDE的问题

神经网络u作为解函数

输入[N,d]代表N个探测点的坐标，也可能包含时间

输出[N,c]代表这N个点预测的c个物理量

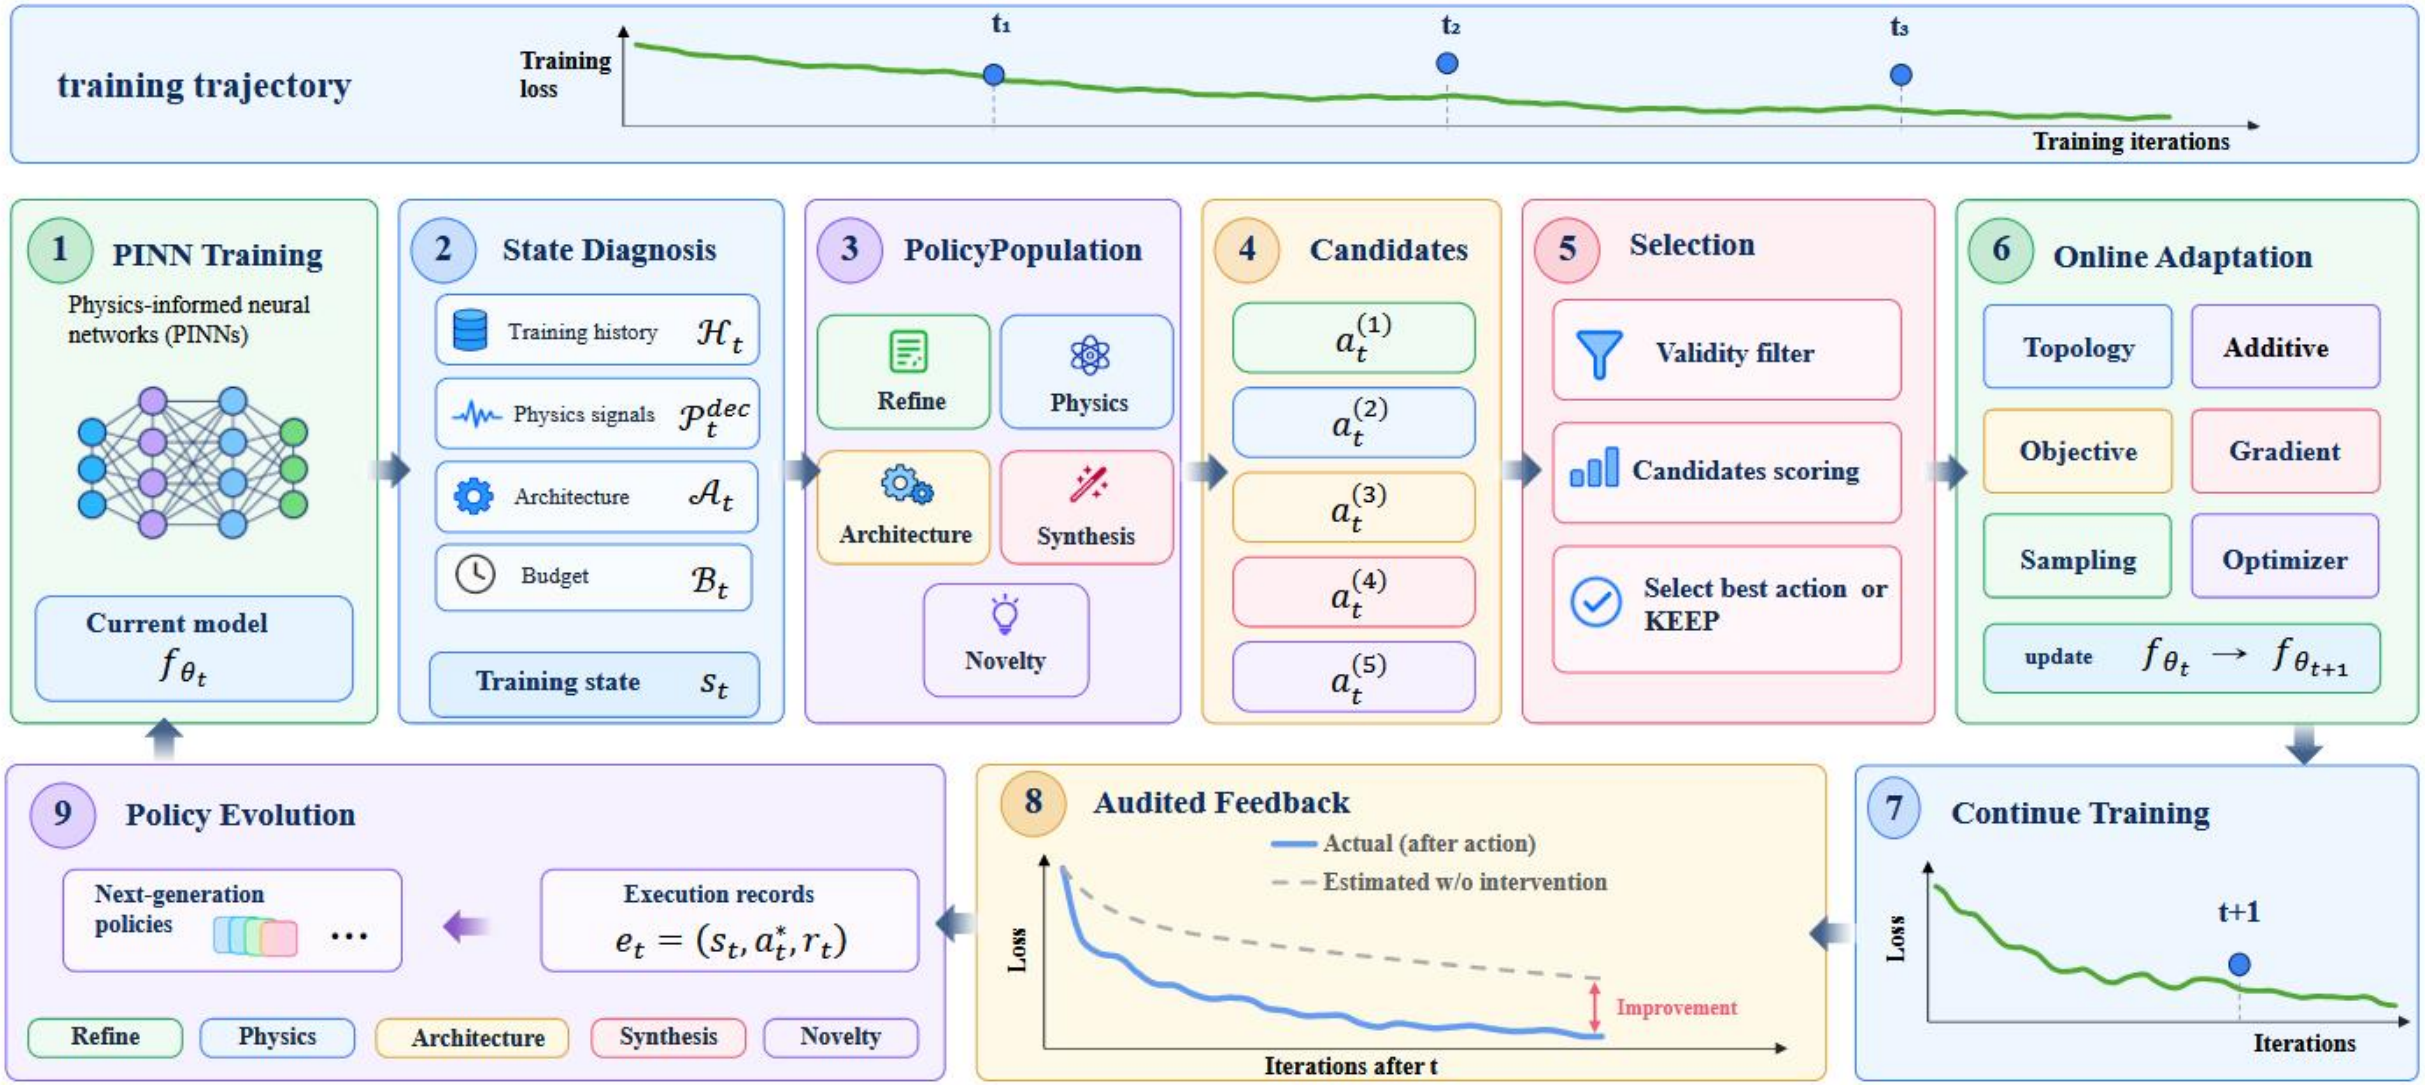
借鉴了遗传算法

用agent辅助改进网络或训练过程

针对每个PDE和其特定条件，都训练一个单独的网络

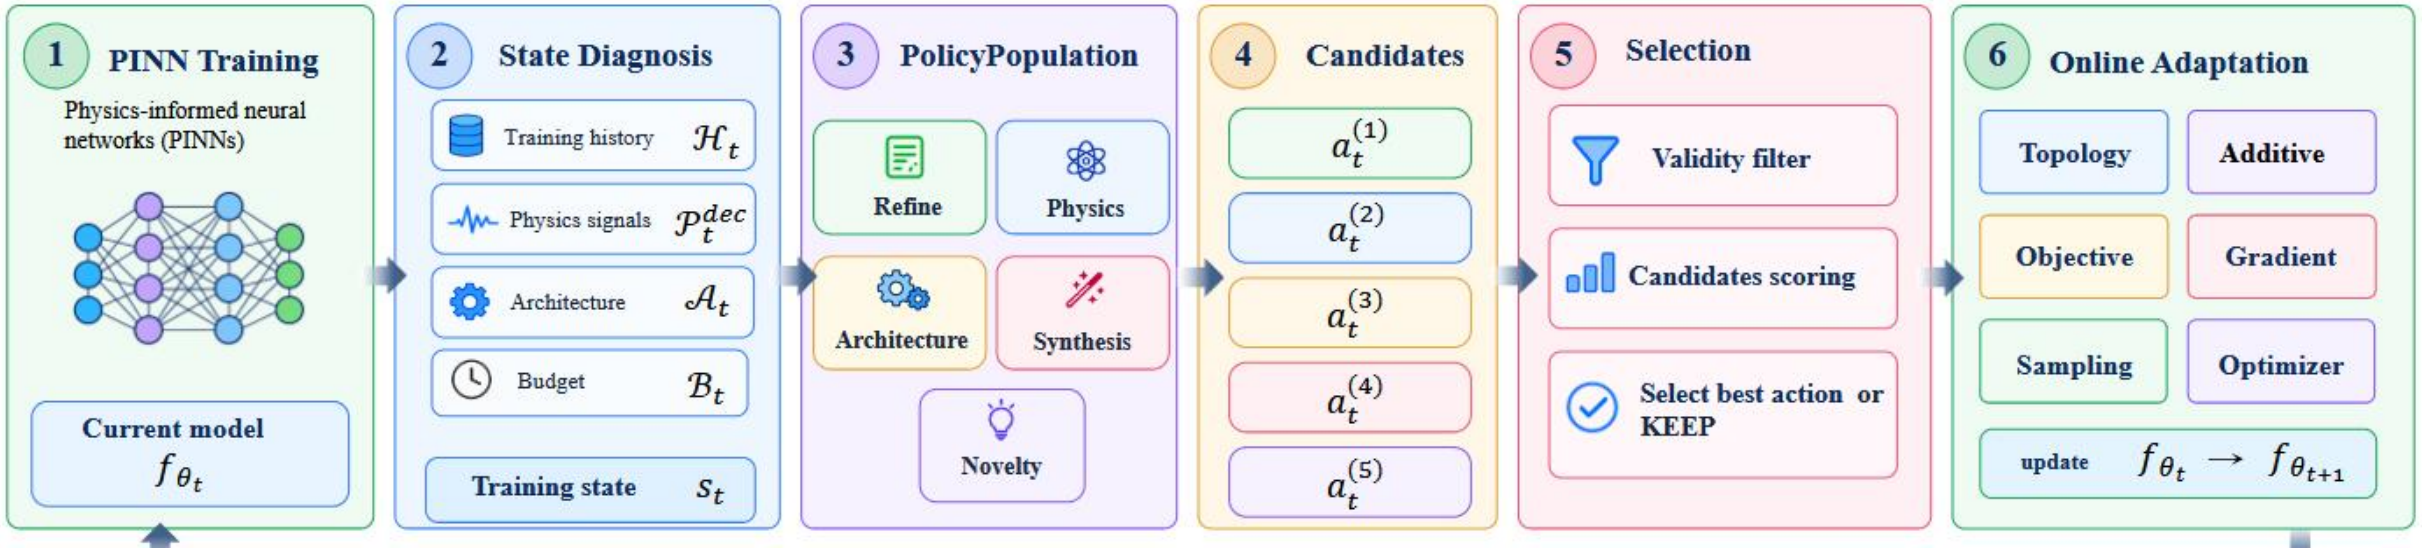
额外条件（边界、初值等）都包含在损失函数中

在考虑小模型训练问题时，可以参考这个方法，对小模型进行适当修改


training trajectory
Training loss
t₁
t₂
t₃
Training iterations
1 PINN Training
Physics-informed neural networks (PINNs)
Current model f_{θ_t}
2 State Diagnosis
Training history $\mathcal{H}_t$
Physics signals $\mathcal{P}_t^{dec}$
Architecture $\mathcal{A}_t$
Budget $\mathcal{B}_t$
Training state s_t
3 PolicyPopulation
Refine
Physics
Architecture
Synthesis
Novelty
4 Candidates
$a_t^{(1)}$
$a_t^{(2)}$
$a_t^{(3)}$
$a_t^{(4)}$
$a_t^{(5)}$
5 Selection
Validity filter
Candidates scoring
Select best action or KEEP
6 Online Adaptation
Topology
Additive
Objective
Gradient
Sampling
Optimizer
update $f_{\theta_t} \rightarrow f_{\theta_{t+1}}$
7 Continue Training
Loss
t+1
Iterations
8 Audited Feedback
Actual (after action)
Estimated w/o intervention
Loss
Improvement
Iterations after t
9 Policy Evolution
Next-generation policies
...
Execution records
$e_t = (s_t, a_t^*, r_t)$
Refine
Physics
Architecture
Synthesis
Novelty

Policy Population
五种改进的思考维度
Refine，对当前不错的策略进行优化
Physics，根据当前的物理错误生成策略，如边界违反严重
Architecture，分析当前网络的问题，来给出策略
Synthesis，融合不同策略的优点
Novelty，鼓励探索新干预方向

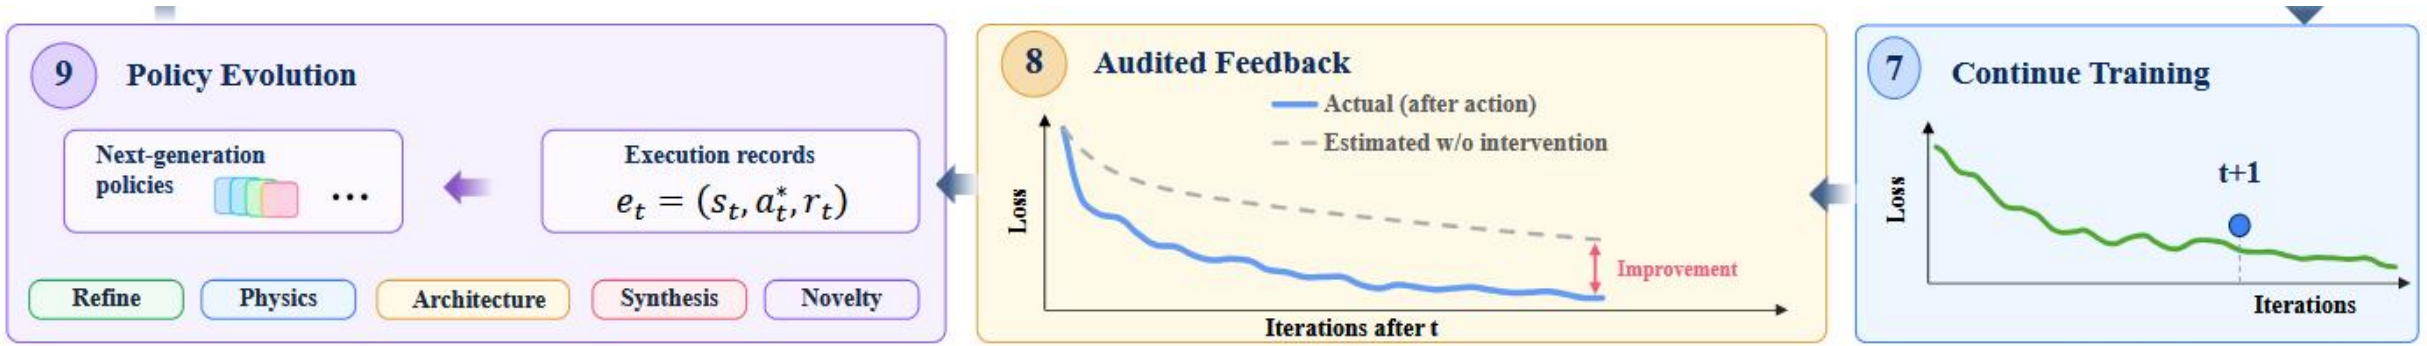
Selection
所有候选动作经过筛选：
1.有效性过滤：是否是个有效的动作
2.候选打分：评分模型（qwen3.8-27B）打分
3.选择最优动作或KEEP：选择打分最高的动作at*，或者不干预



State Diagnosis
收集信息构建训练状态St：
1.训练历史，近期的优化表现与之前的干预记录
2.物理信号：在决策集上测得的结果指标
3.网络架构：当前模型架构
4.训练预算：剩余的训练步数与执行上下文

Candidates
5个策略根据当前训练状态St分别给出一个候选干预动作

Online Adaptation
将动作应用到模型，涉及6类：
1.架构修改
2.增加模块
3.调整多个损失之间的权重
4.梯度相关修改
5.根据残差分布，替换高残差区域的采样点
6.调整优化器
保留已经学到的权重和优化器状态



Policy Evolution
执行记录(St,at*,rt)存入库
LLM利用这些记录生成下一代策略种群 用于3

Audited Feedback
在一个审计点集上，测试干预后网络得到误差曲线，对历史曲线外推得到未干预曲线，对比计算出收益反馈

总结

概述：在网络训练过程中，LLM设计干预动作优化训练过程；LLM的提示词可进化
可学习的点：
1.对经典算法的借鉴
2.agent优化训练小模型的方法
3.可用于其他领域

问题：
1.无法突破单一模型上限
2.LLM与打分模型只是提示词改变，进化效果很局限
3.网络作用范围很局限，更换PDE或条件后都需要训练新模型

论文	领域	任务	小模型	流程	可学习的点	知识库	问题
TS-Agent	金融	时序预测&生成	代码	根据领域知识选择模型、完善代码、执行代码	**1.**针对特定领域的特定策略 **2.**并行模型选择	金融任务案例&代码与指标库&代码优化启发式规则	**1.**难拓展 **2.**不能处理多模态数据 **3.**受限于给定资源
TimeEvo	时序	时序问题回答	工具（代码、文本、提示词补丁）	**LLM**回答问题，过程中根据错题更新工具（代码），**LLM**参考工具输出的数字修正回答；工具的管理	可参考，作为管理小模型的一个方法例子	工具的输出	**1.**工具都是针对错题生成的，可能缺乏泛化能力 **2.**错误的工具会误导模型的输出 **3.**有点像提示词优化，工具的输出只是作为额外提示词出现，主要还是看**LLM**的性能
TIMEVOLVE	时序	时序预测	冻结的预测模型&可训练的小模型	各个模型都跑一遍预测结果->通过模块将这些结果融合起来->模块的参数会在预测过程中根据真实值更新	1. 融合多个模型结果的想法 2. 利用预测过程中的数据进行训练 **3.**多模态上下文的融合 **4.**小模型在预测过程中的参数更新	多模态上下文	**1.**没有考虑预测对环境的影响 **2.**预测模型全冻结 **3.**缺乏长期与周期测试 **4.**可训练的模型很小，不确定复杂场景的有效性
4KAgent	图像超分	图像超分&4K生成	冻结的各类**SOTA**模型	评估图像确定退化类型->生成计划->调用多个小模型迭代和筛选出最优图像	**1.**通用性与可扩展性 **2.**功能性广泛 **3.agent**效果超越单一模型 **4.agent**达到单一模型没有的功能	**LLM**	**1.**计算资源要求高 **2.**没有自主进化手段 **3.**配置的选择问题
AI-SC	物理	**PDE**求解 初值->解函数 网络作为解算子	基础算子模块	搜索最合适的架构，用于解决**PDE**求解问题	**1.**用**agent**代替基座模型 **2.**时间花销小 **3.**通用性	**LLM**	**1.LLM**没有额外物理知识 **2.**实验数据弱 **3.**只是优化架构组合和超参数，不能像**agent**那样突破单模型的上限
PINNMorph	物理	**PDE**求解 网络作为解函数	**PINN**模型	在网络训练过程中，**LLM**设计干预动作优化训练过程；**LLM**的提示词可进化	1. 对经典算法的借鉴 **2.agent**优化训练小模型的方法 3. 可用于其他领域	训练中的上下文	1无法突破单一模型上限 **2.LLM**与打分模型只是提示词改变，进化效果很局限 3. 网络作用范围很局限，更换**PDE**或条件后都需要训练新模型

最后总结

问题：
1.大多数方法，都不会对小模型进行很大范围的修改
　　冻结、根据代码库、模块的组合、架构的小幅度修改
2.没有考虑过真实场景
　　时间/计算的花销、长程预测、真实环境的影响
3.存在套路化现象，比如很多方法本质都是反复调用LLM，加入多层保障和检查，让模型输出更稳定
4.基本上都是从问题出发，设计一个框架，或许可以考虑从框架出发，考虑哪些部分的优化可以让框架更进一步

启发：
1.专家模型的训练与微调/从零开始构建专家模型
2.尝试加入真实约束，但可能需要有对应的bench才好做实验
3.利用agent的特性，让方法可以提供通用性和可拓展性
4.框架只要在设计过程中改进就好，要想提高性能更重要的还是改进具体管理的模型
5.找一个场景，考虑如何让agent超过单一模型的性能，或者是如何让agent通过小模型组合达成单一模型做不到的功能
6.不要局限于现有框架，这是一个很新的领域